

Points d'intérêt

Arnaud LE BRIS



IGN – ENSG – LaSTIG

<http://recherche.ign.fr/labos/matis>
arnaud.le-bris@ign.fr



2022 - 2023



Invariants locaux

-

Détection et appariement de points d'intérêt



Introduction : invariance ponctuelle

Processus de vision

→ Extraction de primitives :

- contours
- points d'intérêt



- points isolés
- coins
- intersections
- “blobs”

• Avantage des points :

- correspondent à des doubles discontinuités
- soit occultés, soit visibles
- existent dans la majorité des images
- plus simples à détecter (pas de chaînage)

• Points destinés à être mis en correspondance

→ Répétabilité de la détection

Répétabilité de la détection

Définition

P point 3D

Si l'image de P est détectée dans l'image 1
alors :

P est “répété” dans l'image i
ssi l'image de P dans i est détectée

Conditions d'invariance

- Changement de point de vue :
 - Rotation
 - Echelle
 - Déformations locales
- Variation d'illumination

Répétabilité de la détection

Définition

P point 3D

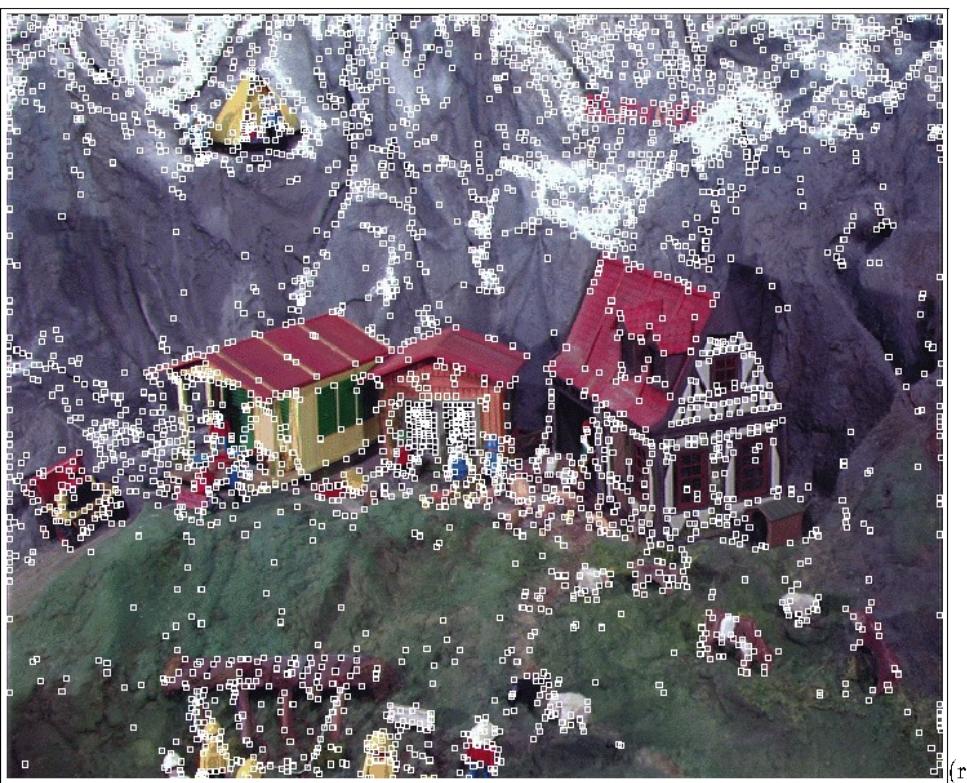
Si l'image de P est détectée dans l'image I alors :

P est "répété" dans l'image I' si l'image de P dans



Conditions d'invariance

- Changement de point de vue :
 - Rotation
 - Echelle
 - Déformations locales
- Variation d'illumination
- Bruit



Qualités d'une méthode de détection et d'appariement de points d'intérêt

- **Répétabilité**

aptitude à détecter des points correspondant aux mêmes détails

- **Précision**

pas seulement correspondre à un même détail,
mais aussi **être précis géométriquement**

(cf coordonnées)

Ces deux principaux critères impliquent d'être :

- **Invariant** à la translation, à la rotation, au changement d'échelle, aux déformations...
- **Robuste** au bruit, aux conditions d'acquisition de l'image, à la compression, ...
- **Discriminant** : i.e. permettant d'obtenir quelques points correspondant à des détails spécifiques (en vue de l'appariement)

Détection des points d'intérêt

Qualités d'un détecteur de points d'intérêt

Autres critères (plus ou moins importants selon l'application visée)

- **Quantité :**

Aptitude à extraire beaucoup de points caractéristiques

- **Efficacité / rapidité :** calcul rapide

(important pour applications temps réel)

Détection de points d'intérêt

<http://www.robots.ox.ac.uk/~vgg/research/affine/detectors.html>

Principales qualités d'un détecteur de points d'intérêt

- **Répétabilité**
aptitude à détecter des points correspondant aux mêmes détails
- **Précision**
pas seulement correspondre à un même détail,
mais aussi être précis géométriquement
(cf coordonnées)
- **Discriminant**
aptitude à obtenir quelques points correspondant à des détails spécifiques
(en vue de l'appariement)

Détection des points d'intérêt

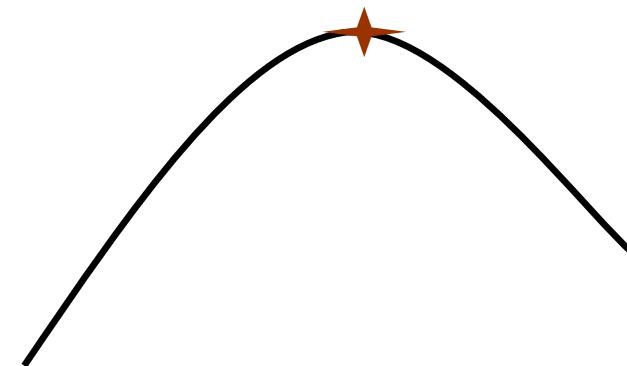
Détection...

- Approche contour
- Approche modèle
- Approche intensité : directement à partir de l'image

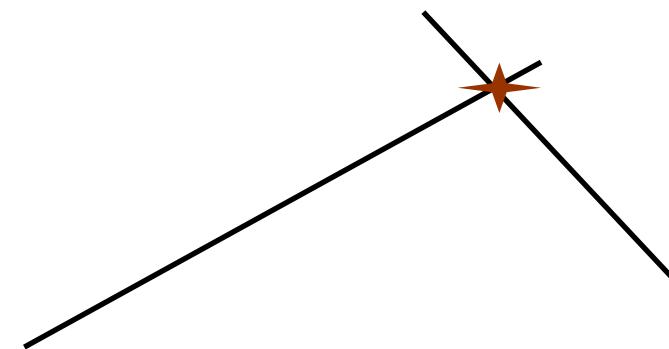
Détection des points d'intérêt

Détection à partir de contours

- Courbure

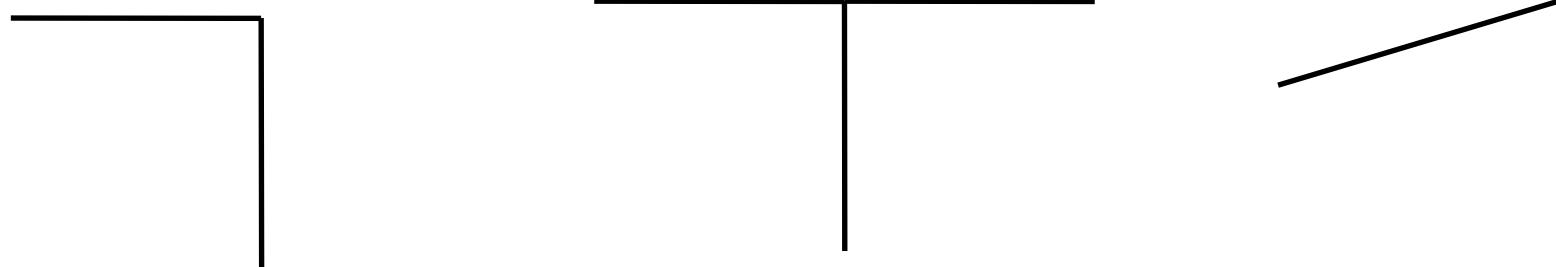


- Intersection de droite



Détection des points d'intérêt

Détection à partir de modèles



+ : grande précision

- : répétabilité

Détection des points d'intérêt

Détection directement à partir de l'image

- + stable
- + générale

Des détecteurs de coins et de points isolés...
(Moravec, Harris...)

...aux détecteurs de “blobs” et aux détecteurs de “régions”

Détection des points d'intérêt : Moravec

Détecteur de coin de Moravec (1980)

- Considérer le voisinage w (i.e. une fenêtre) d'un pixel (x_0, y_0)
- Déterminer changements moyens de l'intensité de l'image dans ce voisinage pour de petits déplacements (dx, dy) de la fenêtre dans différentes directions.

$$E_{dx,dy}(w) = \sum_{x,y} w(x, y) \cdot |I(x+dx, y+dy) - I(x, y)|^2$$

- ◆ Si image à peu près constante : mesure faible dans toutes les directions
- ◆ Si contour : mesure forte pour déplacements perpendiculaires à la ligne et faible pour des déplacements le long de la ligne
- ◆ Si coin ou point isolé : mesure forte dans toutes directions

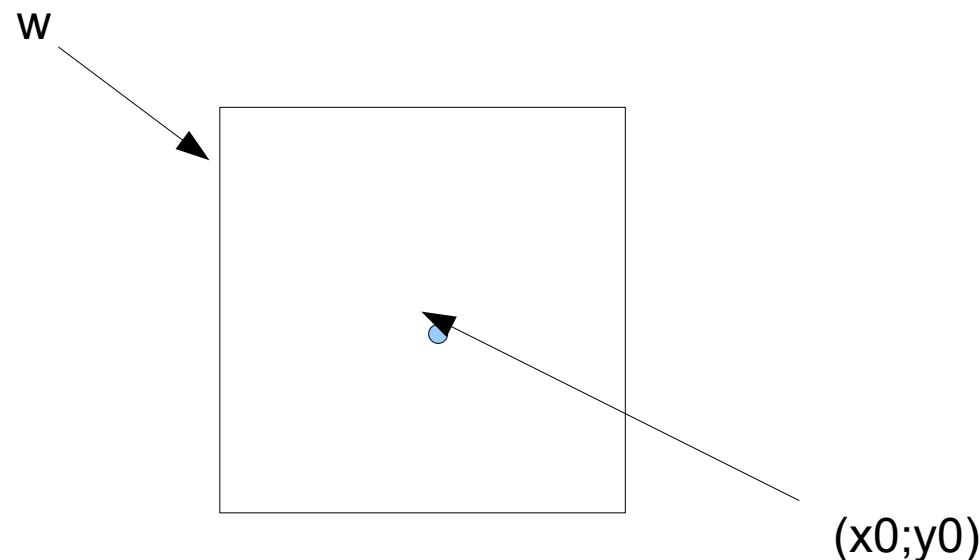
→ Recherche des maxima locaux de $\min_{dx, dy \in \{-1; 0; 1\}} E_{dx,dy}(x_0, y_0)$

Détection des points d'intérêt : Moravec

Détecteur de coin de Moravec (1980)

- Considérer le voisinage w (i.e. une fenêtre) d'un pixel (x_0, y_0)
- Déterminer changements moyens de l'intensité de l'image dans ce voisinage pour de petits déplacements (dx, dy) de la fenêtre dans différentes directions.

$$E_{dx,dy}(w) = \sum_{x,y} w(x, y) \cdot |I(x+dx, y+dy) - I(x, y)|^2$$

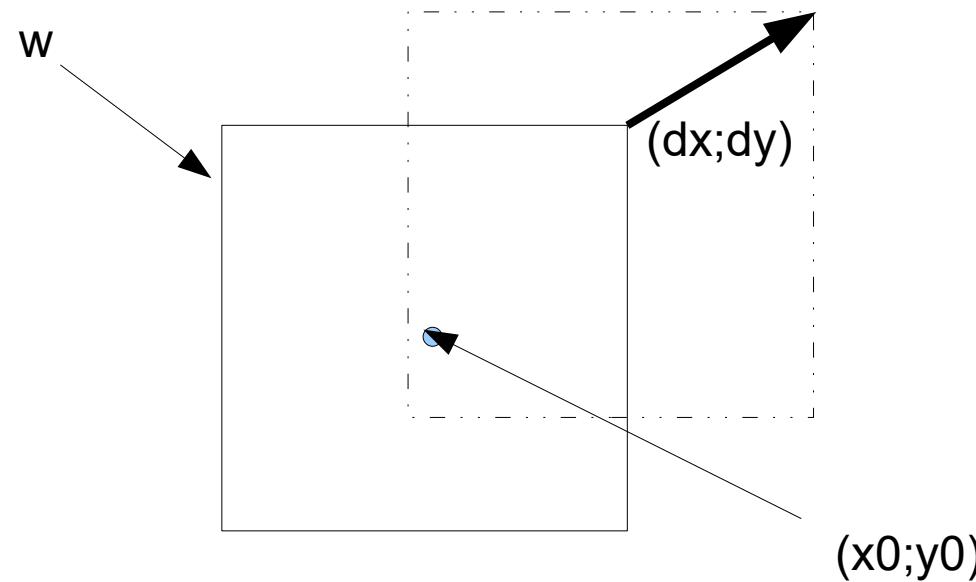


Détection des points d'intérêt : Moravec

Détecteur de coin de Moravec (1980)

- Considérer le voisinage w (i.e. une fenêtre) d'un pixel (x_0, y_0)
- Déterminer changements moyens de l'intensité de l'image dans ce voisinage pour de petits déplacements (dx, dy) de la fenêtre dans différentes directions.

$$E_{dx,dy}(w) = \sum_{x,y} w(x, y) \cdot |I(x+dx, y+dy) - I(x, y)|^2$$

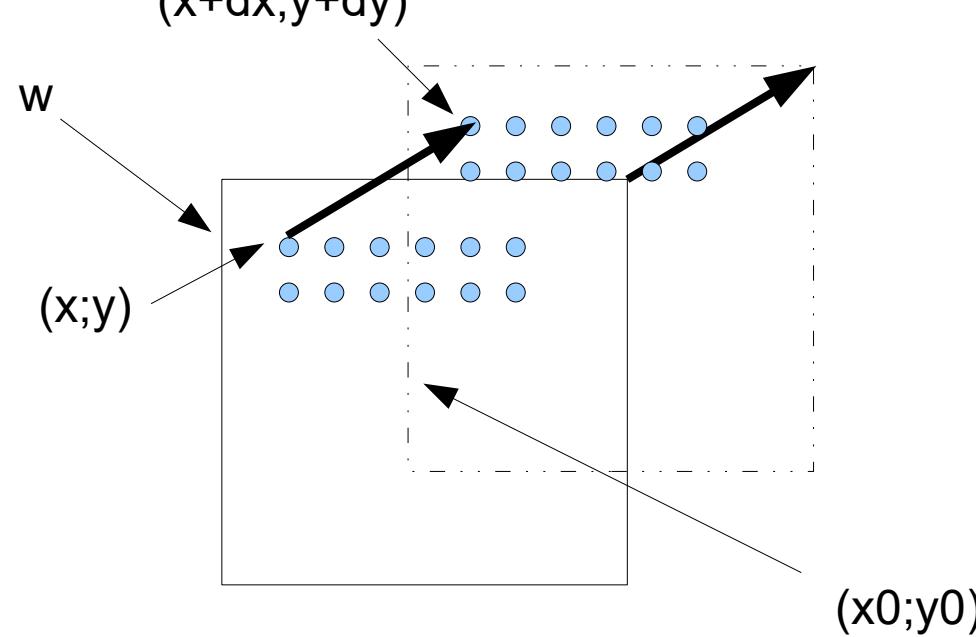


Détection des points d'intérêt : Moravec

Détecteur de coin de Moravec (1980)

- Considérer le voisinage w (i.e. une fenêtre) d'un pixel (x_0, y_0)
- Déterminer changements moyens de l'intensité de l'image dans ce voisinage pour de petits déplacements (dx, dy) de la fenêtre dans différentes directions.

$$E_{dx,dy}(w) = \sum_{x,y} w(x, y) \cdot |I(x+dx, y+dy) - I(x, y)|^2$$



Détection des points d'intérêt : Moravec

Coin ou point isolé



Contour

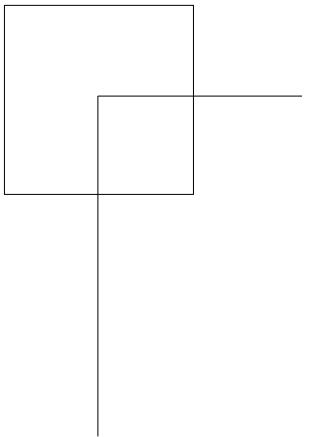


Zone de l'image à
peu près constante



Détection des points d'intérêt : Moravec

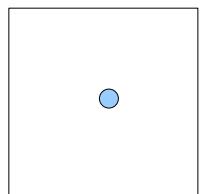
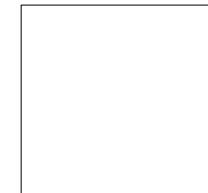
Coin ou point isolé



Contour

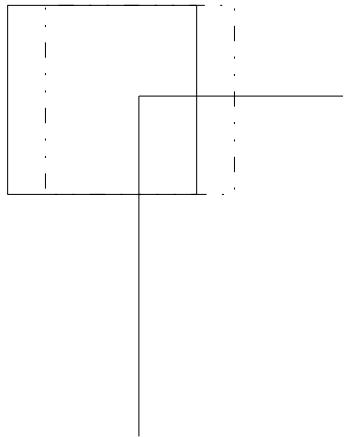


Zone de l'image à peu près constante

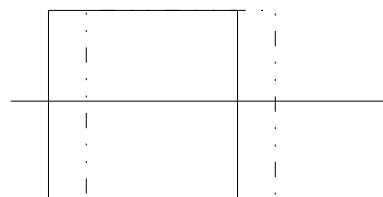


Détection des points d'intérêt : Moravec

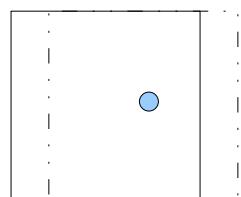
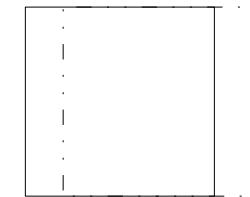
Coin ou point isolé



Contour

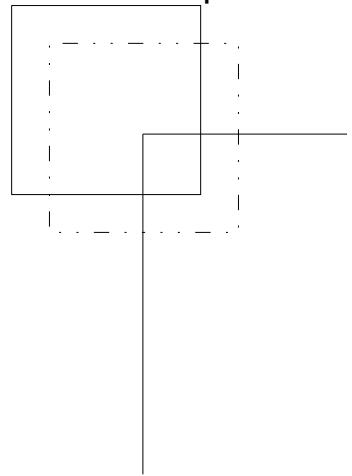


Zone de l'image à peu près constante

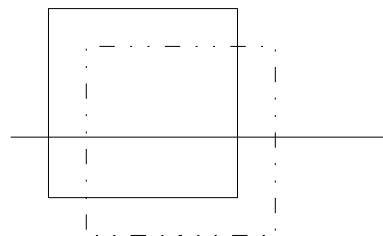


Détection des points d'intérêt : Moravec

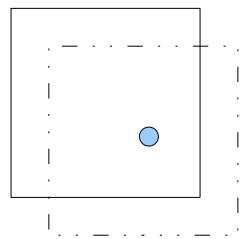
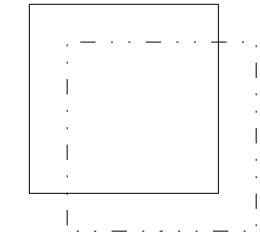
Coin ou point isolé



Contour

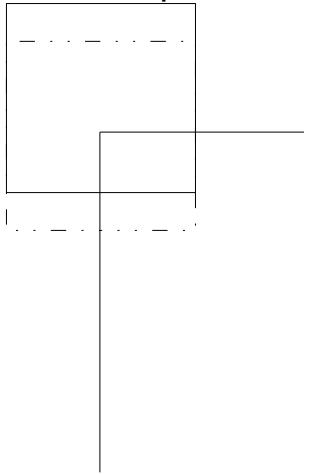


Zone de l'image à peu près constante

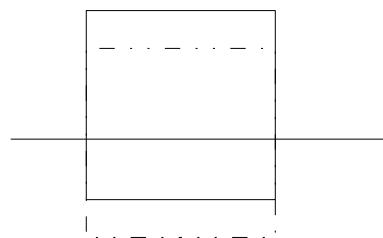


Détection des points d'intérêt : Moravec

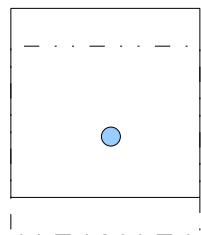
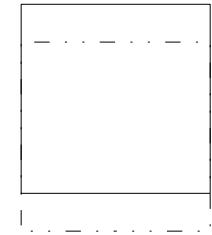
Coin ou point isolé



Contour

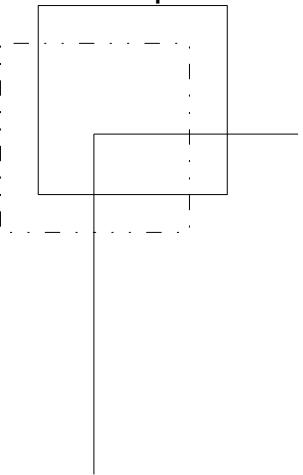


Zone de l'image à peu près constante

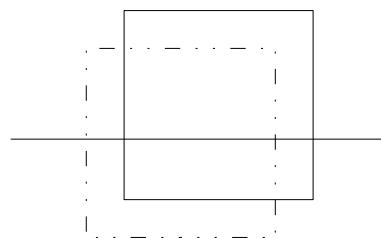


Détection des points d'intérêt : Moravec

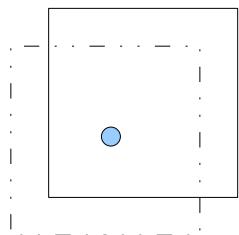
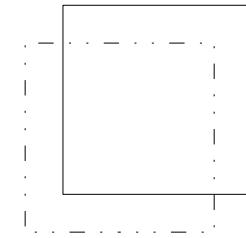
Coin ou point isolé



Contour

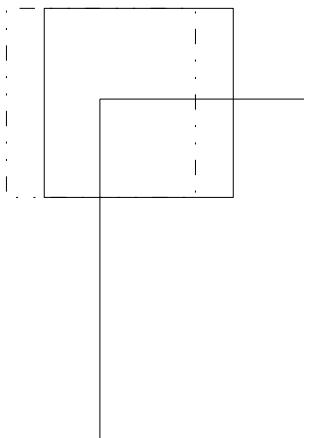


Zone de l'image à peu près constante

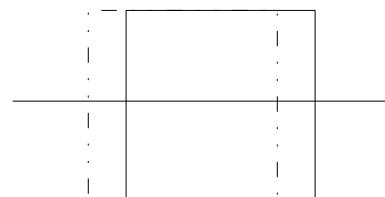


Détection des points d'intérêt : Moravec

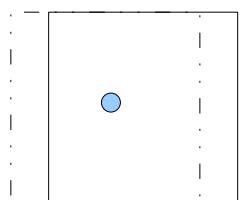
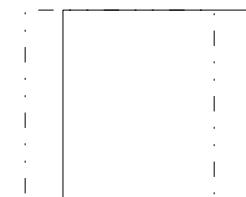
Coin ou point isolé



Contour

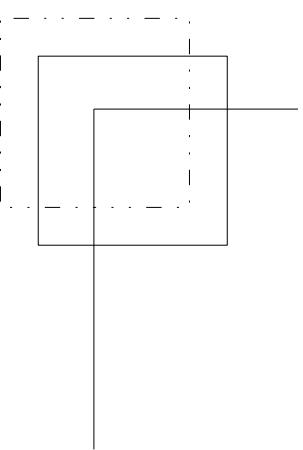


Zone de l'image à peu près constante

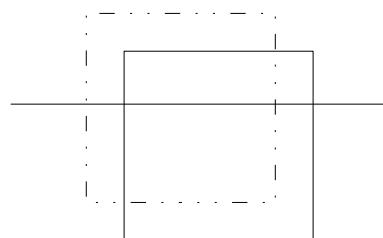


Détection des points d'intérêt : Moravec

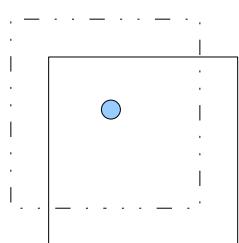
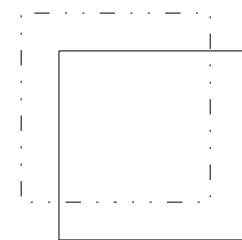
Coin ou point isolé



Contour

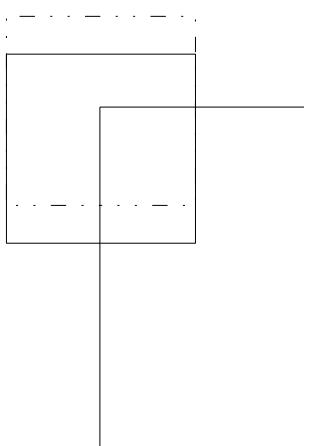


Zone de l'image à peu près constante

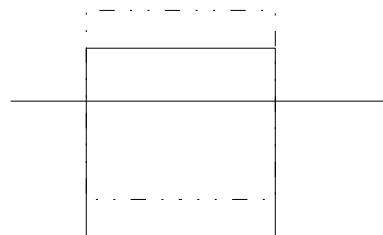


Détection des points d'intérêt : Moravec

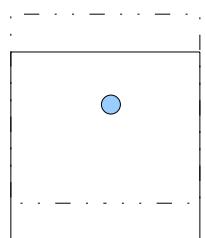
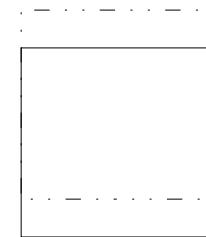
Coin ou point isolé



Contour

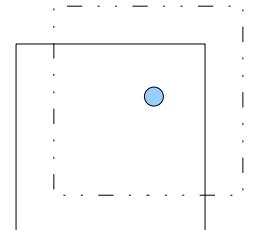
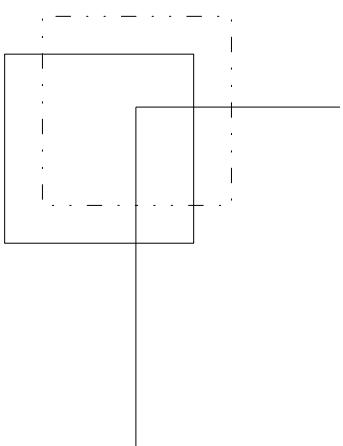


Zone de l'image à peu près constante



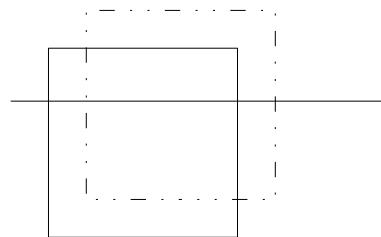
Détection des points d'intérêt : Moravec

Coin ou point isolé



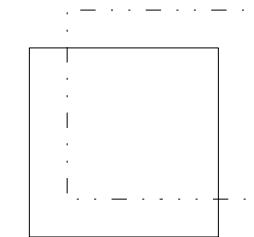
Mesure forte
dans toutes les directions

Contour



Mesure forte pour déplacements
perpendiculaires à la ligne
et faible pour des déplacements
le long de la ligne

Zone de l'image à
peu près constante



Mesure faible
dans toutes les directions

Détection des points d'intérêt : Moravec

Détecteur de coin de Moravec (1980)

- Considérer le voisinage w (i.e. une fenêtre) d'un pixel (x_0, y_0)
- Déterminer changements moyens de l'intensité de l'image dans ce voisinage pour de petits déplacements (dx, dy) de la fenêtre dans différentes directions.

$$E_{dx,dy}(w) = \sum_{x,y} w(x, y) \cdot |I(x+dx, y+dy) - I(x, y)|^2$$

- ◆ Si image à peu près constante : mesure faible dans toutes les directions
- ◆ Si contour : mesure forte pour déplacements perpendiculaires à la ligne et faible pour des déplacements le long de la ligne
- ◆ Si coin ou point isolé : mesure forte dans toutes directions

→ Recherche des maxima locaux de $\min_{dx, dy \in \{-1; 0; 1\}} E_{dx,dy}(x_0, y_0)$

Détection des points d'intérêt : Harris

Détecteur de Harris (1988)

Amélioration du détecteur de Moravec

Recherche des maxima locaux de $R(x,y)$ supérieurs à un seuil

$$R(x,y) = \text{Det}(M) - k \cdot [\text{Tr}(M)]^2$$

$$M = G_\sigma * \begin{bmatrix} (I_x(x,y))^2 & I_x(x,y) \cdot I_y(x,y) \\ I_x(x,y) \cdot I_y & (I_y(x,y))^2 \end{bmatrix}$$

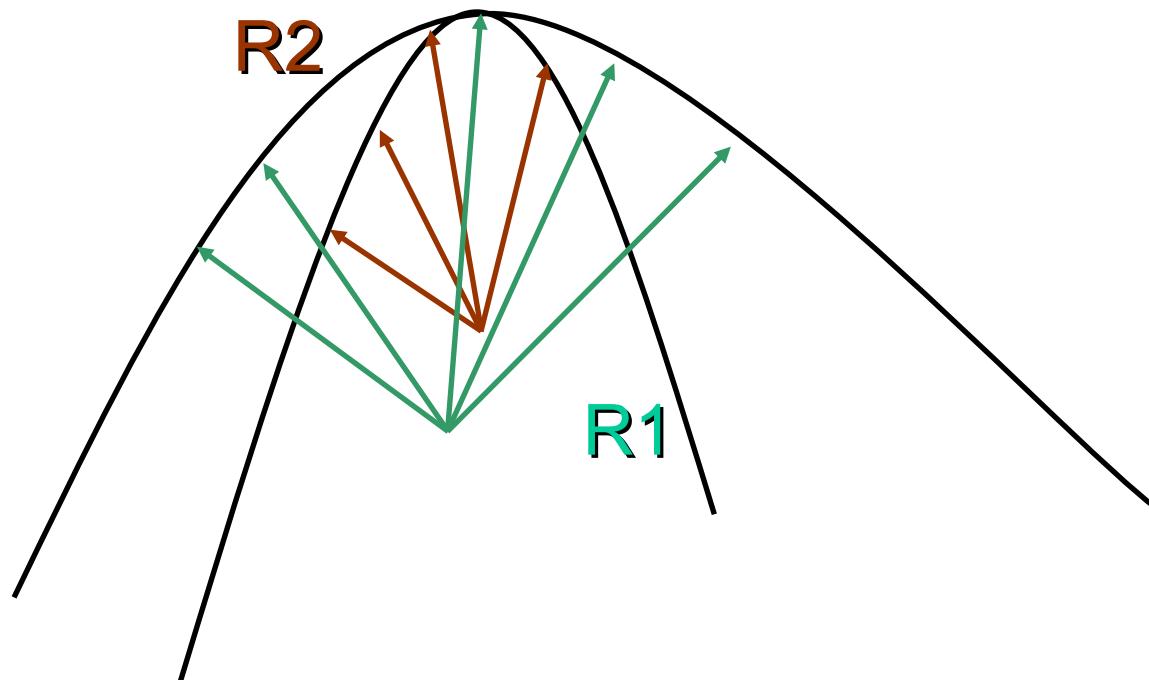
$$I_x = \frac{\partial I}{\partial x} = [-1 \quad 0 \quad 1] * I$$

$$I_y = \frac{\partial I}{\partial y} = [1 \quad 0 \quad -1] * I$$

Harris, C. and Stephens, M. A combined corner and edge detector. In *Alvey Vision Conference*, pp 147-151, 1988

A quoi correspond la mesure ?

Valeurs propres de la matrice correspondent aux courbures de la fonction locale d'autocorrélation

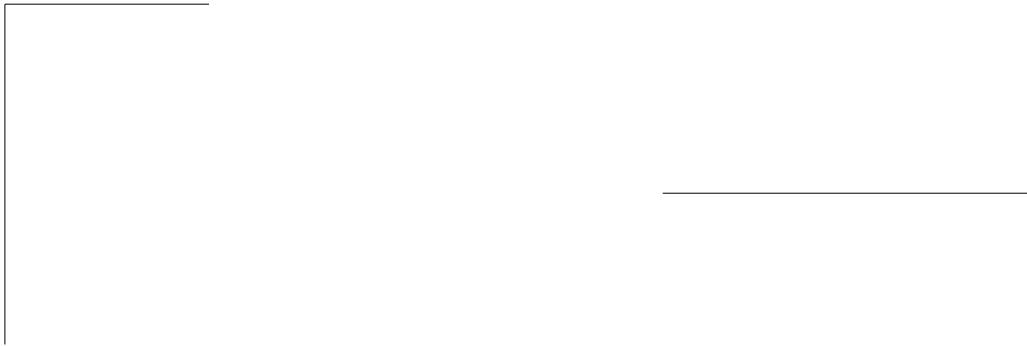


Détection des points d'intérêt : Harris

Coin ou point isolé

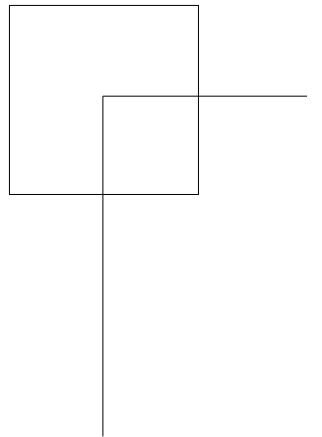
Contour

Zone de l'image à
peu près constante



Détection des points d'intérêt : Harris

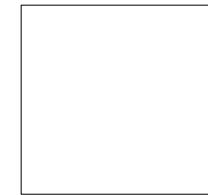
Coin ou point isolé



Contour

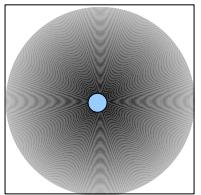
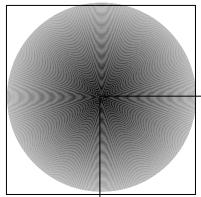


Zone de l'image à peu près constante

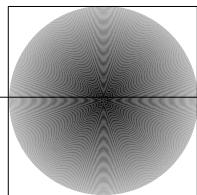


Détection des points d'intérêt : Harris

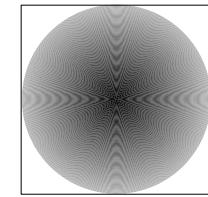
Coin ou point isolé



Contour

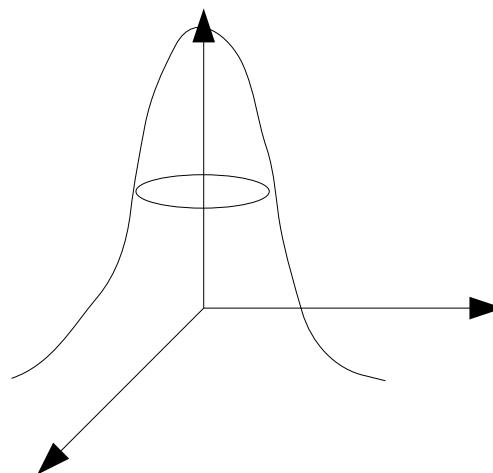
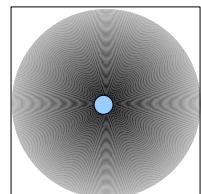
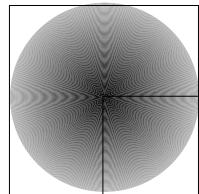


Zone de l'image à peu près constante

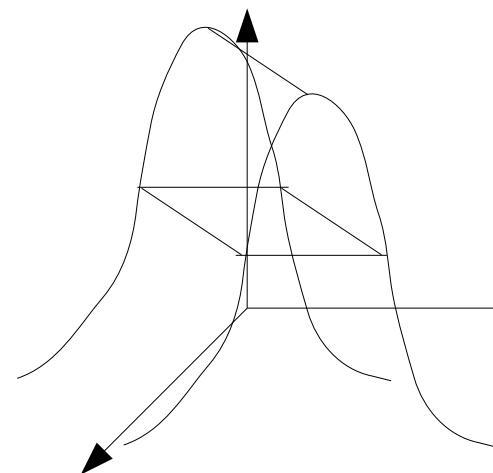
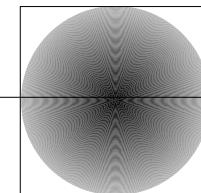


Détection des points d'intérêt : Harris

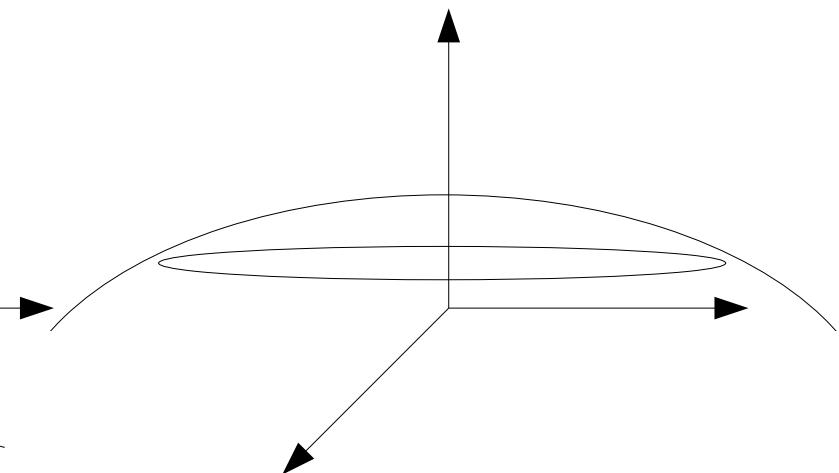
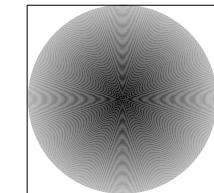
Coin ou point isolé



Contour

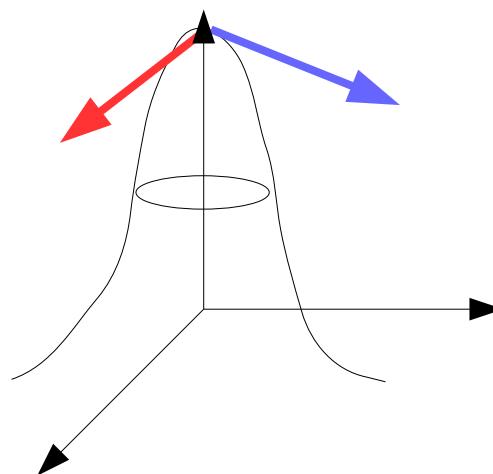
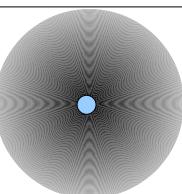
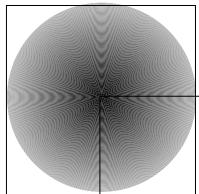


Zone de l'image à peu près constante

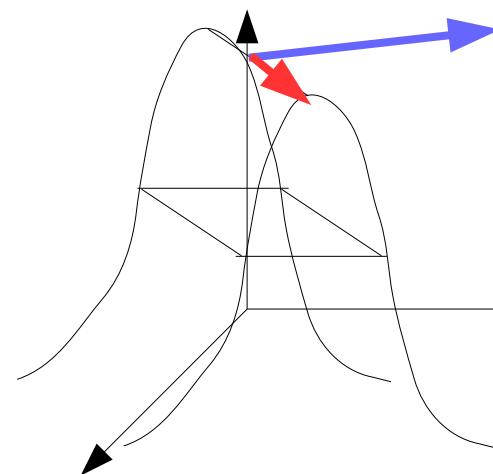
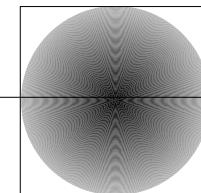


Détection des points d'intérêt : Harris

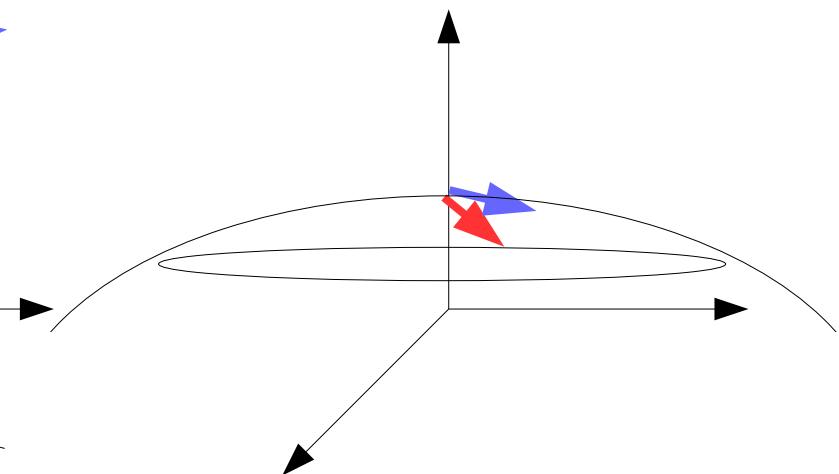
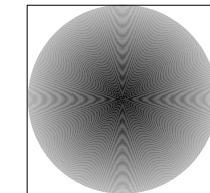
Coin ou point isolé



Contour

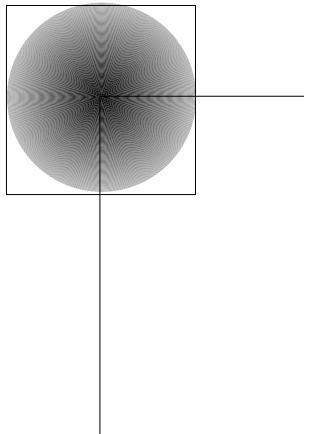


Zone de l'image à peu près constante

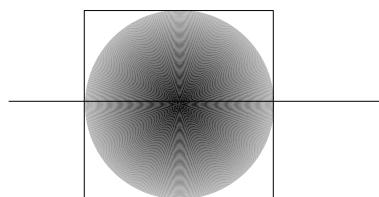


Détection des points d'intérêt : Harris

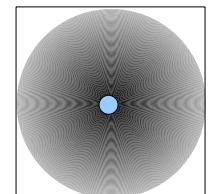
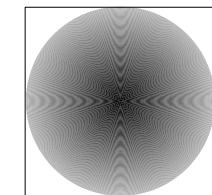
Coin ou point isolé



Contour



Zone de l'image à peu près constante



Courbure forte dans les deux directions principales

Valeurs propres de M toutes deux fortes

Courbure forte dans une des directions principales
Courbure faible dans l'autre

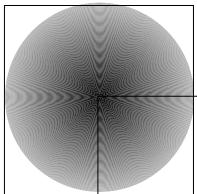
Une valeur propre de M forte,
l'autre faible

Courbure faible dans les deux directions principales

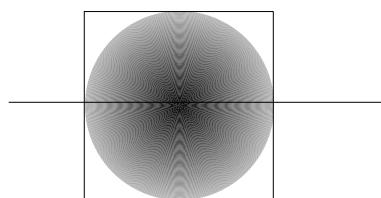
Valeurs propres de M toutes deux faibles

Détection des points d'intérêt : Harris

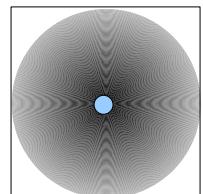
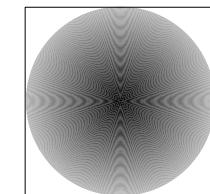
Coin ou point isolé



Contour



Zone de l'image à peu près constante



$$R = \text{Det}(M) - k \cdot [\text{Tr}(M)]^2$$

Une manière de comparer les valeurs propres L_1 et L_2 de M sans les calculer explicitement....

$$R = L_1 \cdot L_2 - k \cdot [L_1 + L_2]^2$$

Courbure forte dans les deux directions principales

Valeurs propres de M toutes deux fortes

R fortement positif
 $R \gg 0$

Courbure forte dans une des directions principales
Courbure faible dans l'autre

Une valeur propre de M forte,
l'autre faible

R fortement négatif
 $R \ll 0$

Courbure faible dans les deux directions principales

Valeurs propres de M toutes deux faibles

R faible en valeur absolue

Détection des points d'intérêt : Harris



Détection des points d'intérêt : Harris

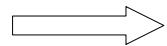
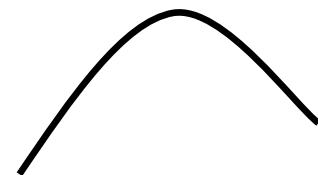


Détection des points d'intérêt : Harris



Invariance à l'échelle

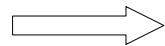
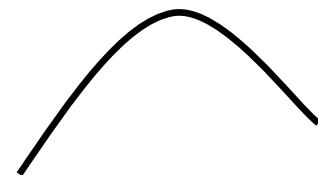
Moravec et Harris = détecteurs de coins ou de points isolés
Pb : pas d'invariance à l'échelle



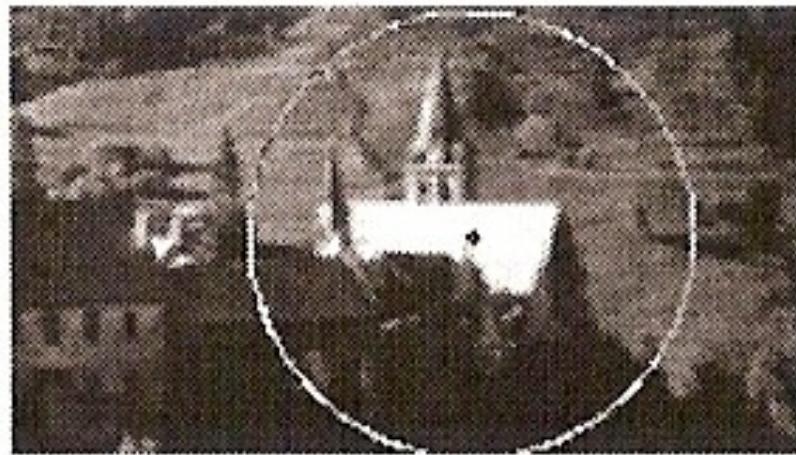
Prendre en compte la notion d'échelle

Invariance à l'échelle

Moravec et Harris = détecteurs de coins ou de points isolés
Pb : pas d'invariance à l'échelle

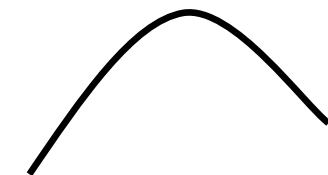


Prendre en compte la notion d'échelle

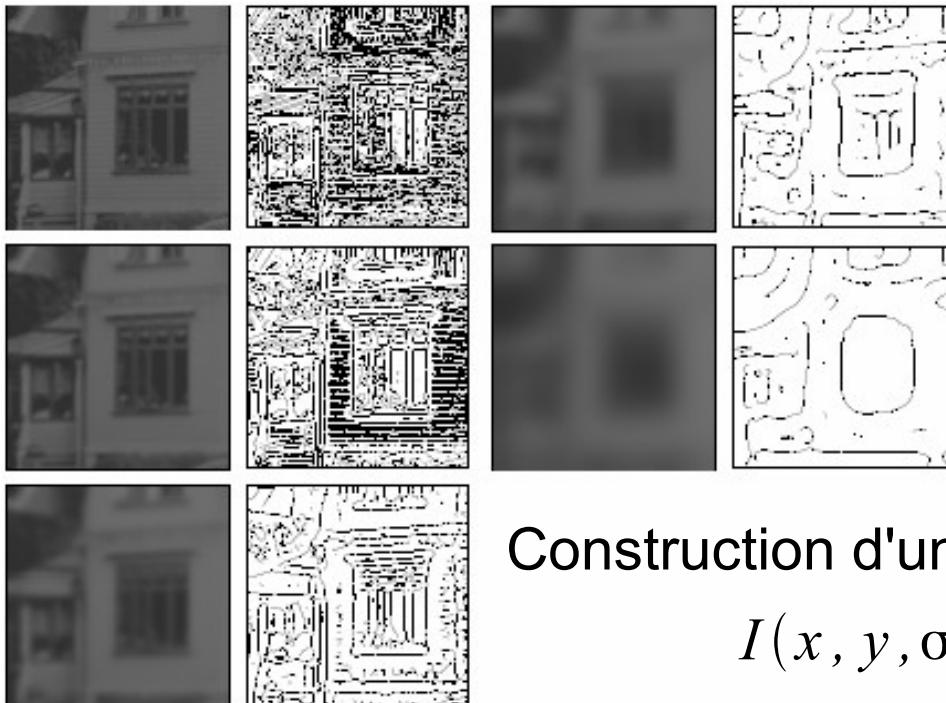


Invariance à l'échelle

Moravec et Harris = détecteurs de coins ou de points isolés
Pb : pas d'invariance à l'échelle



Prendre en compte la notion d'échelle



Construction d'un “scale space” (espace d'échelles)

$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$



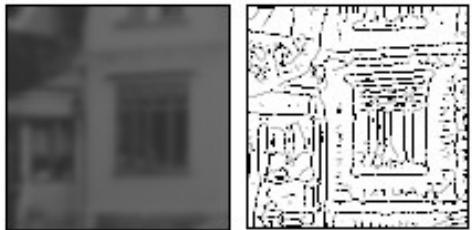
Construction d'un “scale space” (espace d'échelles)

$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$



Harris “multi-échelles” naïf ?

→ Appliquer le détecteur de Harris à chaque niveau de l'espace d'échelles ?



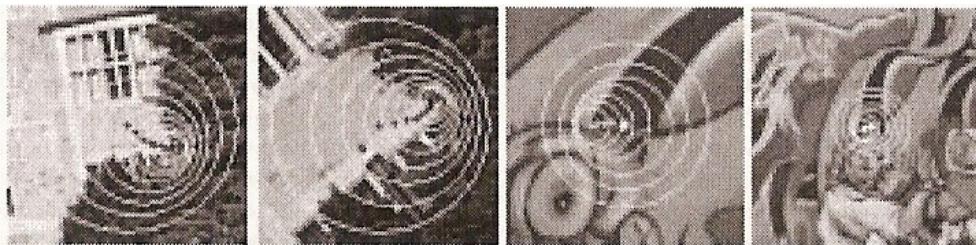
Construction d'un “scale space” (espace d'échelles)

$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$



Harris “multi-échelles” naïf ?

→ Appliquer le détecteur de Harris à chaque niveau de l'espace d'échelles ?



Pb de surdétection : détection multiple d'un même point...



Construction d'un “scale space” (espace d'échelles)

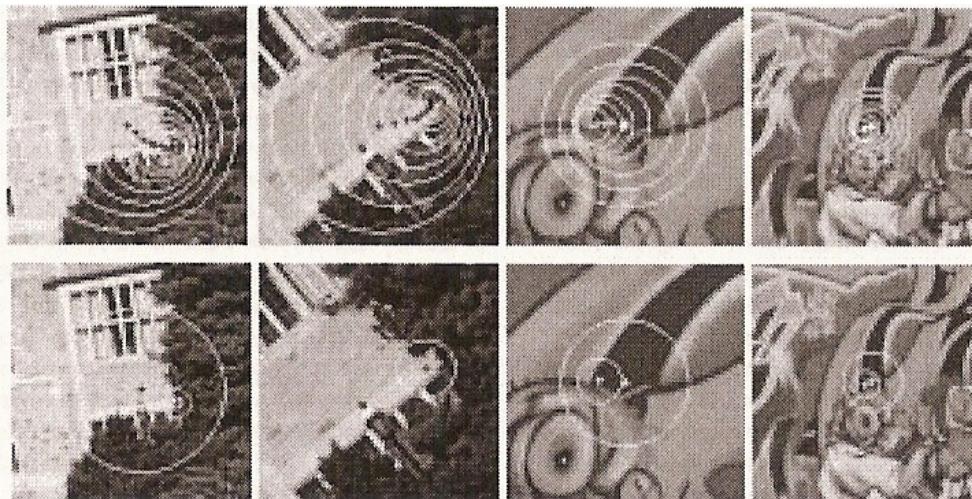
$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$





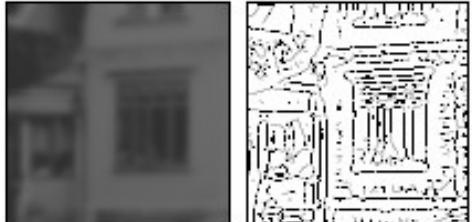
Harris “multi-échelles” naïf ?

→ Appliquer le détecteur de Harris à chaque niveau de l'espace d'échelles ?



Pb de surdétection : détection multiple d'un même point...

→ Nécessité d'un autre critère



Construction d'un “scale space” (espace d'échelles)

$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$

Détection des points d'intérêt : Harris-Laplace

Détecteur de Harris-Laplace (2004)

Recherche des maxima locaux de R

$$R = \text{Det}(M) - k \cdot [\text{Tr}(M)]^2$$

$$L_x = \frac{\partial L}{\partial x}, \dots$$

$$L(x, y, \sigma) = (G_\sigma * I)(x, y)$$

$$M(x, y, \sigma_I, \sigma_D) = G_{\sigma_I} * \begin{bmatrix} L_x^2(x, y, \sigma_D) & L_x \cdot L_y(x, y, \sigma_D) \\ L_x \cdot L_y(x, y, \sigma_D) & L_y^2(x, y, \sigma_D) \end{bmatrix}$$

et des maxima locaux de |LoG|

(pour sélection de l'échelle caractéristique)

$$|\text{LoG}(x, y, \sigma_D)| = \sigma_D^2 \cdot |L_{xx}(x, y, \sigma_D) + L_{yy}(x, y, \sigma_D)|$$

Algorithme

- Détection des points de Harris à chaque niveau $\sigma_n = (1,4)^n \cdot \sigma_0$ de l'espace d'échelles
(Utilisation de la mesure $R(x,y,\sigma_D, \sigma_I)$ pour $\sigma_I = \sigma_n$ et $\sigma_D = 0,7 \cdot \sigma_n$)
- Pour chaque point $m^{(0)}(x^{(0)}, y^{(0)}, \sigma^{(0)})$ détecté :
on itère les actions suivantes tant que $m^{(k)} \neq m^{(k+1)}$
 - ◆ Recherche de l'extremum du LoG au point $(x^{(k)}, y^{(k)})$ parmi les échelles voisines de $\sigma^{(k)}$.
Si aucun extremum détecté : point rejeté
Sinon : $\sigma^{(k+1)} \leftarrow \sigma_m$ (échelle pour laquelle l'extremum est atteint)
 - ◆ Recherche du maximum de la mesure de Harris le plus proche de $(x^{(k)}, y^{(k)})$ pour $\sigma_I = \sigma^{(k+1)}$ (et $\sigma_D = 0,7 \cdot \sigma_I$).
 $(x^{(k+1)}, y^{(k+1)}) \leftarrow (x_m, y_m)$
 $((x_m, y_m))$ = coordonnées pour lesquelles le maximum est atteint)

Invariance à l'échelle

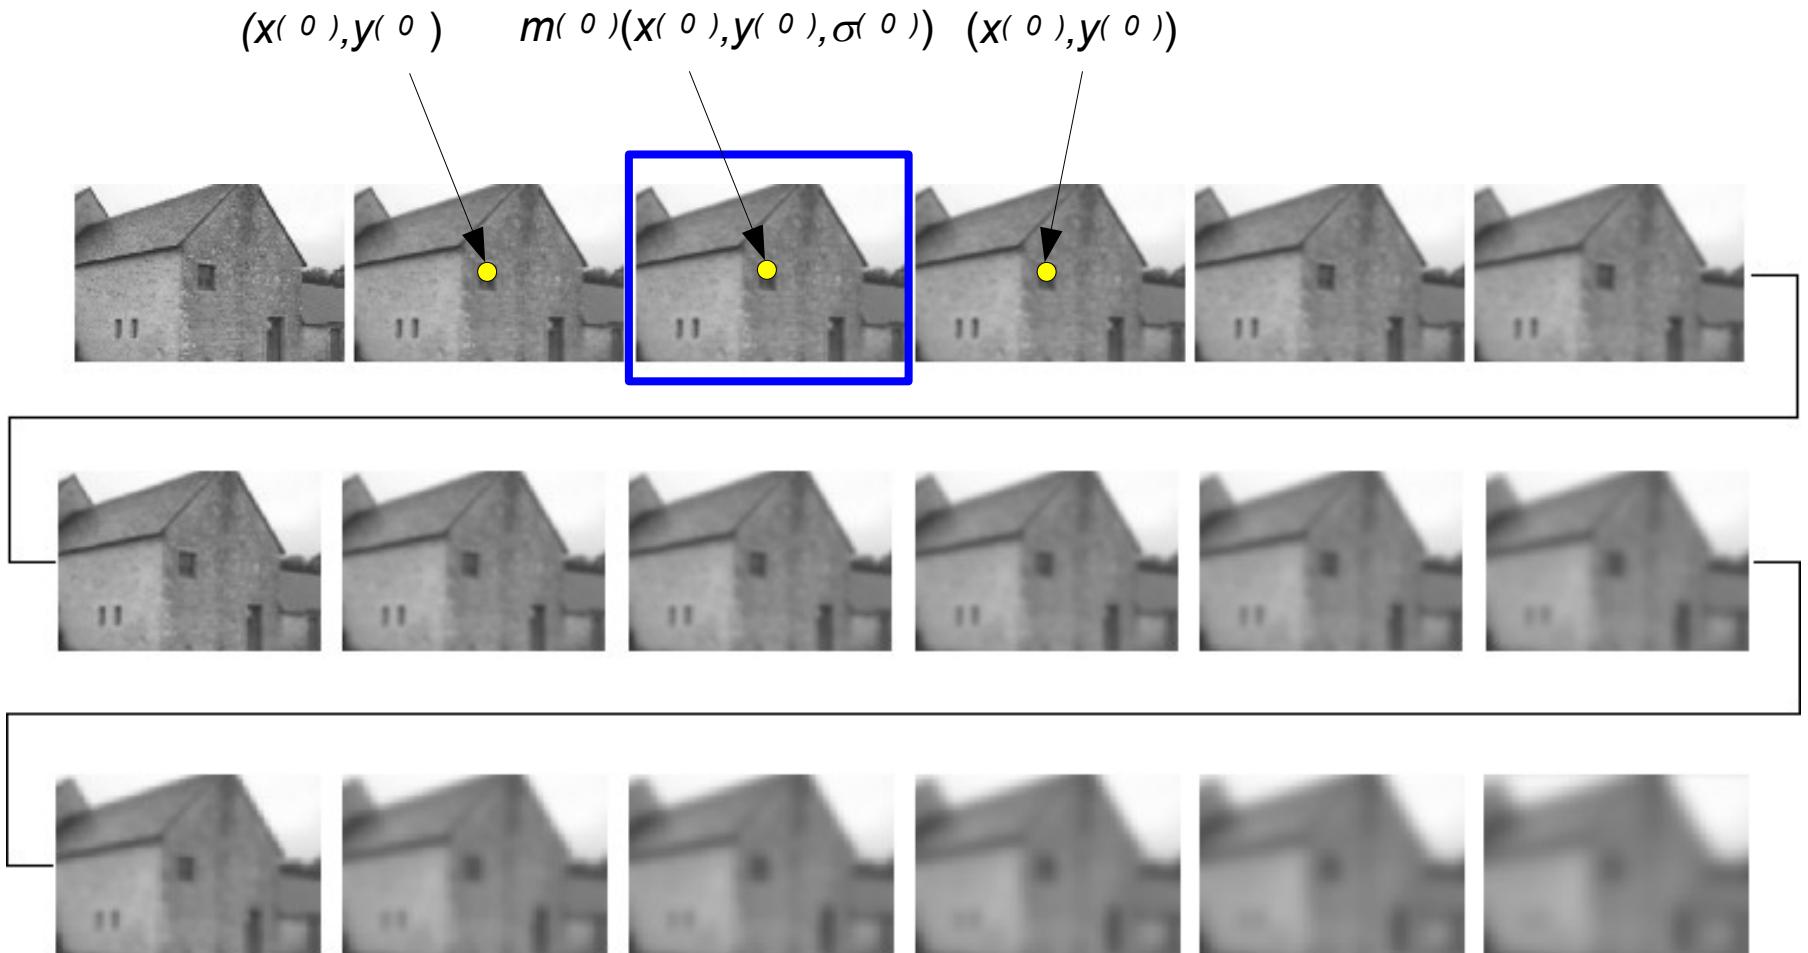


Invariance à l'échelle

$$m(0)(x(0), y(0), \sigma(0))$$



Invariance à l'échelle



Recherche de l'extremum du LoG au point $(x^{(k)}, y^{(k)})$ parmi les échelles voisines de $\sigma^{(k)}$.
Si aucun extremum détecté : point rejeté
Sinon : $\sigma^{(k+1)} \leftarrow \sigma_m$ (échelle pour laquelle l'extremum est atteint)

Invariance à l'échelle

$(x^{(0)}, y^{(0)}, \sigma^{(1)})$



Recherche de l'extremum du LoG au point $(x^{(k)}, y^{(k)})$ parmi les échelles voisines de $\sigma^{(k)}$.

Si aucun extremum détecté : point rejeté

Sinon : $\sigma^{(k+1)} \leftarrow \sigma_m$ (échelle pour laquelle l'extremum est atteint)

Invariance à l'échelle

$(x^{(0)}, y^{(0)}, \sigma^{(1)})$



Recherche du maximum de la mesure de Harris le plus proche de $(x^{(k)}, y^{(k)})$
pour $\sigma_l = \sigma^{(k+1)}$ (et $\sigma_D = 0,7 \cdot \sigma_l$)

Invariance à l'échelle

$(x^{(1)}, y^{(1)}, \sigma^{(1)})$



Recherche du maximum de la mesure de Harris le plus proche de $(x^{(k)}, y^{(k)})$
pour $\sigma_I = \sigma^{(k+1)}$ (et $\sigma_D = 0,7 \cdot \sigma_I$)

Détection des points d'intérêt : Hessian-Laplace

Détecteur Hessian-Laplace

Variante de Harris-Laplace utilisant la hessienne

Recherche des maxima locaux de $\det(H)$

$$H(x, y, \sigma_D) = \begin{bmatrix} L_{xx}(x, y, \sigma_D) & L_{xy}(x, y, \sigma_D) \\ L_{xy}(x, y, \sigma_D) & L_{yy}(x, y, \sigma_D) \end{bmatrix}$$

$$L_{xy} = \frac{\partial^2 L}{\partial x \partial y}, \dots$$

$$L(x, y, \sigma) = (G_\sigma * I)(x, y)$$

et des maxima locaux de $|\text{LoG}|$

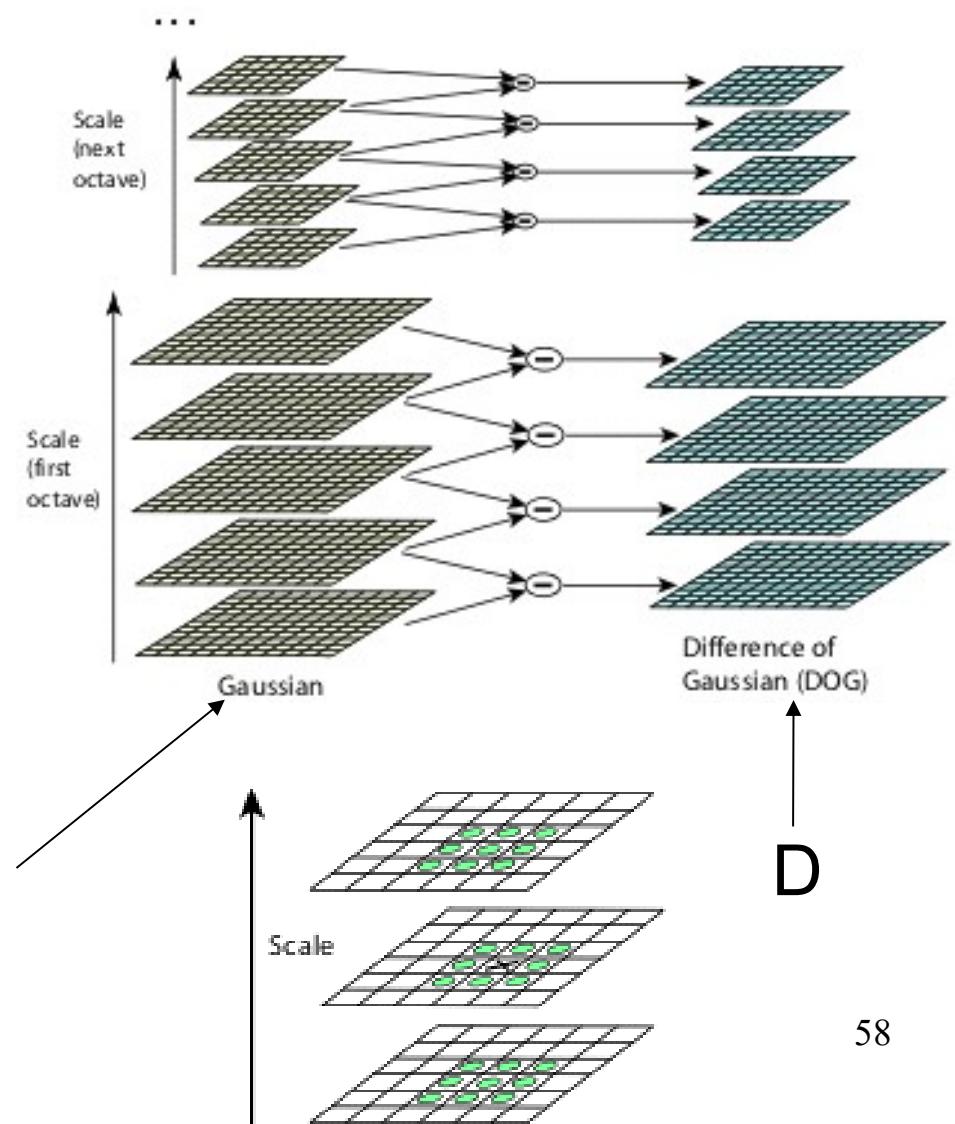
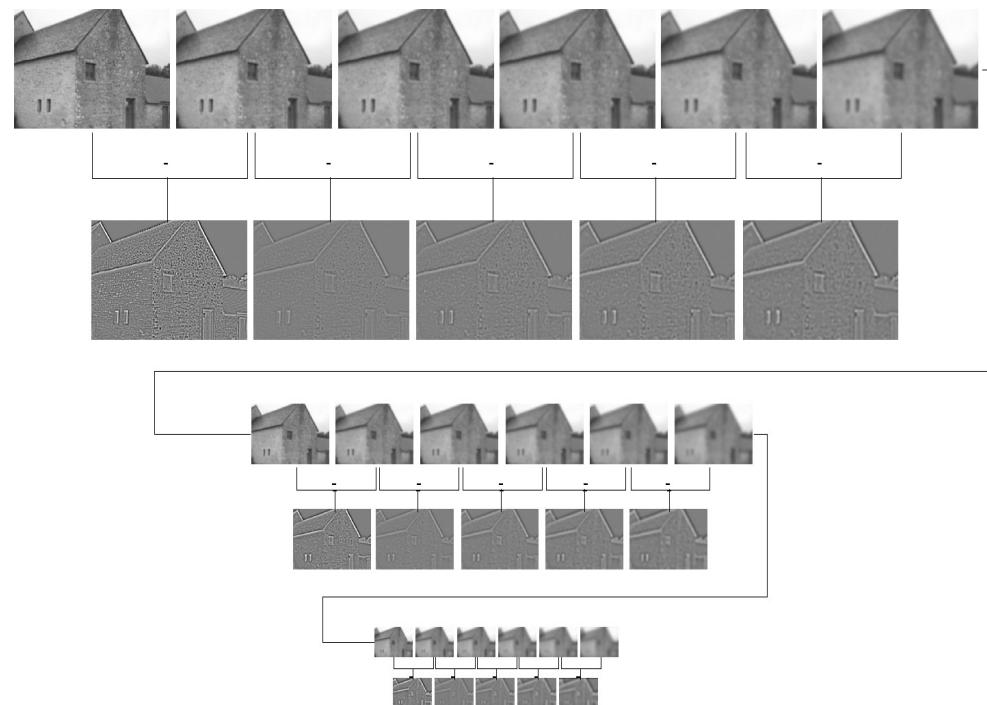
(pour sélection de l'échelle caractéristique)

$$|\text{LoG}(x, \sigma_D)| = \sigma_D^2 \cdot |L_{xx}(x, \sigma_D) + L_{yy}(x, \sigma_D)|$$

Détection des points d'intérêt

- SIFT (et le *DoG*)

$$D(x, y, \sigma) = L_{k\sigma_t}(x, y) - L_{\sigma_t}(x, y) = ((G_{k\sigma} - G_\sigma) * I)(x, y)$$



- SURF
- Autres variantes de SIFT ...

Détection des points d'intérêt : Harris/Hessian affine

Les détecteurs précédents sont notamment invariants aux variations d'éclairements, aux variations d'échelle et aux rotations (ainsi que dans une certaine mesure aux petites déformations)

mais certaines détecteurs sont invariants aux déformations affines :

- **Harris-affine**

$$R(x, y, \Sigma_D, \Sigma_I) = \det(\Sigma_D) \cdot G_{\Sigma_I} * ((\nabla L)(x, \Sigma_D) \cdot {}^t(\nabla L)(x, \Sigma_D))$$

Cas isotrope : cf Harris-Laplace

$$\Sigma_I = \begin{bmatrix} \sigma_I^2 & 0 \\ 0 & \sigma_I^2 \end{bmatrix} \quad \Sigma_D = \begin{bmatrix} \sigma_D^2 & 0 \\ 0 & \sigma_D^2 \end{bmatrix}$$

- **Hessian-affine**

invariants aux déformations affines

Appariement – mesures invariantes

Méthodes d'appariement – mesures invariantes

Objectif :

Retrouver pour un point extrait d'une première image son homologue parmi les points d'intérêt extraits d'une autre image.

Nécessité de trouver un critère permettant cette tâche,
c'est-à-dire déterminer à la fois :

- une **caractéristique** associée à chacun des points
 - i.e. un **descripteur** du comportement de l'image au voisinage du point
- une **mesure** permettant de comparer ces descripteurs

Qualités d'une méthode d'appariement

- **Localité** du descripteur :
une caractéristique locale sera plus robuste aux occlusions
- **Invariance** à la translation, à la rotation, au changement d'échelle, aux déformations...
- **Robustesse** au bruit, aux conditions d'acquisition de l'image, à la compression, ...
- **Discriminante** :
permettant de retrouver le bon homologue parmi beaucoup de candidats
- **Efficacité** : calcul rapide (important pour les applications en temps réel)

Coefficient de corrélation

$$\frac{\sum_{u,v} (I_1(x_1+u, y_1+v) - \bar{I}_1) \cdot (I_2(x_2+u, y_2+v) - \bar{I}_2)}{\sqrt{\sum_{u,v} (I_1(x_1+u, y_1+v) - \bar{I}_1)^2} \cdot \sqrt{\sum_{u,v} (I_2(x_2+u, y_2+v) - \bar{I}_2)^2}}$$

Problème en cas de :

- Rotations
- Changements d'échelle



Utilisation d'un prédicteur

→ le plus souvent possible en aérien

→ permet de savoir où chercher et de rééchantillonner localement les images pour les rendre plus ressemblantes
(ou au moins d'appliquer une rotation à l'image en cas de besoin)

Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal
- Dans un certain voisinage de la position prédite du point homologue dans l'image 2, homologue = pixel pour lequel le coefficient de corrélation est maximal

La zone de recherche peut être 1D ou 2D

Elle est échantillonnée selon un pas dk

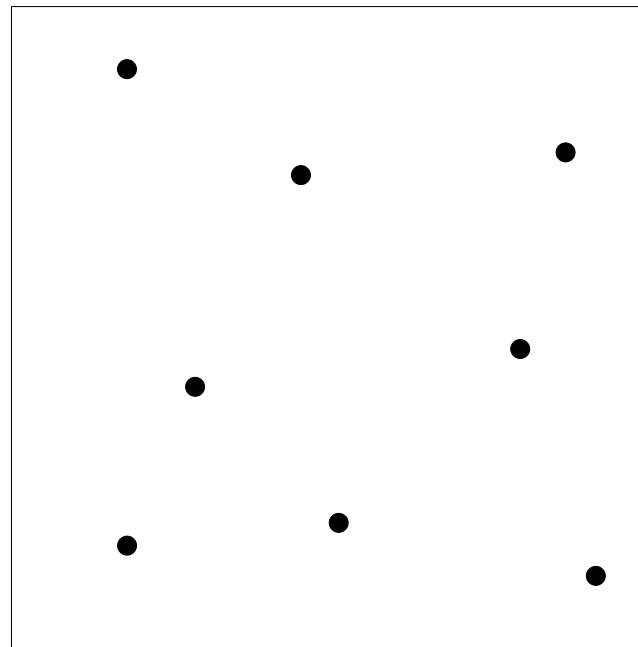
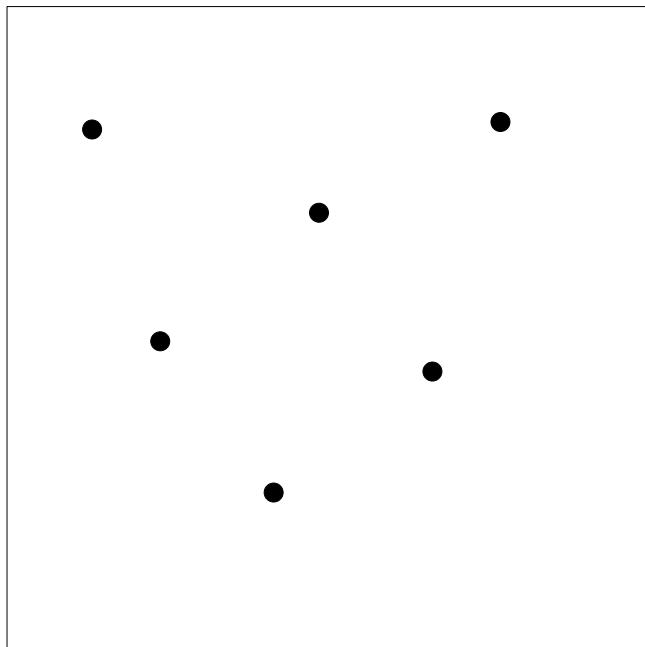
Pour chaque point de la zone de recherche dans l'image, on calcule un score de corrélation

On obtient une courbe ou une surface de corrélation

Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

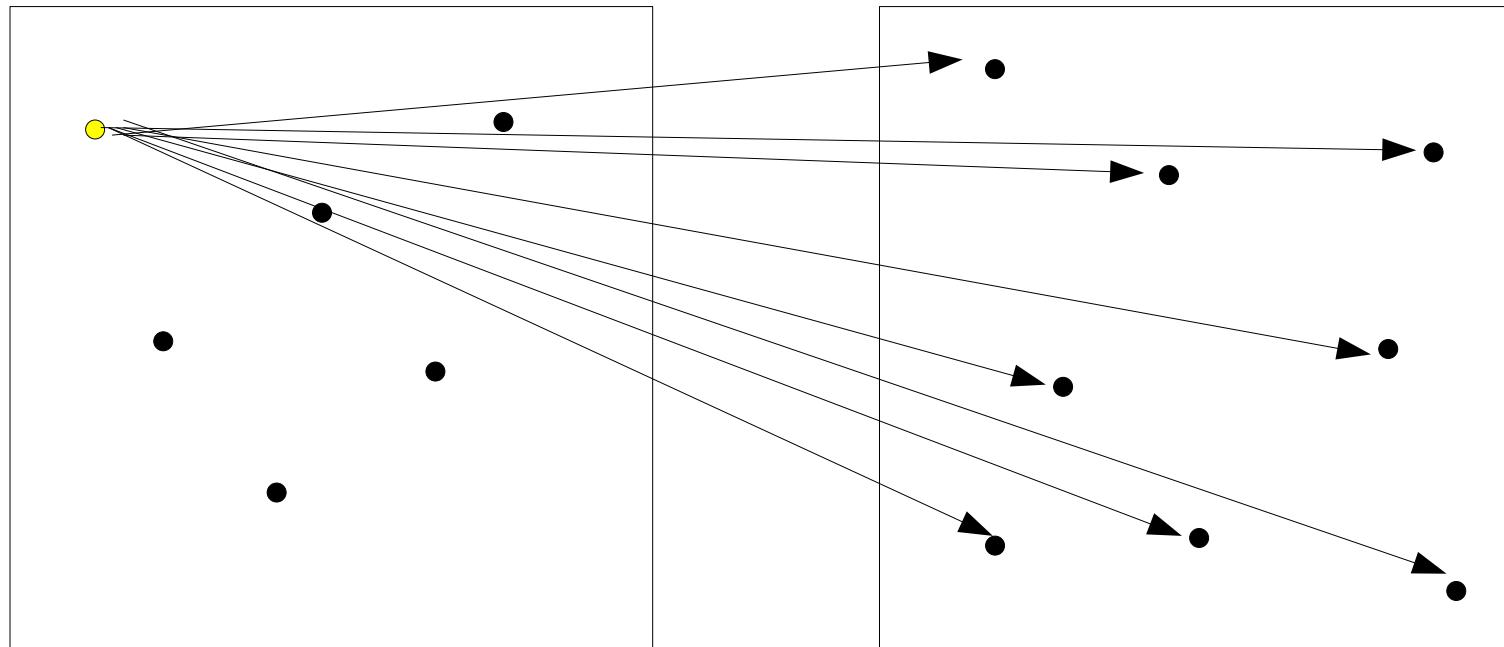
- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal



Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

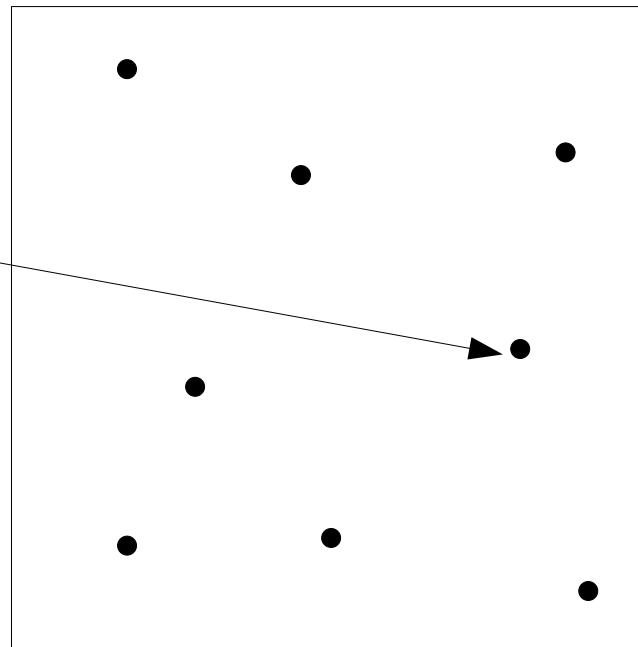
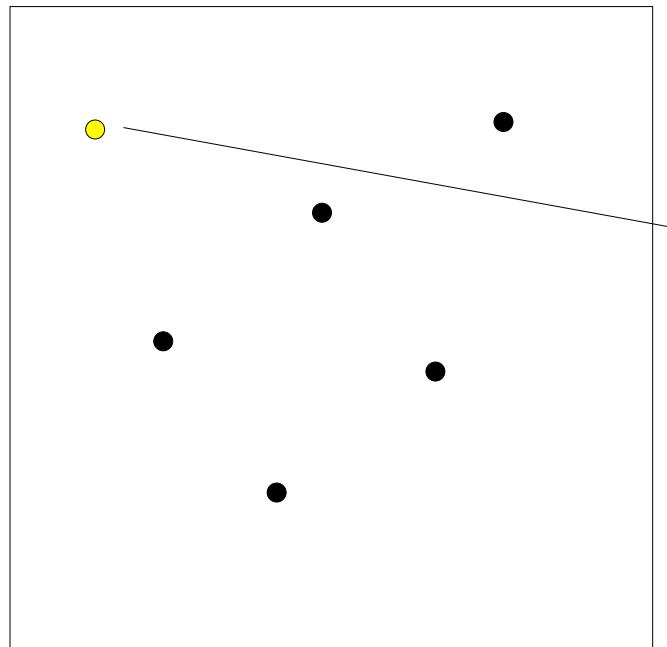
- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal



Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

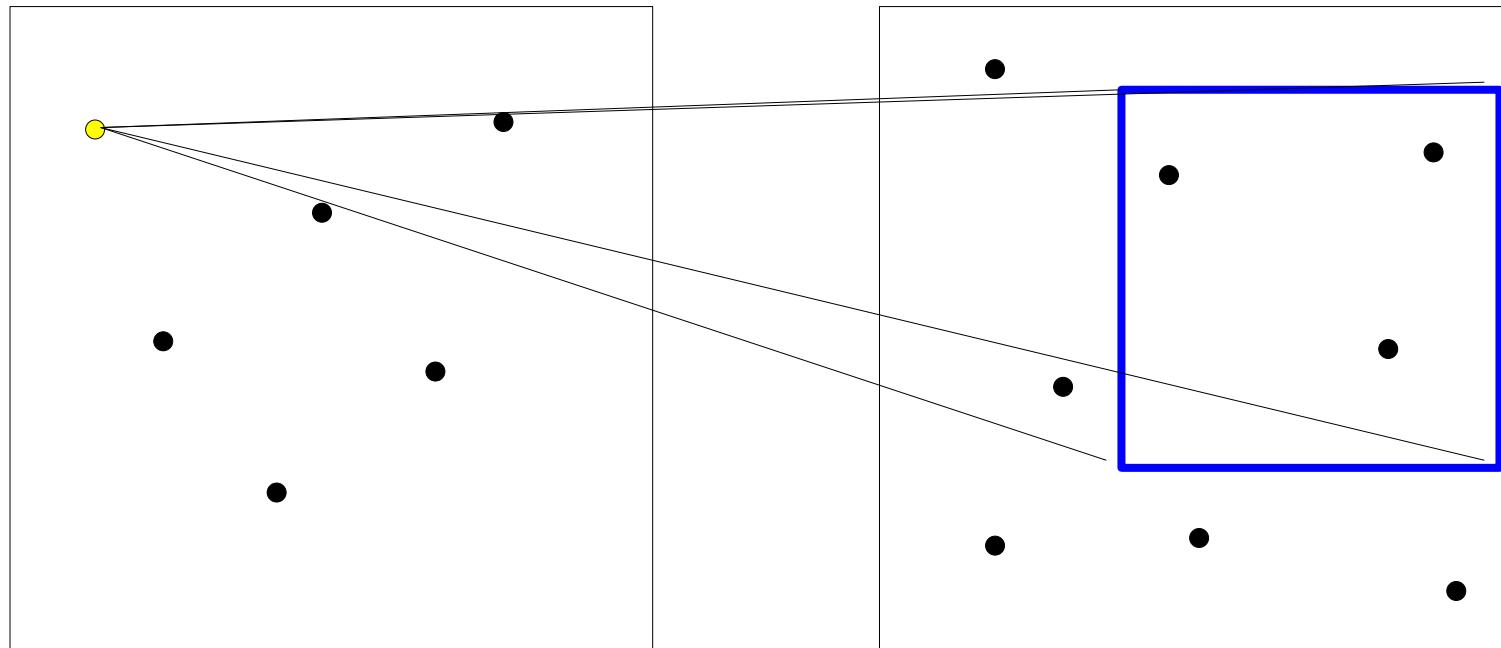
- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal



Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal

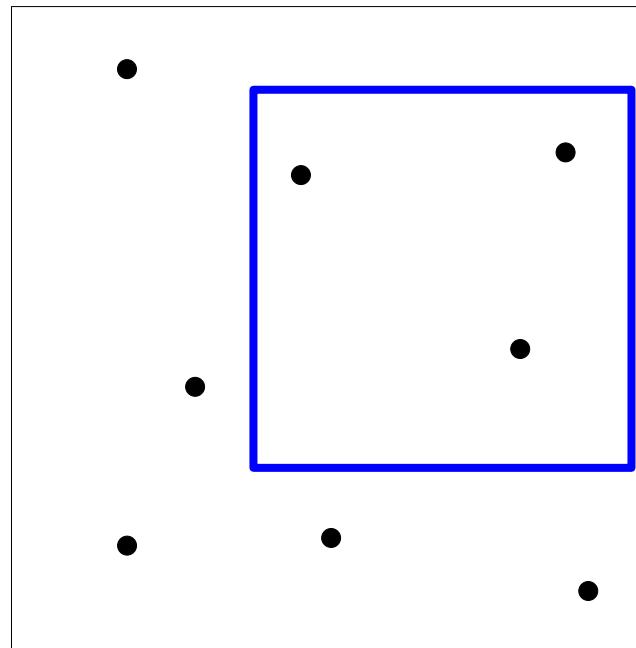
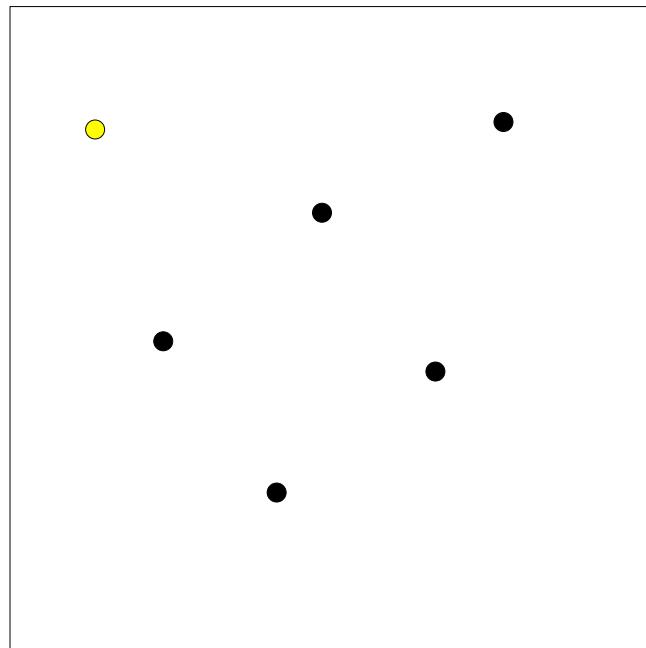


Utilisation possible d'un prédicteur pour limiter la zone de recherche

Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal

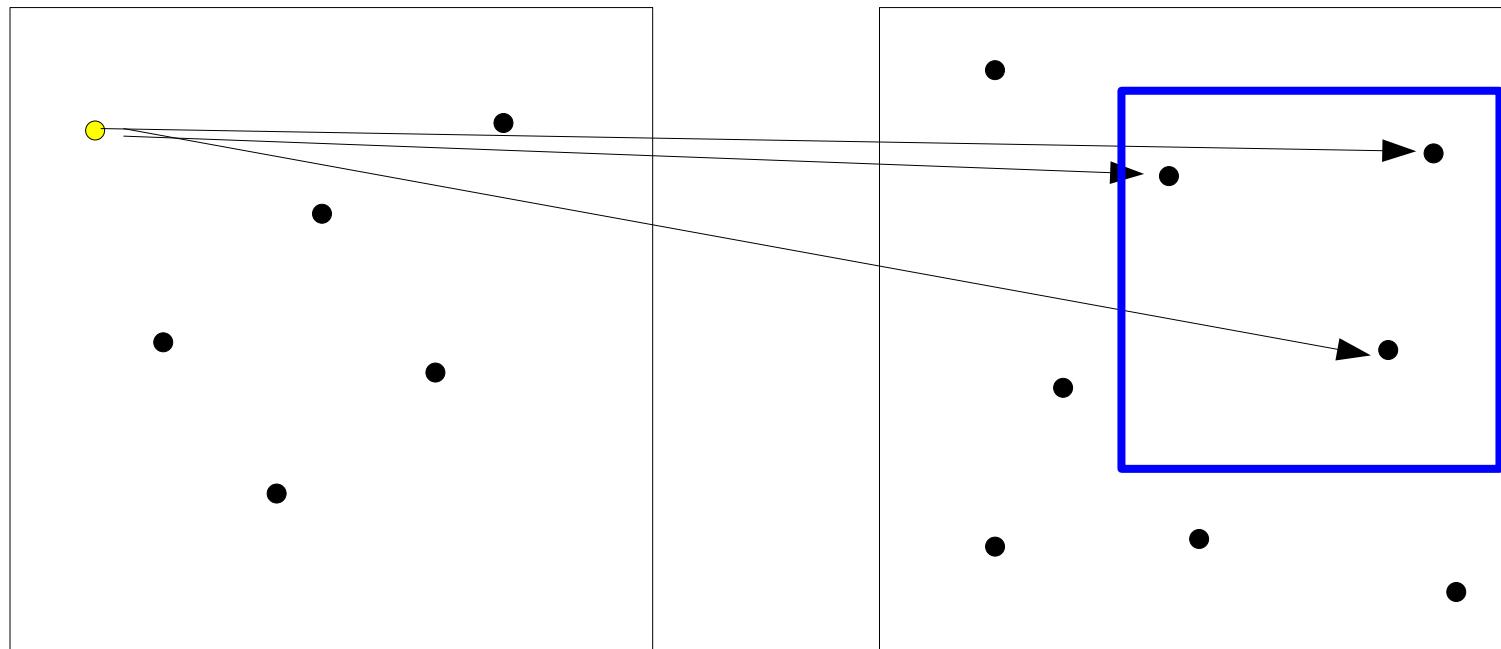


Utilisation possible d'un prédicteur pour limiter la zone de recherche

Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal

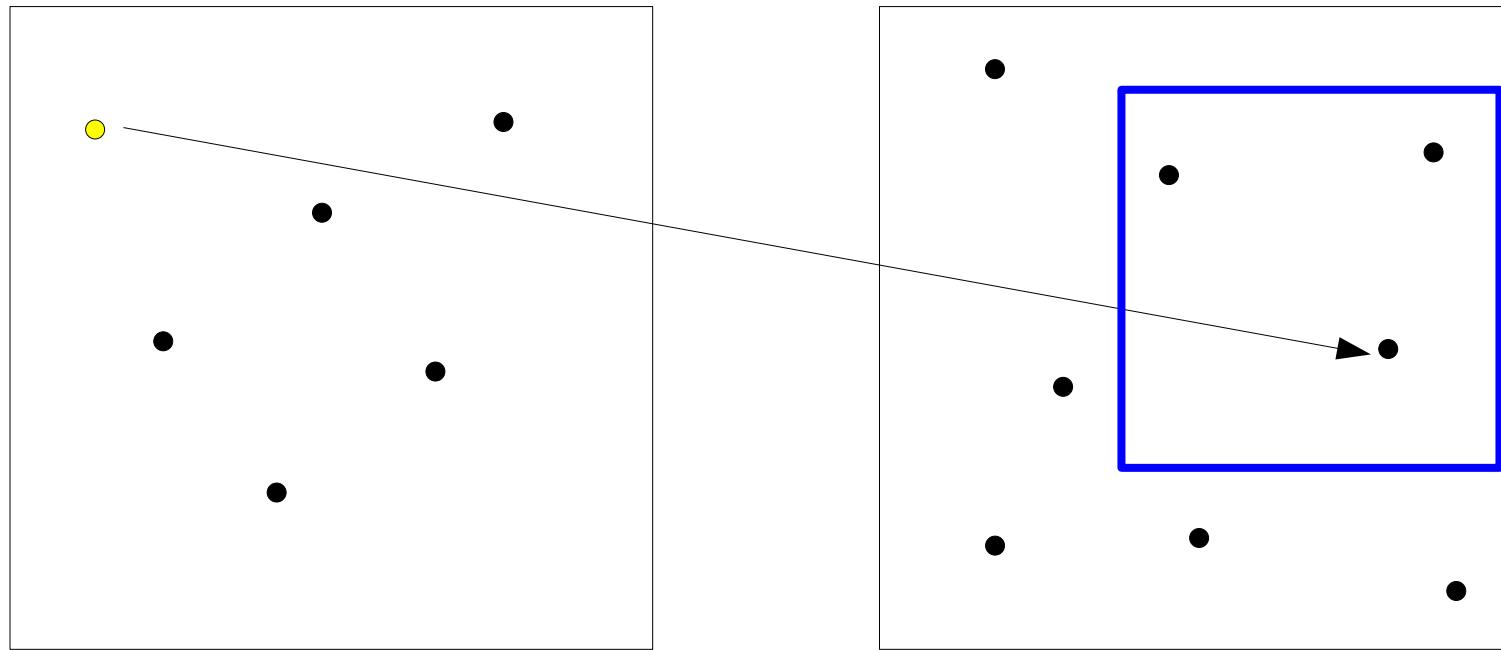


Utilisation possible d'un prédicteur pour limiter la zone de recherche

Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal



Utilisation possible d'un prédicteur pour limiter la zone de recherche

Mesure automatique de points de liaison : corrélation et prédicteur

2 approches de recherche de l'homologue d'un point de l'image 1 dans l'image 2 :

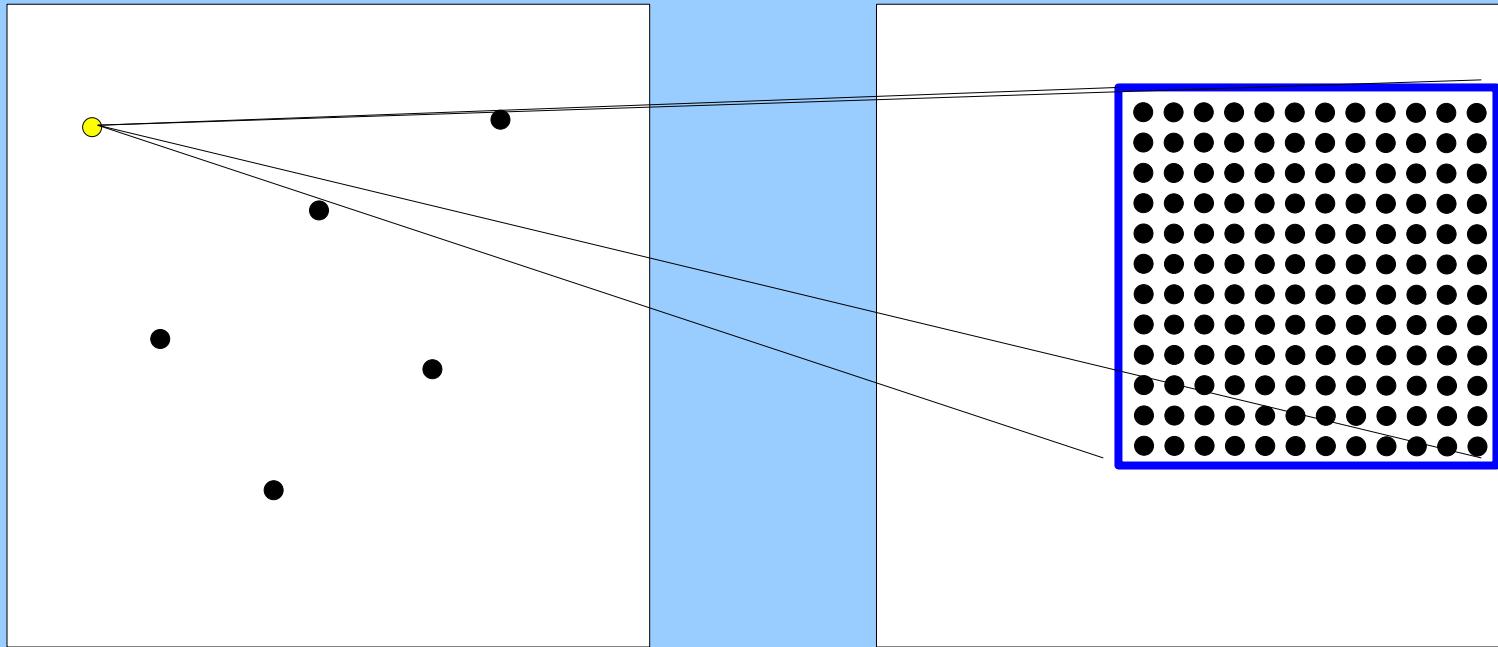
- Parmi les points extraits de l'image 2 , homologue = celui pour lequel le coefficient de corrélation est maximal
- Dans un certain voisinage de la position prédictée du point homologue dans l'image 2, homologue = pixel pour lequel le coefficient de corrélation est maximal

La zone de recherche peut être 1D ou 2D

Elle est échantillonnée selon un pas dk

Pour chaque point de la zone de recherche dans l'image, on calcule un score de corrélation

On obtient une courbe ou une surface de corrélation



- Dans un certain voisinage de la position prédite du point homologue dans l'image 2, homologue = pixel pour lequel le coefficient de corrélation est maximal

La zone de recherche peut être 1D ou 2D

Elle est échantillonnée selon un pas d_k

Pour chaque point de la zone de recherche dans l'image, on calcule un score de corrélation

On obtient une courbe ou une surface de corrélation

Mesure automatique de points de liaison : corrélation et prédicteur

- Dans un certain voisinage de la position prédite du point homologue dans l'image 2, homologue = pixel pour lequel le coefficient de corrélation est maximal

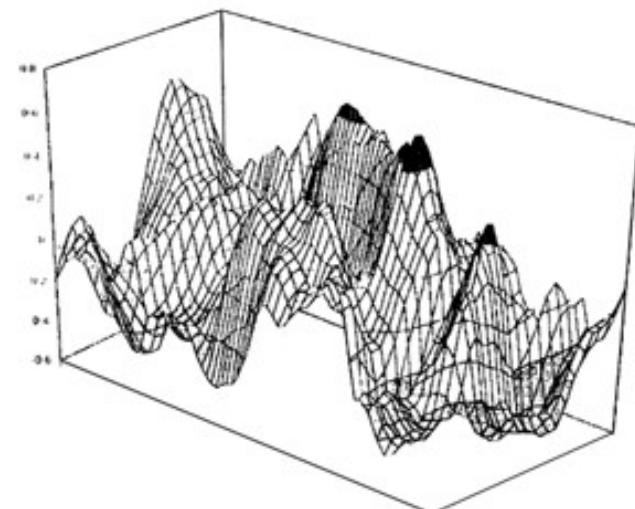
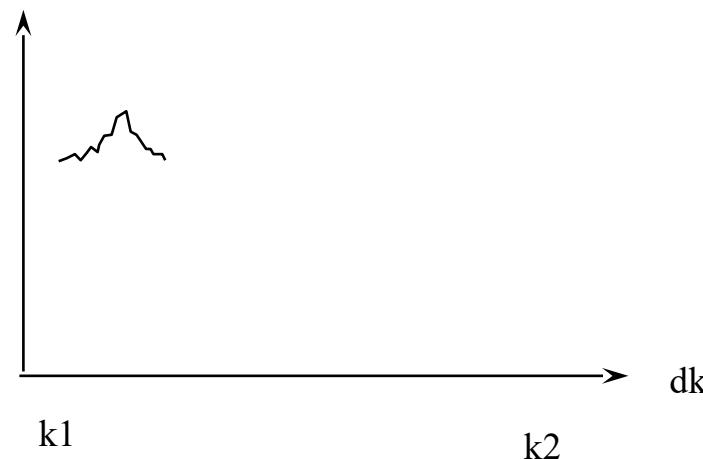
La zone de recherche peut être 1D ou 2D

Elle est échantillonnée selon un pas dk

Pour chaque point de la zone de recherche dans l'image, on calcule un score de corrélation

On obtient une courbe ou une surface de corrélation

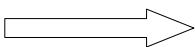
Score de corrélation



Mesure automatique de points de liaison : corrélation et prédicteur

Détermination des points homologues : limitation de la zone de recherche

→ Utilisation d'un prédicteur



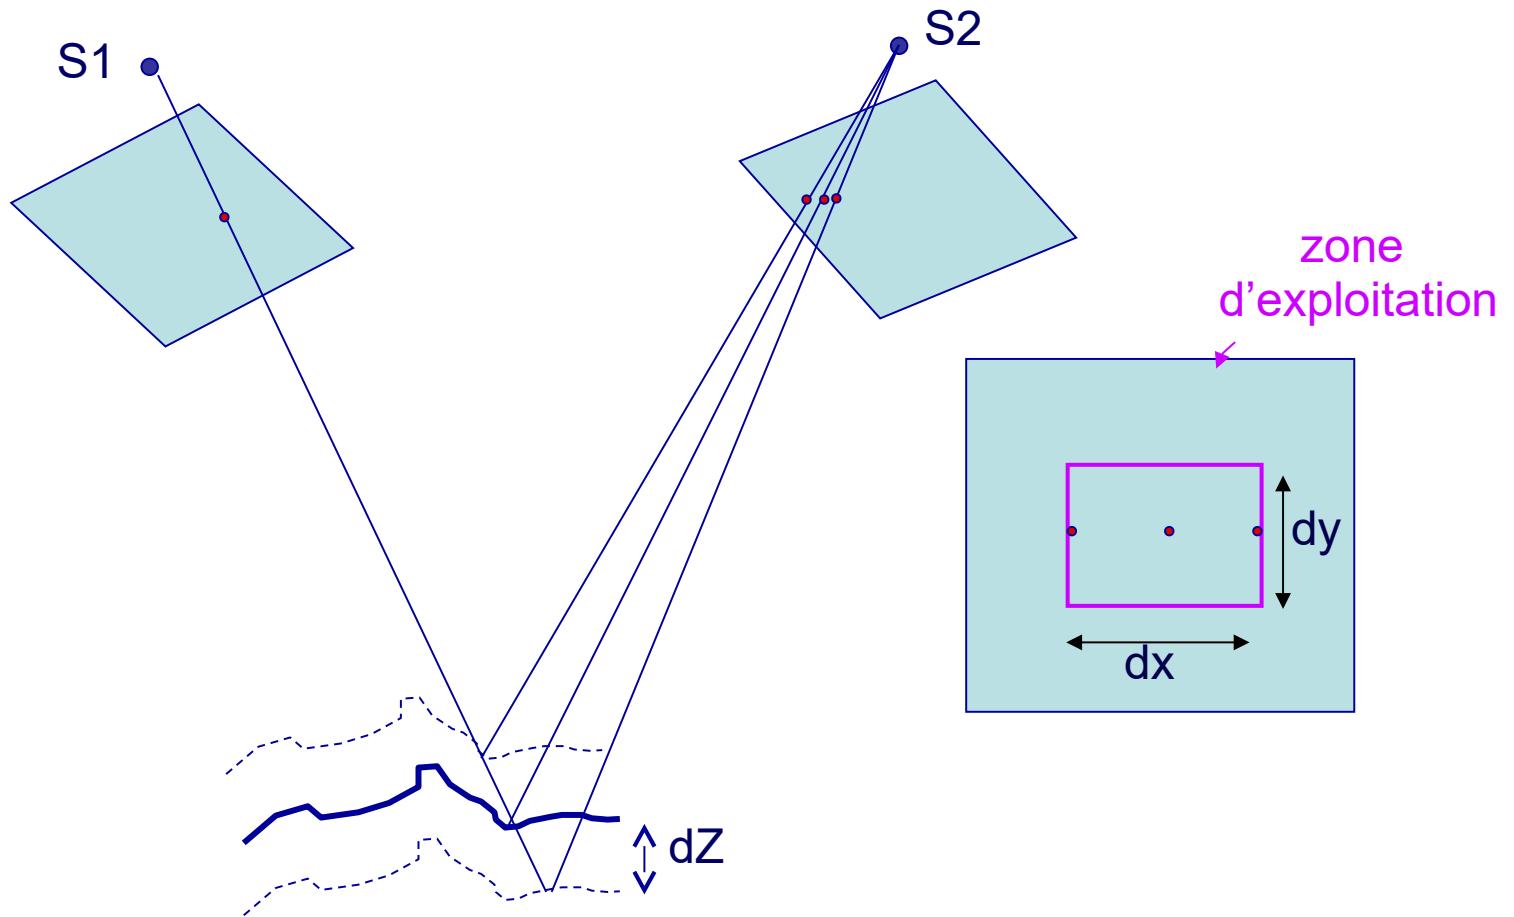
Nécessite :

- un géoréférencement approché des clichés
- un MNT

- projection des points d'intérêt de l'image 1 sur un MNT en utilisant une photogrammétrie approchée (prédicteur)
- projection de ces points « terrain » dans les images voisines en utilisant la photogrammétrie approchée
- corrélation automatique au voisinage de ces points

Mesure automatique de points de liaison : corrélation et prédicteur

Utilisation d'un prédicteur



MNT

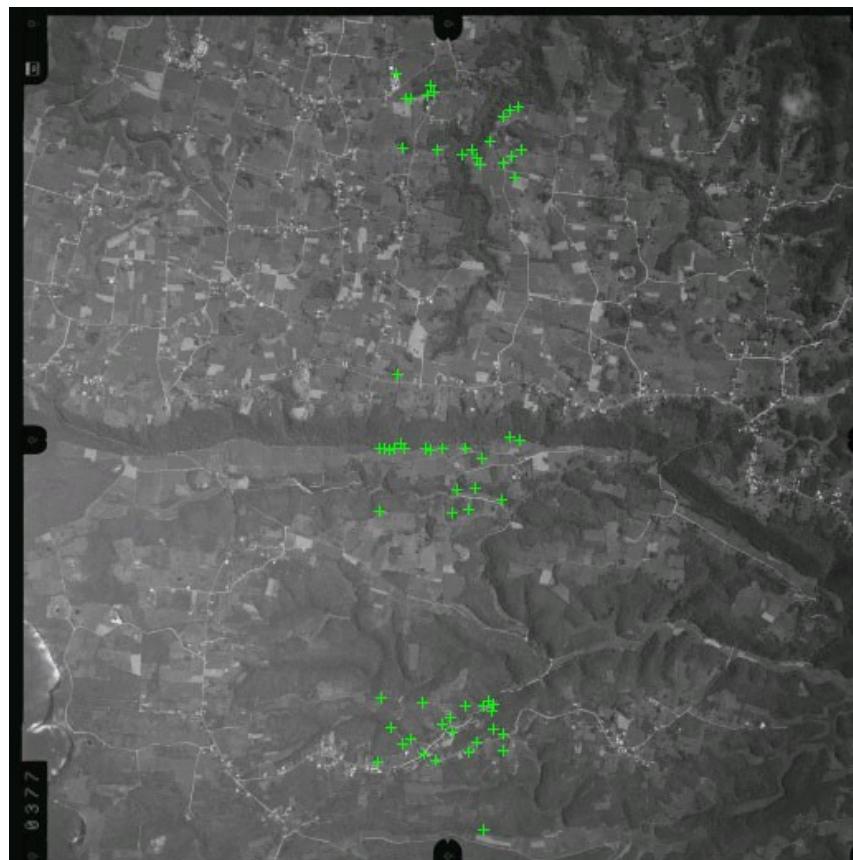
- dX est lié à l'imprécision dZ du MNT
- dY est lié à l'imprécision de l'aérotriangulation (donné par la paramètre « taille de la zone d'exploitation »)

Mesure automatique de points de liaison : corrélation et prédicteur

Approche pyramidale :

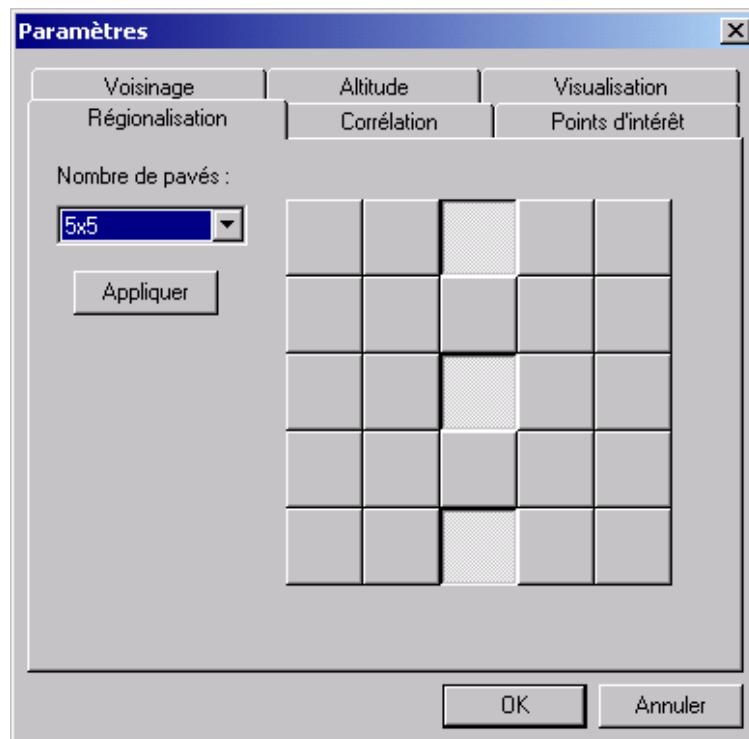
Le prédicteur initial provient généralement des données GPS (+ éventuellement INS)

Affinage du prédicteur en travaillant sur des images sous-échantillonnées

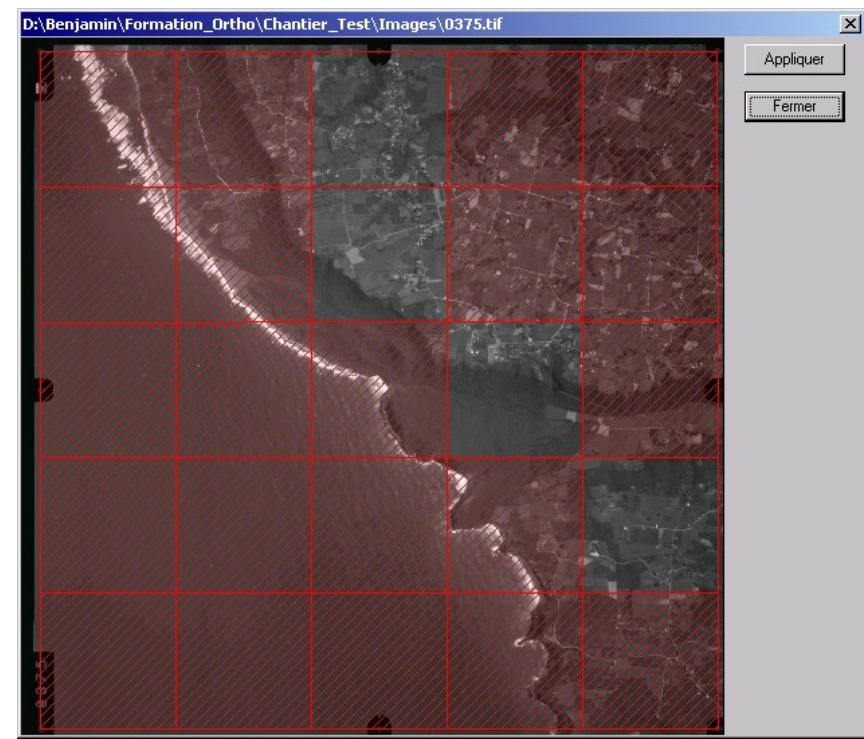


Mesure automatique de points de liaison : corrélation et prédicteur

Limitation des points d'intérêt dans certaines zones de l'image

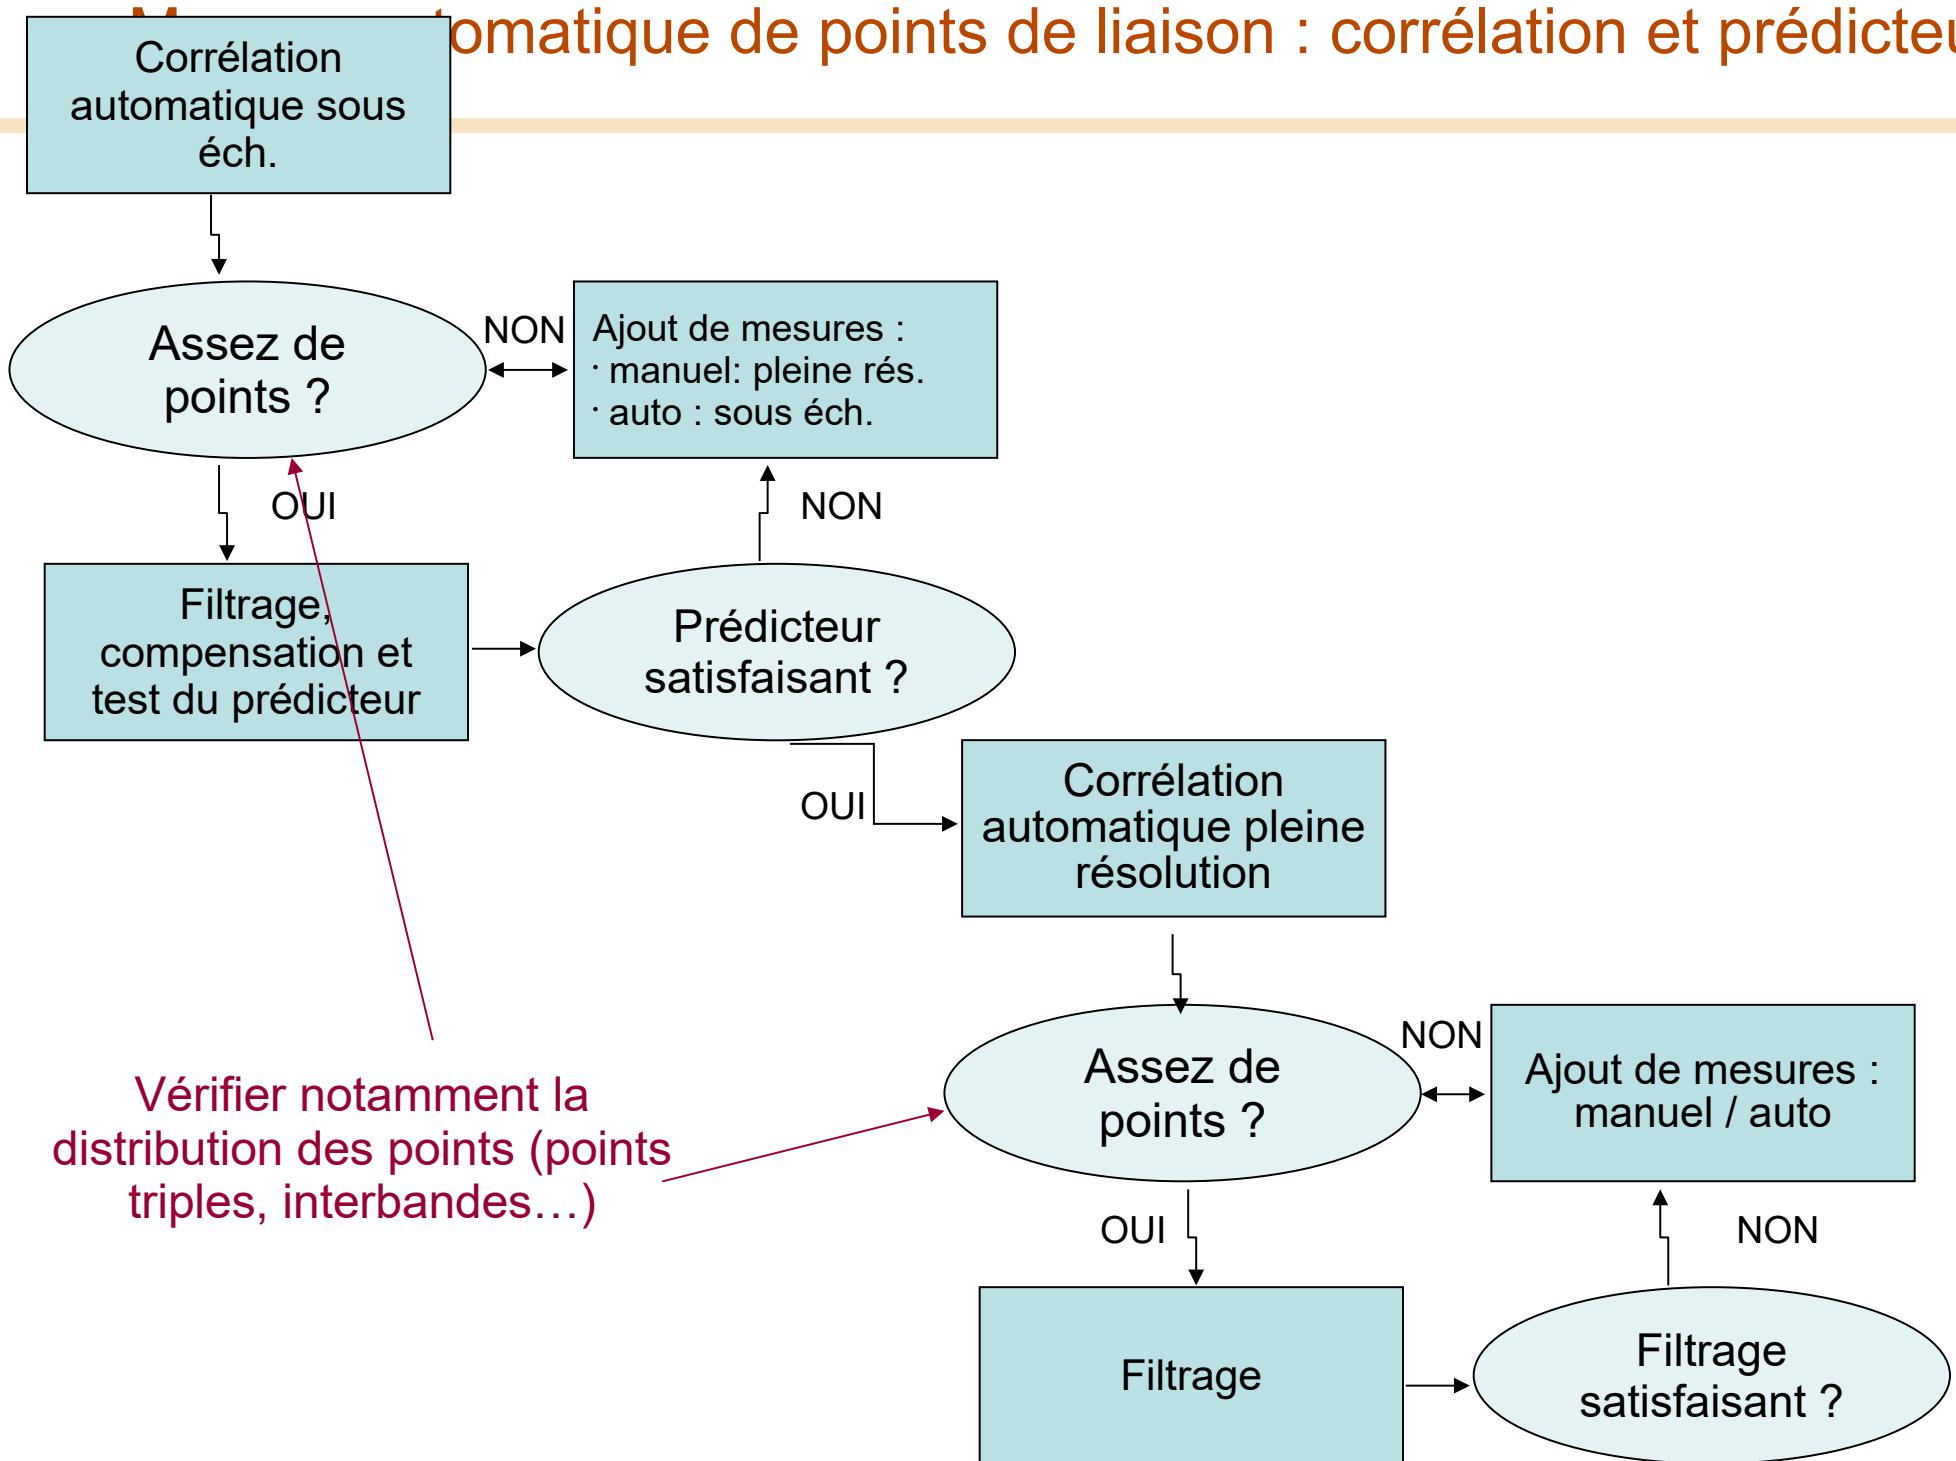


Configuration par défaut



Gestion de masques individuels

Automatique de points de liaison : corrélation et prédicteur



Coefficient de corrélation

$$\frac{\sum_{u,v} (I_1(x_1+u, y_1+v) - \bar{I}_1) \cdot (I_2(x_2+u, y_2+v) - \bar{I}_2)}{\sqrt{\sum_{u,v} (I_1(x_1+u, y_1+v) - \bar{I}_1)^2} \cdot \sqrt{\sum_{u,v} (I_2(x_2+u, y_2+v) - \bar{I}_2)^2}}$$

Problème en cas de :

- Rotations
- Changements d'échelle



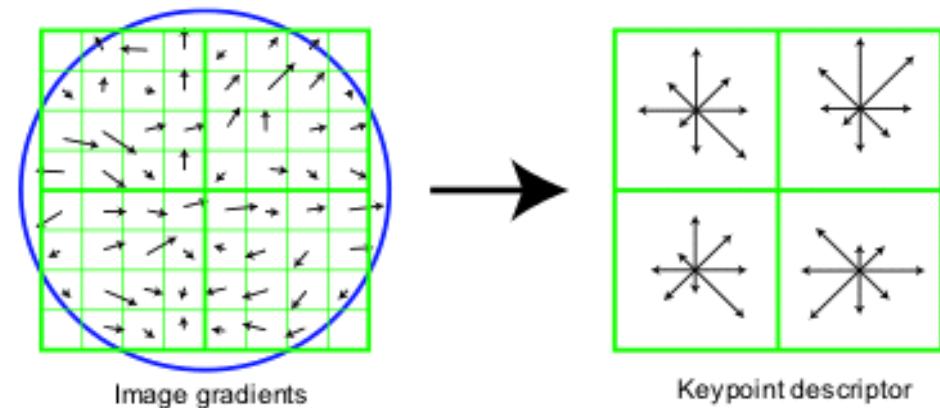
Utilisation d'autres mesures invariantes

Descripteurs invariants

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- **SIFT (Scale Invariant Feature Transform)**
et ses variantes (SIFT-PCA, ...)

- **SURF**

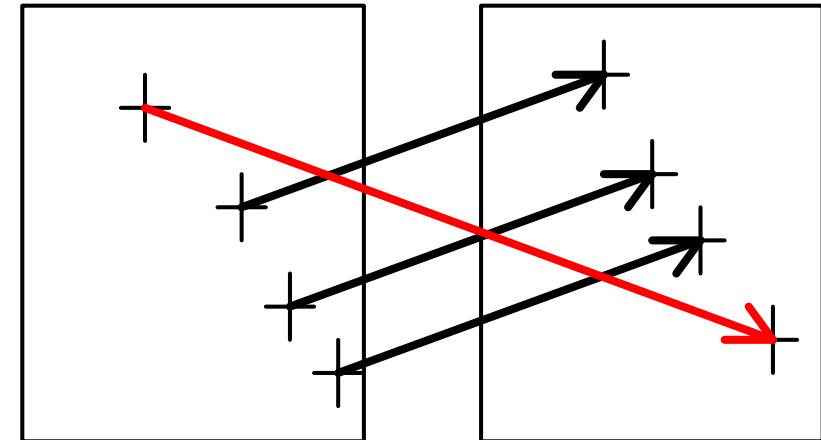


Recherche du plus proche voisin dans l'espace des descripteurs

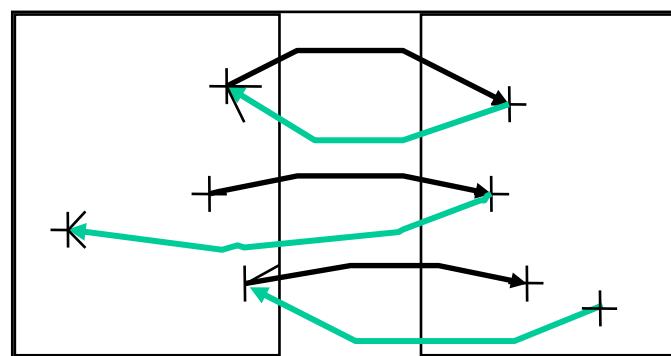
Appariement - filtrage

Filtrage des mises en correspondance erronées

- Filtrage par considération du voisinage



- Appariement croisé



- Filtrage “photogrammétrique”
 - ◆ Contrainte épipolaire en inter-bandes
 - ◆ Formules d'image

Appariement : quelques exemples

Appariement : exemples



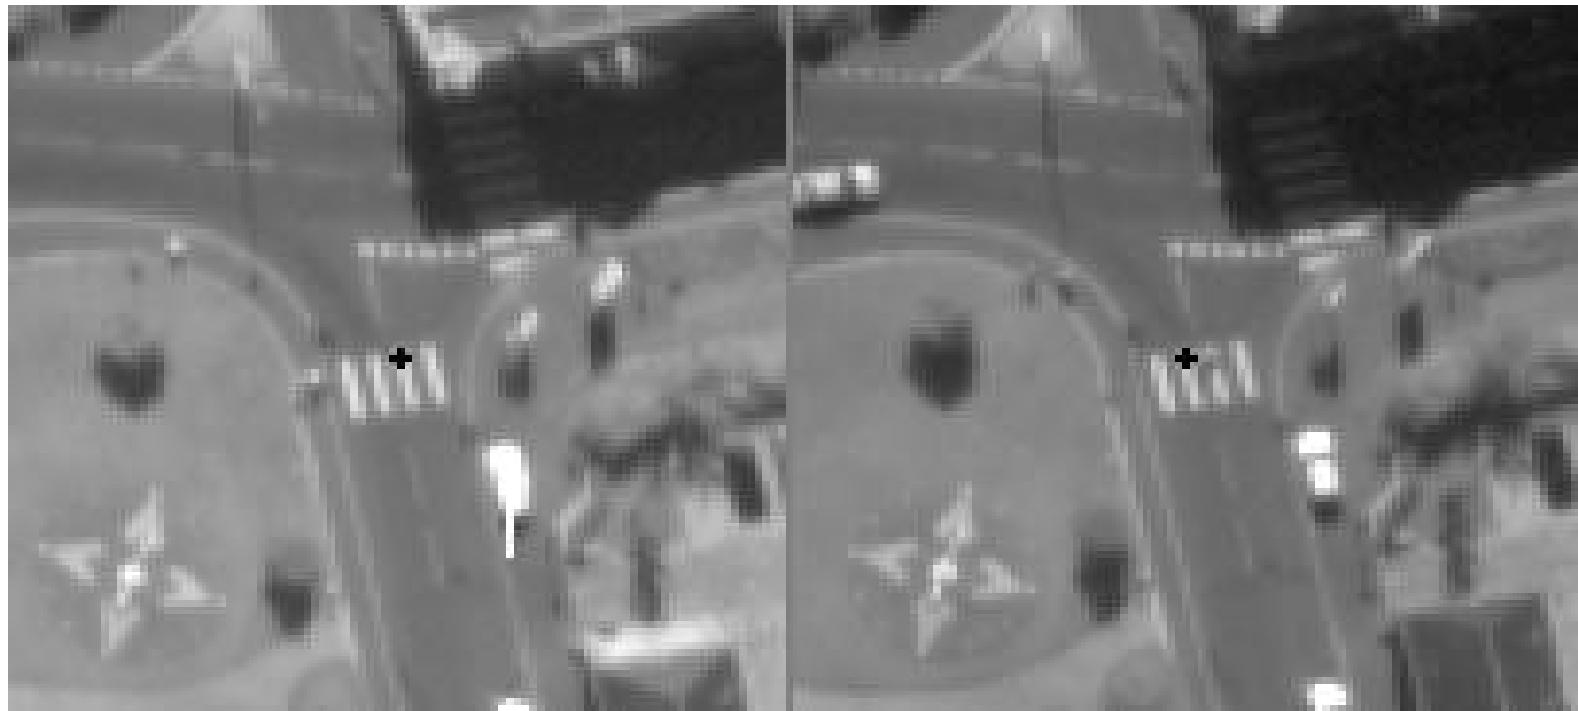
Appariement : exemples

Véhicule en mouvement



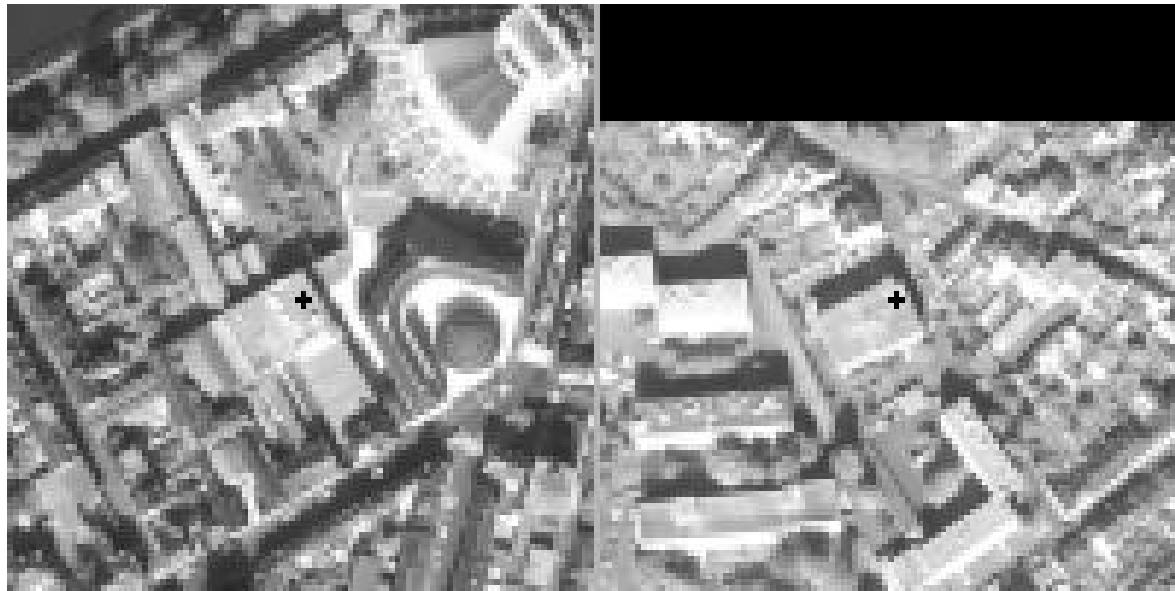
Appariement : exemples

Faux appariement : motifs répétitifs



Appariement : exemples

Faux appariement : zones ressemblantes (localement)



Appariement : exemples

Problème des ombres



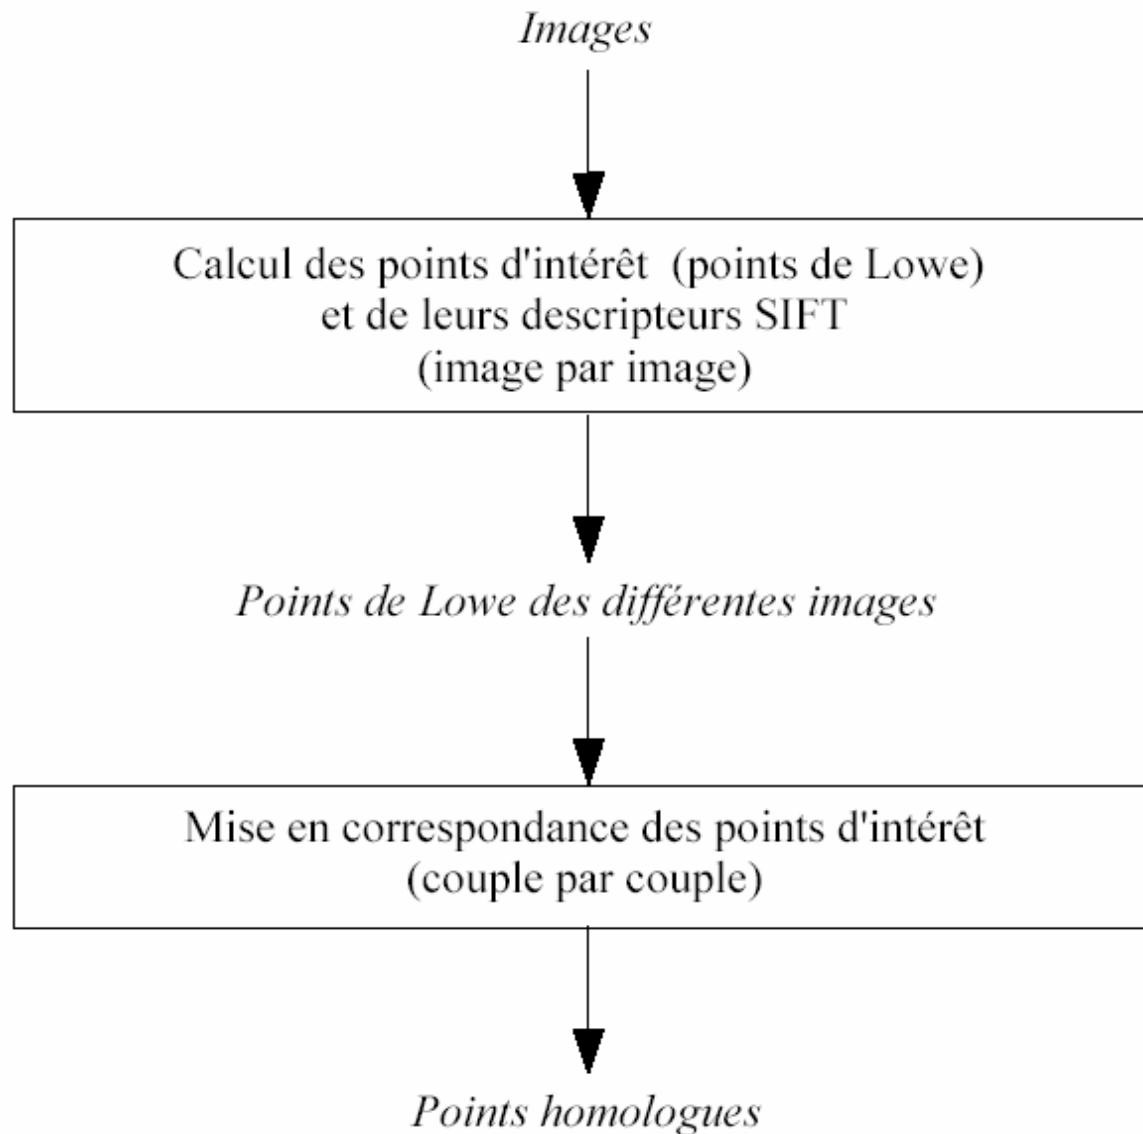
SIFT (Scale Invariant Feature Transform)

Référence :

<http://www.cs.ubc.ca/~lowe/keypoints>

David. G. Lowe Distinctive Image Features from Scale-Invariant Keypoints.
International Journal of Computer Vision. 2004.

SIFT : Scale Invariant Feature Transform



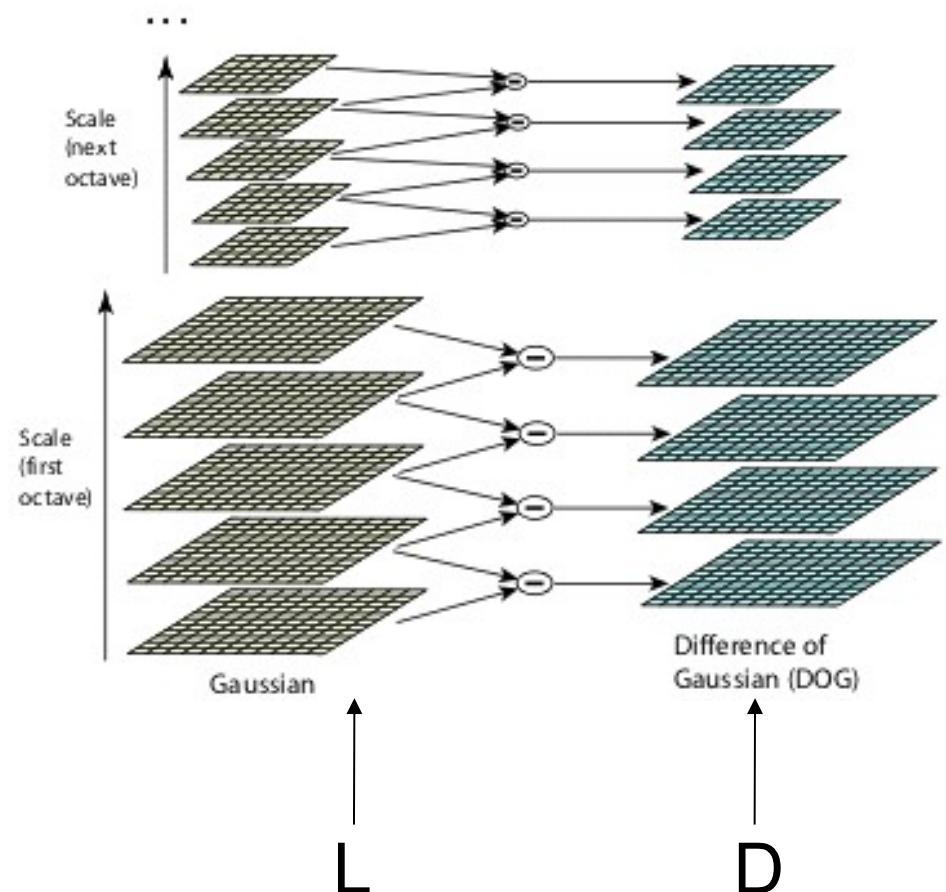
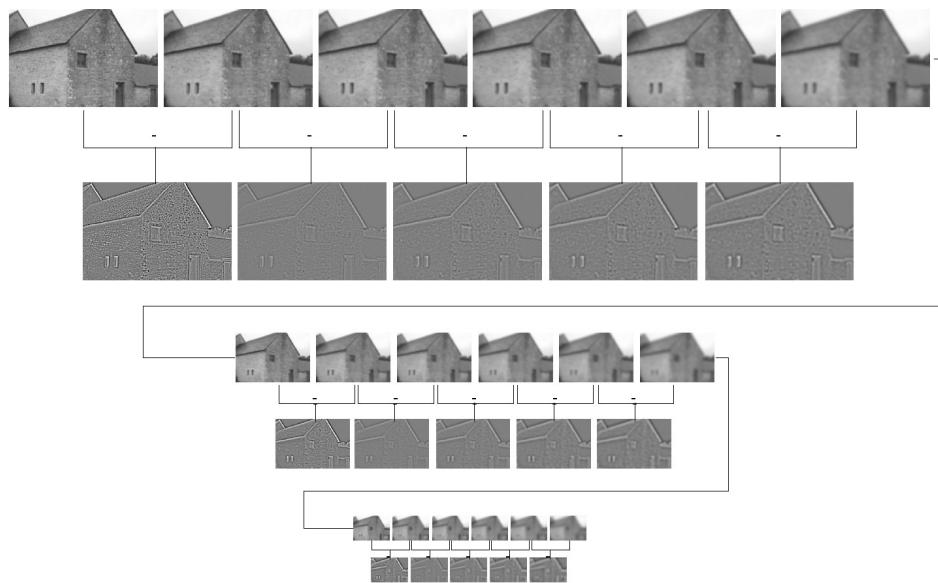
SIFT : Scale Invariant Feature Transform

Extraction des points de Lowe

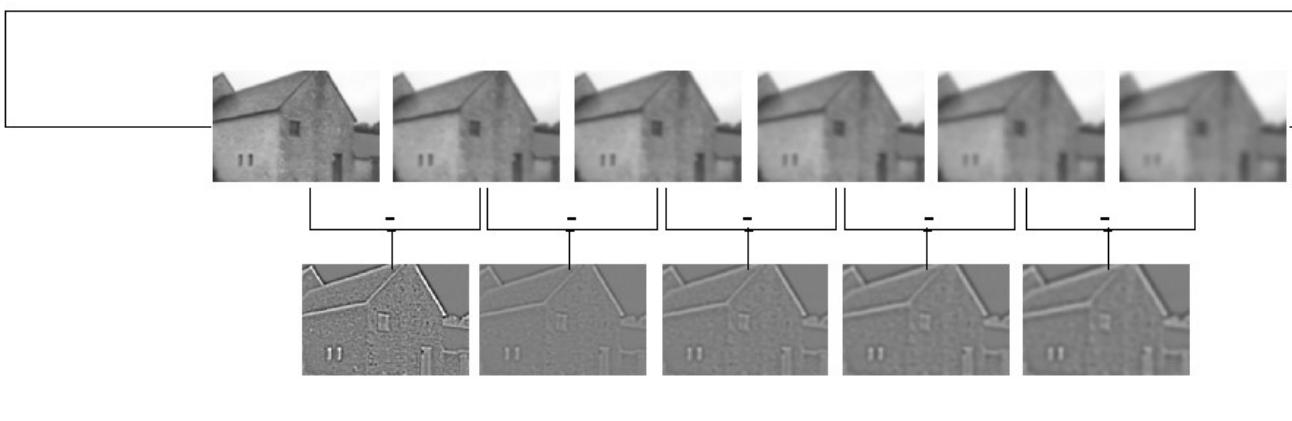
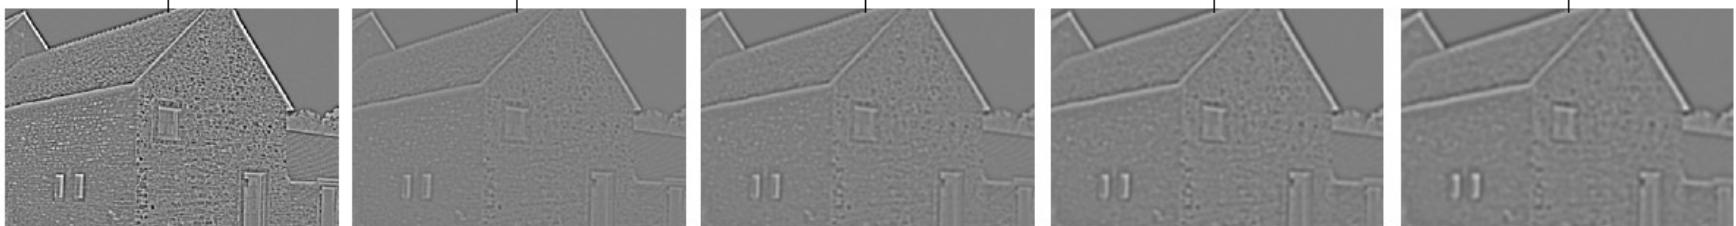
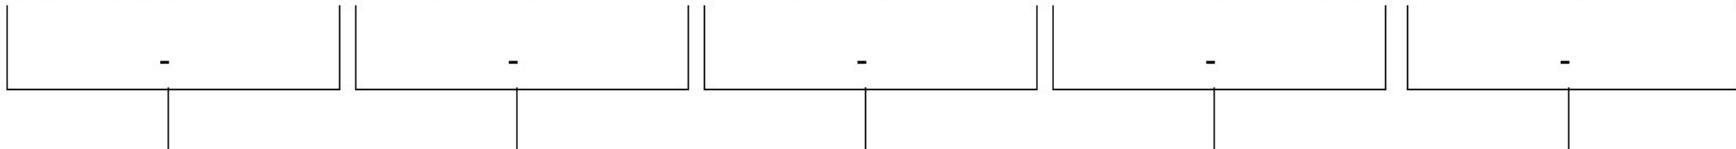
- Construction d'un espace d'échelles ("scale space")

$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y) \quad G_\sigma \text{ gaussienne de variance } \sigma$$

$$D(x, y, \sigma) = L(x, y, k \cdot \sigma) - L(x, y, \sigma) = ((G_{k \cdot \sigma} - G_\sigma) * I)(x, y)$$

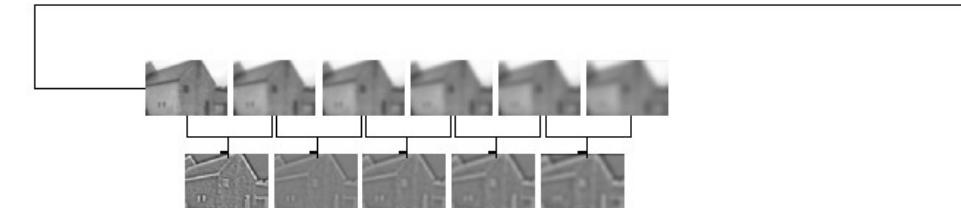


SIFT : Scale Invariant Feature Transform



L

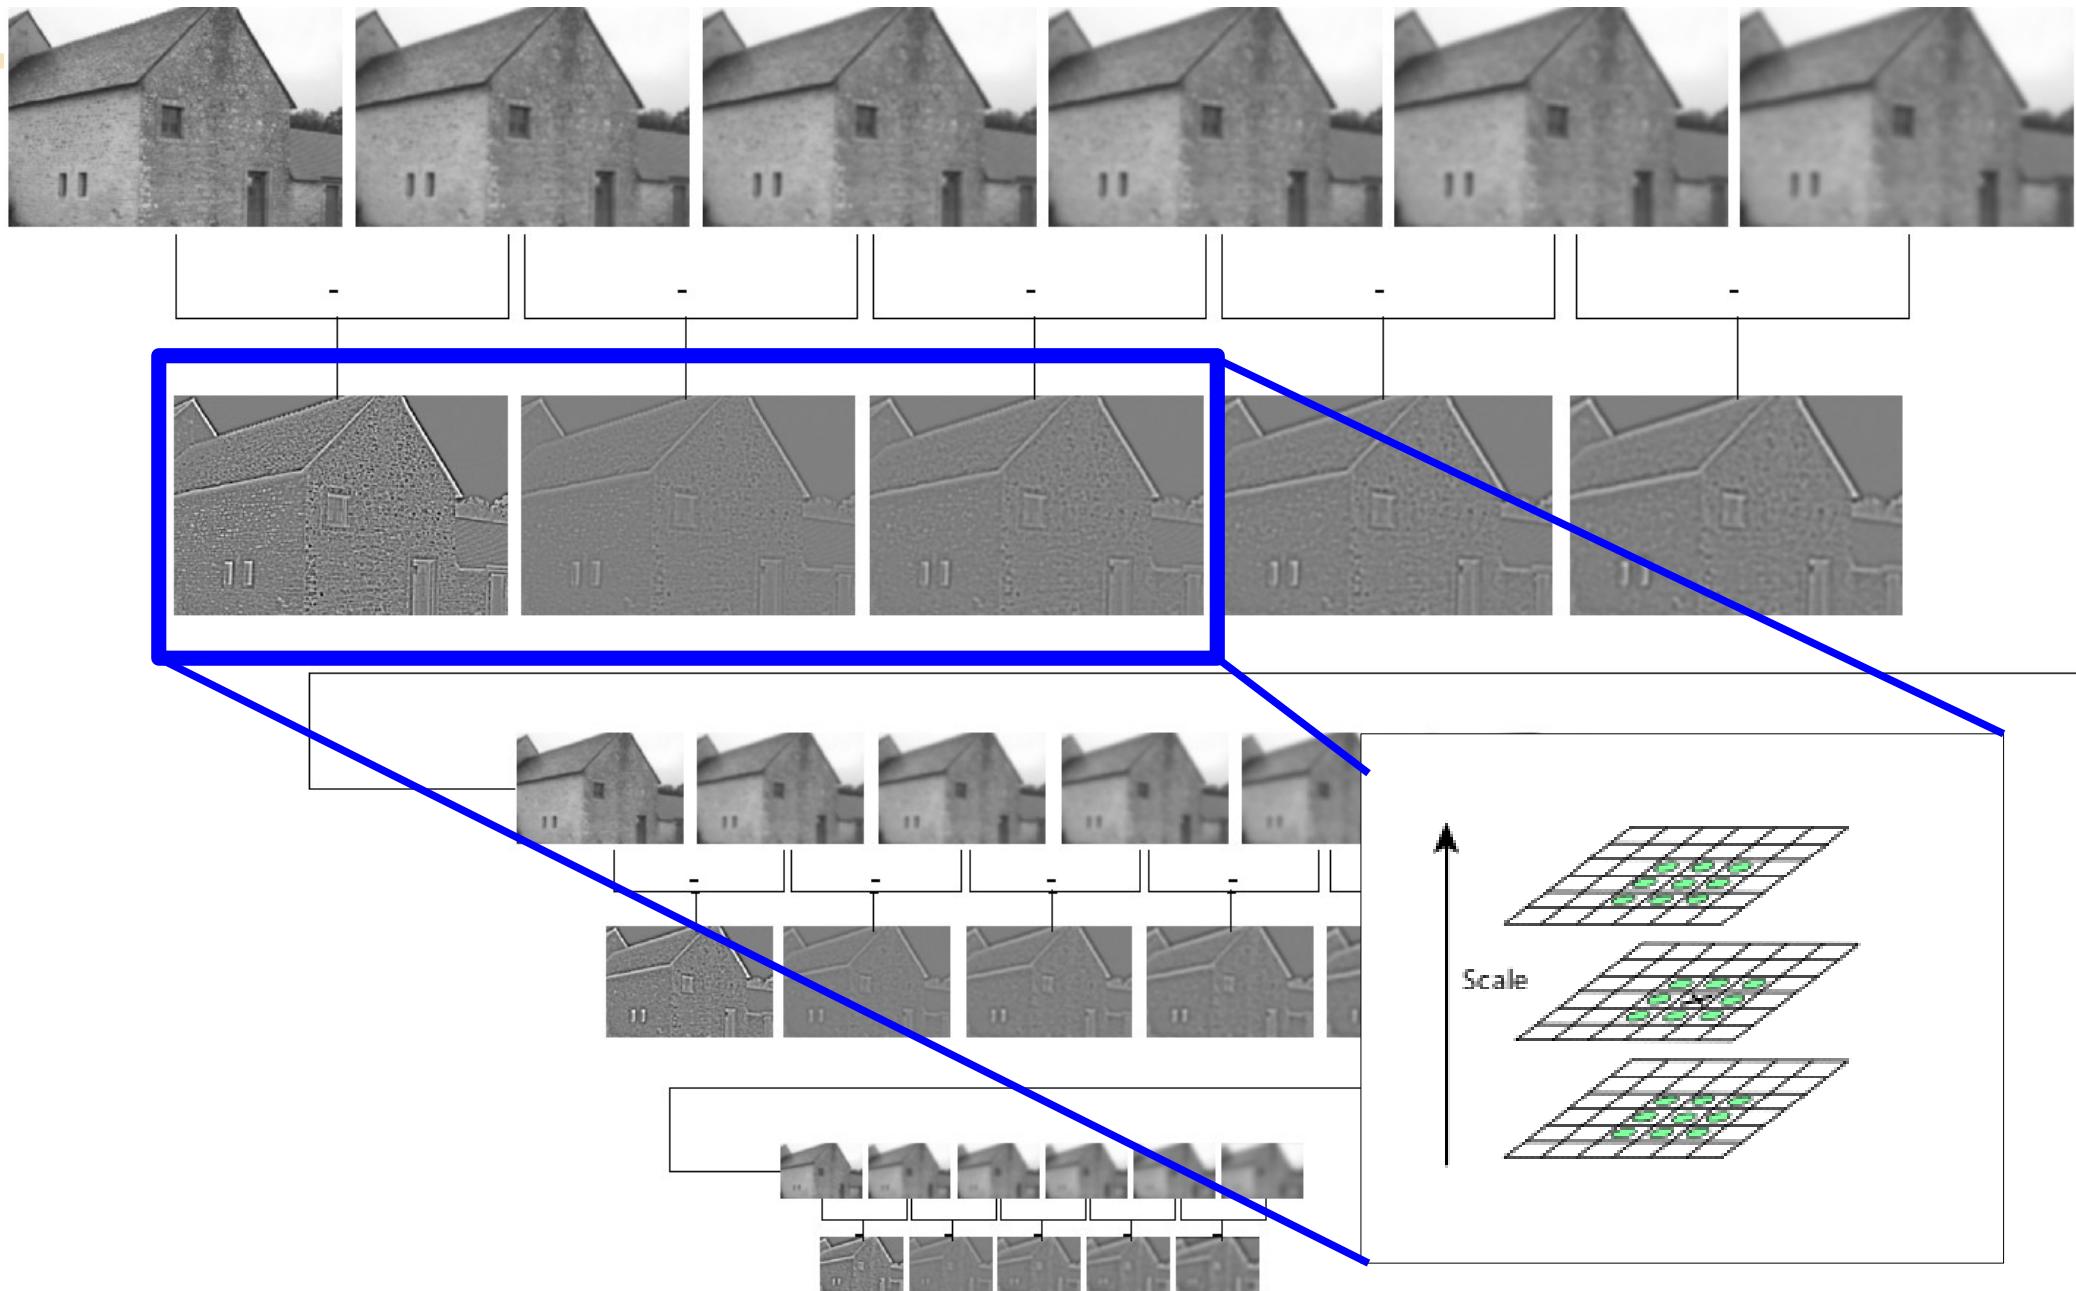
D



$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$

$$D(x, y, \sigma) = L(x, y, k \cdot \sigma) - L(x, y, \sigma) = ((G_{k \cdot \sigma} - G_\sigma) * I)(x, y)$$

SIFT : Scale Invariant Feature Transform



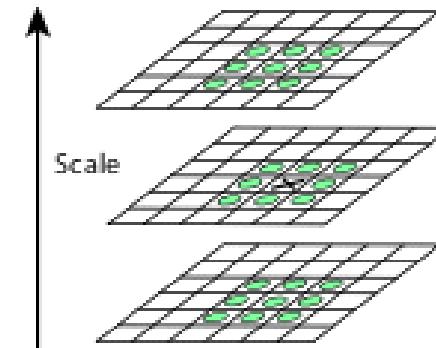
$$I(x, y, \sigma) = (L(\sigma))(x, y) = (G_\sigma * I)(x, y)$$

$$D(x, y, \sigma) = L(x, y, k \cdot \sigma) - L(x, y, \sigma) = ((G_{k \cdot \sigma} - G_\sigma) * I)(x, y)$$

SIFT : Scale Invariant Feature Transform

Extraction des points de Lowe (suite)

- Détection des extrema de D



- Affinage de la localisation des points détectés :
Recherche de la position interpolée de l'extremum de D

Soit $P(x, y, \sigma)$ un point détecté précédemment. Soit la matrice $X = [x \ y \ \sigma]^t$.

On recherche l'extremum $\hat{X} = X + d\hat{X}$ de D au voisinage de X :

$$\begin{bmatrix} d\hat{x} \\ d\hat{y} \\ d\hat{\sigma} \end{bmatrix} = d\hat{X} = - \left(\frac{\partial^2 D}{\partial X^2}(X) \right)^{-1} \cdot \frac{\partial D}{\partial X}(X)$$

(qui correspond au passage par 0 de la dérivée)

$$D(X + dX) = D(X) + {}^t \left(\frac{\partial D}{\partial X}(X) \right) \cdot dX + \frac{1}{2} \cdot {}^t dX \cdot \left(\frac{\partial^2 D}{\partial X^2}(X) \right) \cdot dX$$

(développement de Taylor de la fonction D au voisinage de X)

SIFT : Scale Invariant Feature Transform

Extraction des points de Lowe (suite)

- Élimination des points les moins contrastés

Rejet si $|D(X)| < S_{contraste}$

- Élimination des points situés sur une arête

Soit la matrice hessienne :

$$H(x, y, \sigma) = \begin{bmatrix} \frac{\partial^2 D}{\partial x^2}(x, y, \sigma) & \frac{\partial^2 D}{\partial x \partial y}(x, y, \sigma) \\ \frac{\partial^2 D}{\partial x \partial y}(x, y, \sigma) & \frac{\partial^2 D}{\partial y^2}(x, y, \sigma) \end{bmatrix} \text{ au point } P(x, y, \sigma)$$

$$\text{Si } \frac{\text{Tr}(H(x, y, \sigma))^2}{\text{Det}(H(x, y, \sigma))} < \frac{(S_{edge} + 1)^2}{S_{edge}}$$

Alors P est conservé

Sinon P est rejeté

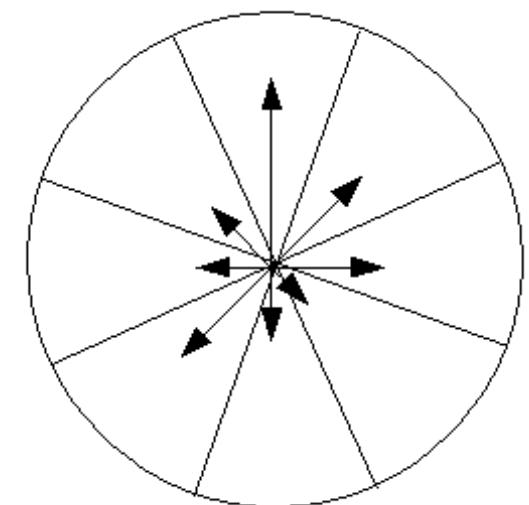
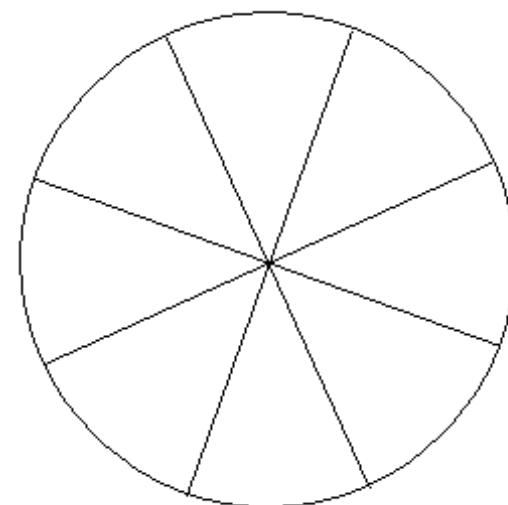
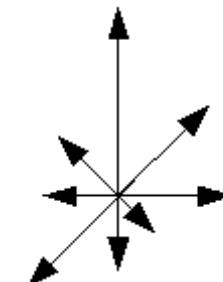
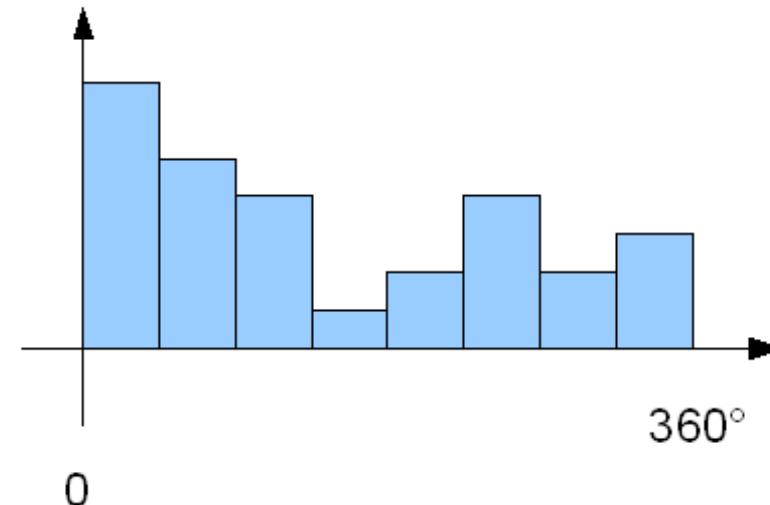
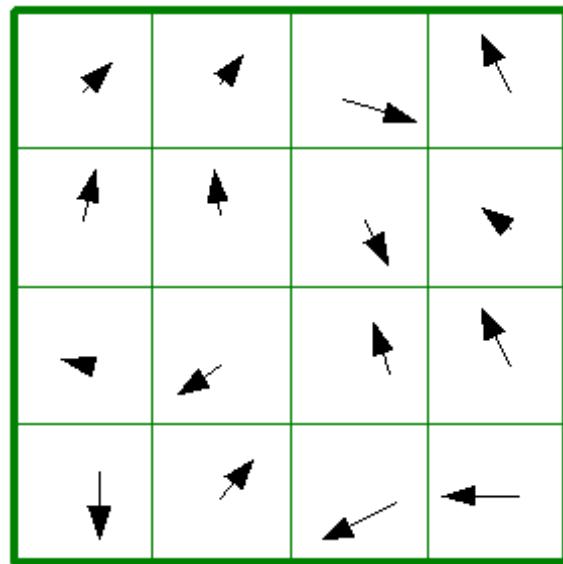
SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT

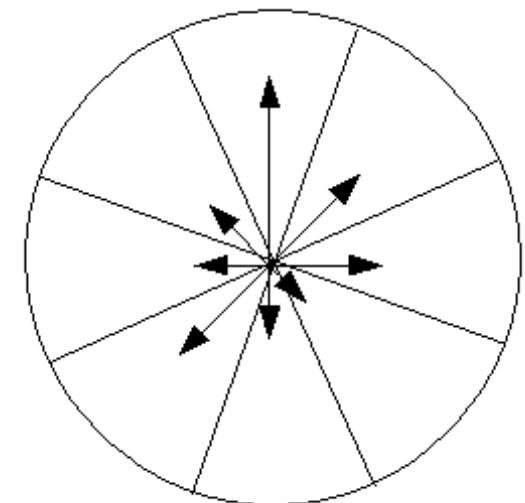
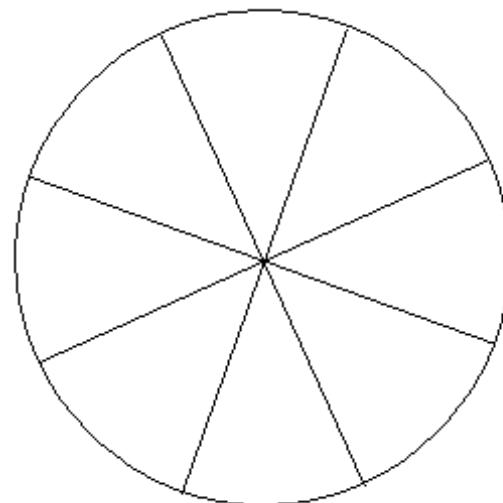
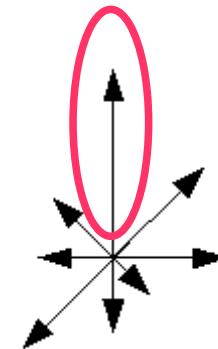
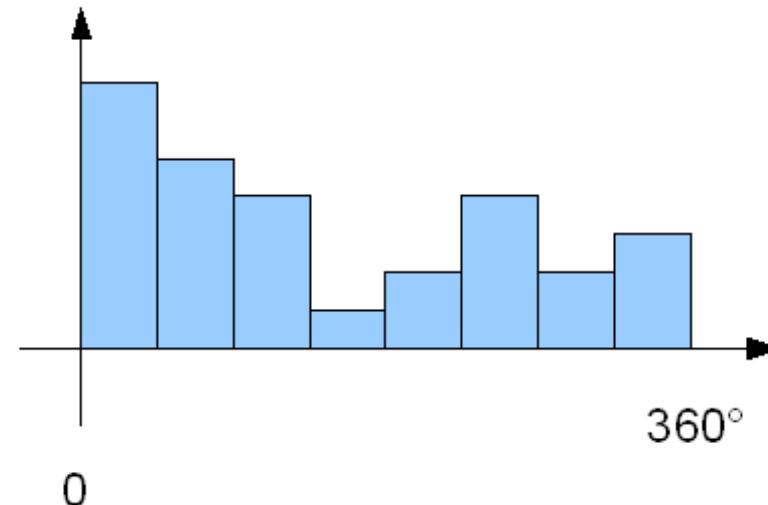
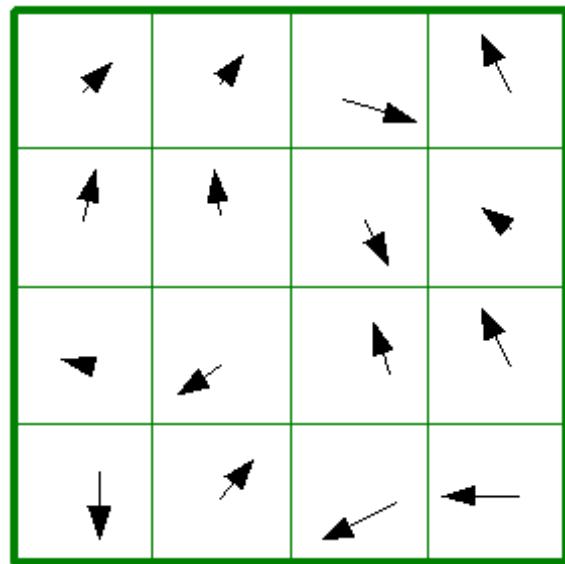
(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul de l'orientation des points détectés
 - ◆ Calcul de l'histogramme des orientations des gradients des pixels voisins dans $L(s)$
 - ◆ Orientation = orientation correspondant au plus haut pic de l'histogramme
 - ◆ Si plusieurs pics importants, on dédouble le point
- Calcul du(descripteur SIFT

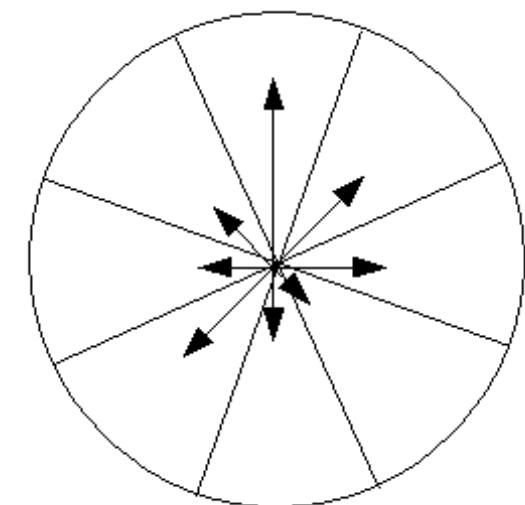
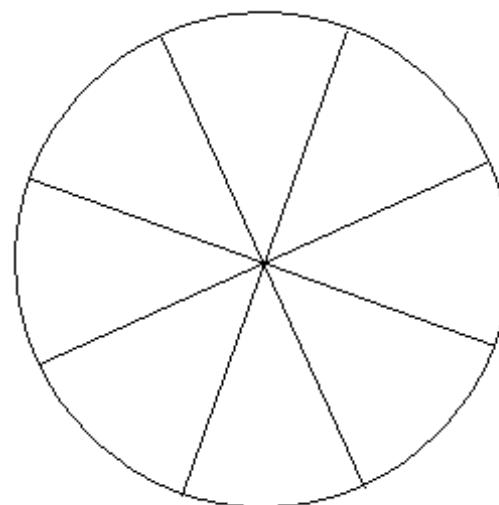
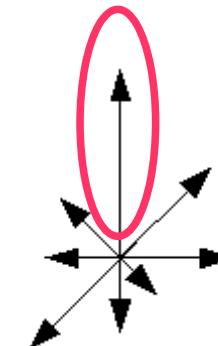
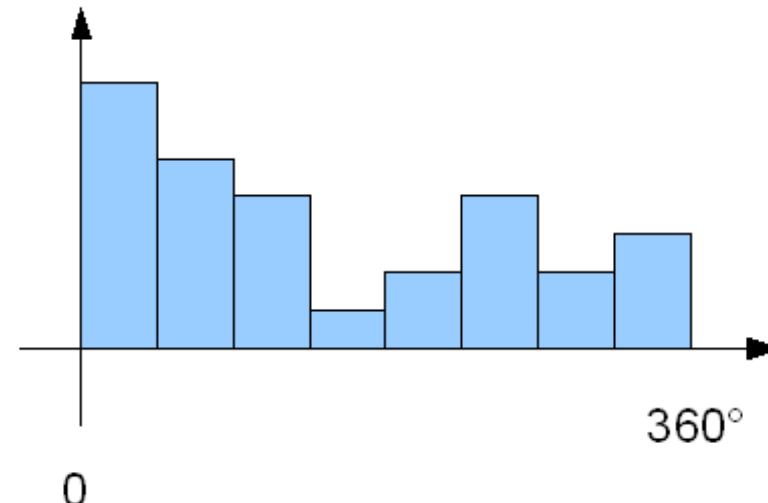
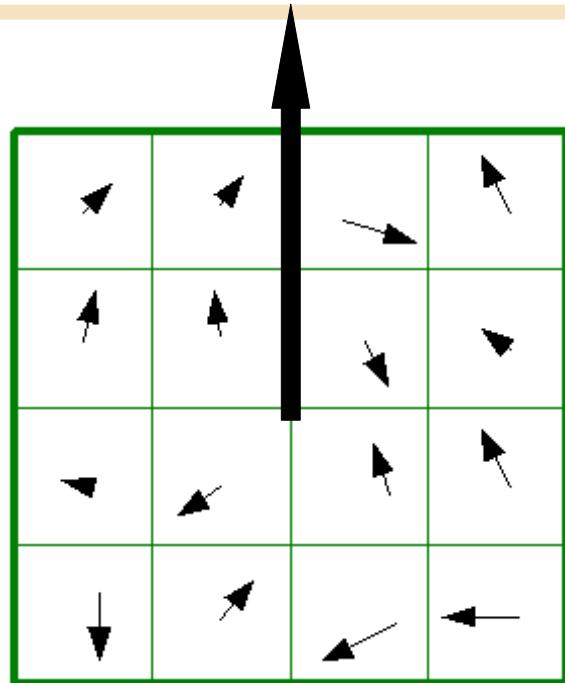
SIFT : Scale Invariant Feature Transform



SIFT : Scale Invariant Feature Transform



SIFT : Scale Invariant Feature Transform



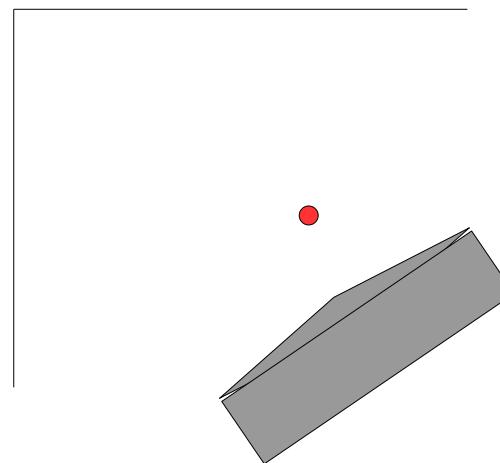
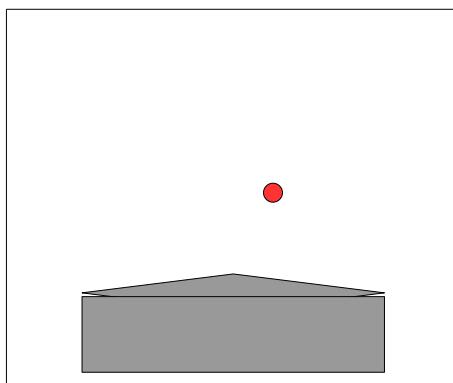
SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

- ◆ Calcul des histogrammes des orientations (**relatives à l'orientation du point d'intérêt**) des gradients des pixels voisins dans L_s



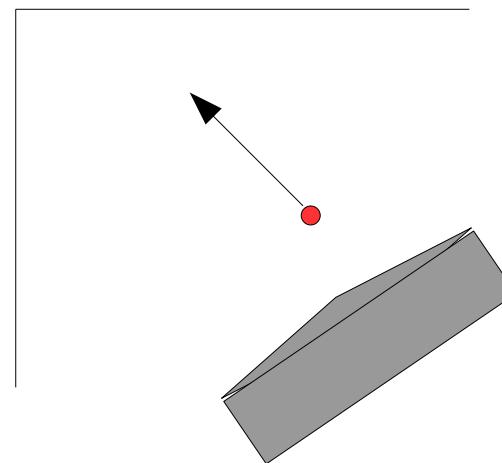
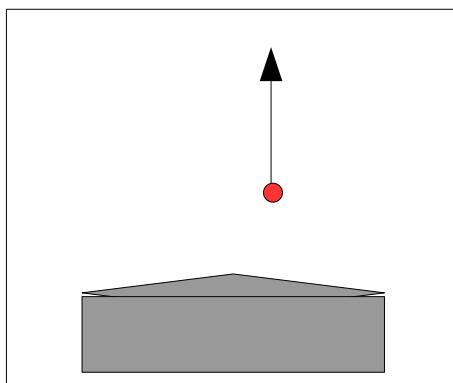
SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

- ◆ Calcul des histogrammes des orientations (**relatives à l'orientation du point d'intérêt**) des gradients des pixels voisins dans L_s



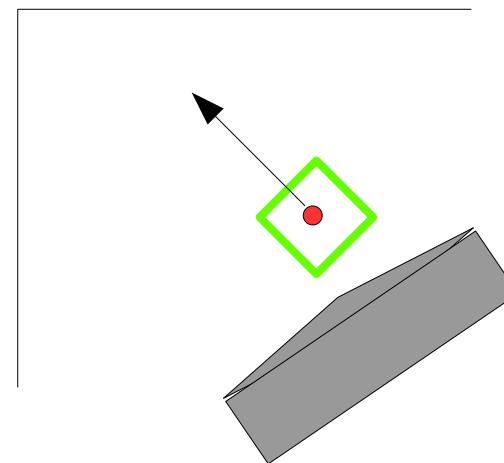
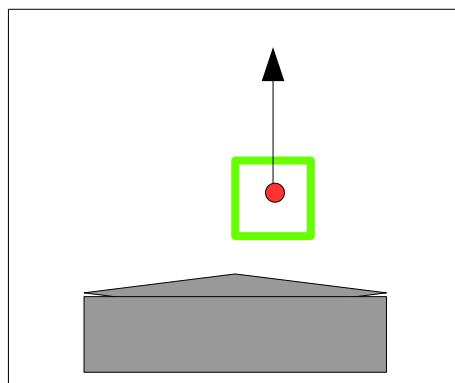
SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

- ◆ Calcul des histogrammes des orientations (**relatives à l'orientation du point d'intérêt**) des gradients des pixels voisins dans L_s



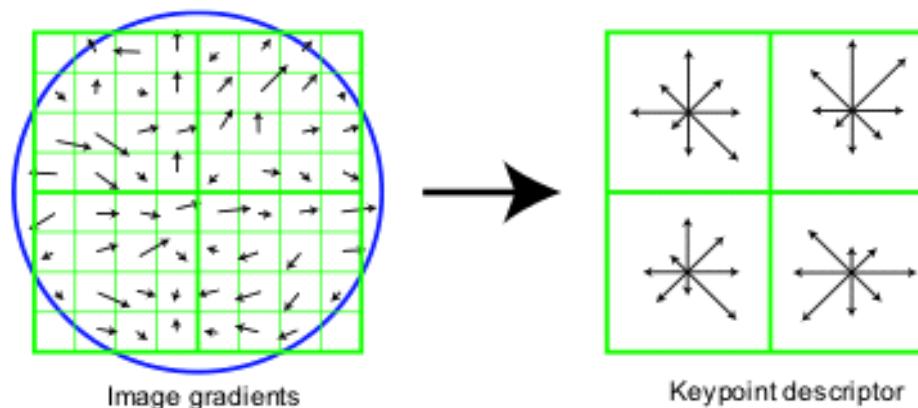
SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

- ◆ Calcul des histogrammes des orientations (relatives à l'orientation du point d'intérêt) des gradients des pixels voisins dans L_s
- ◆ Calcul des histogrammes de ces orientations au sein de fenêtres situées de part et d'autres du point d'intérêt détecté
- ◆ Valeurs de ces histogrammes sous la forme d'un vecteur dans chaque fenêtre
- ◆ Concaténation de ces vecteurs en un seul vecteur : le(descripteur
- ◆ Normalisation du(descripteur

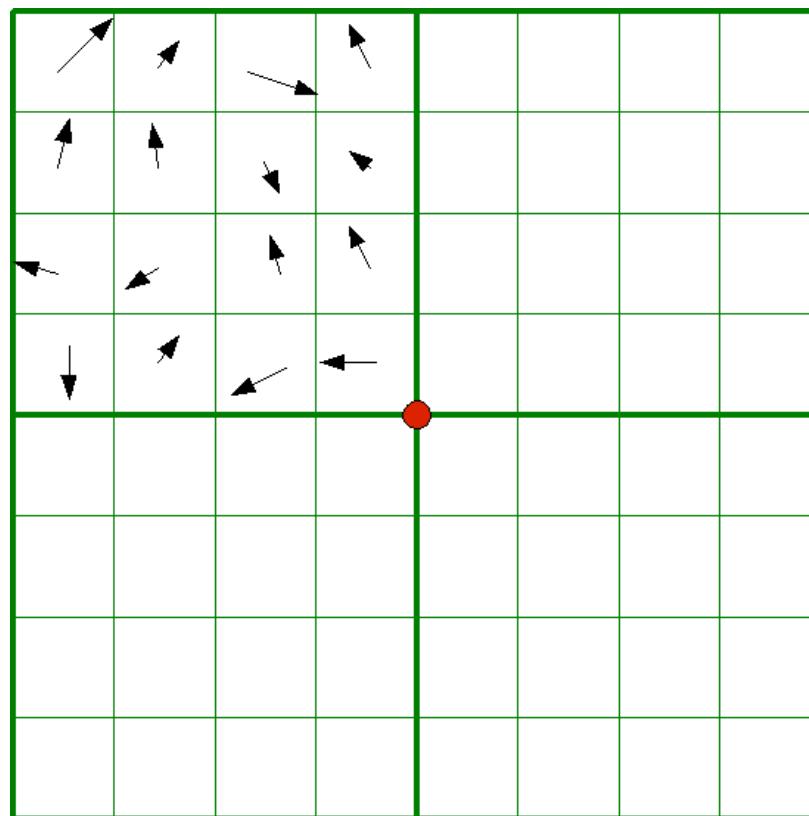


SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

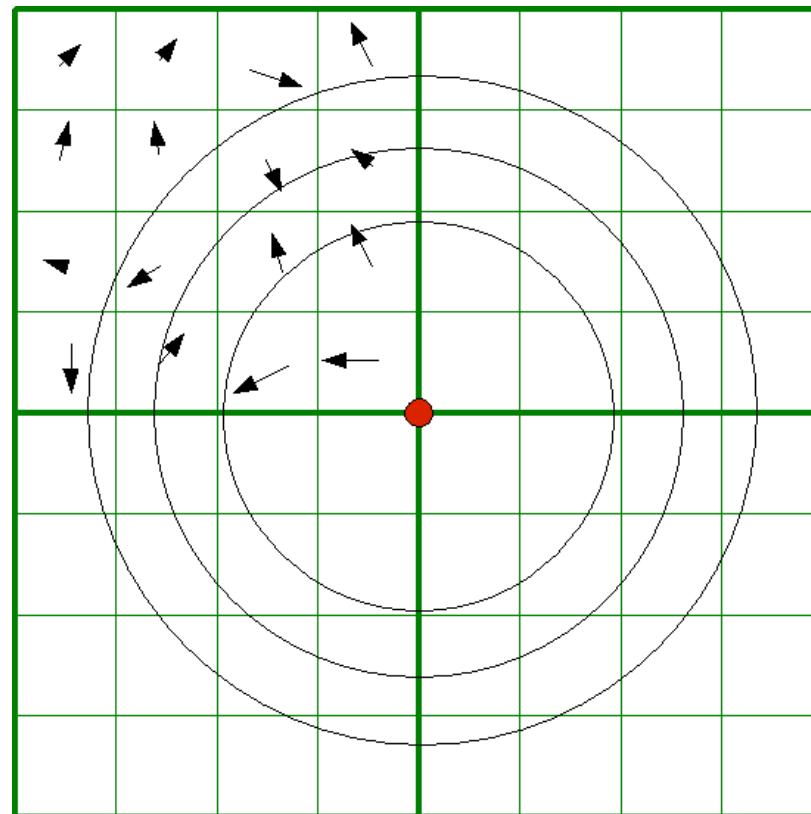


SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

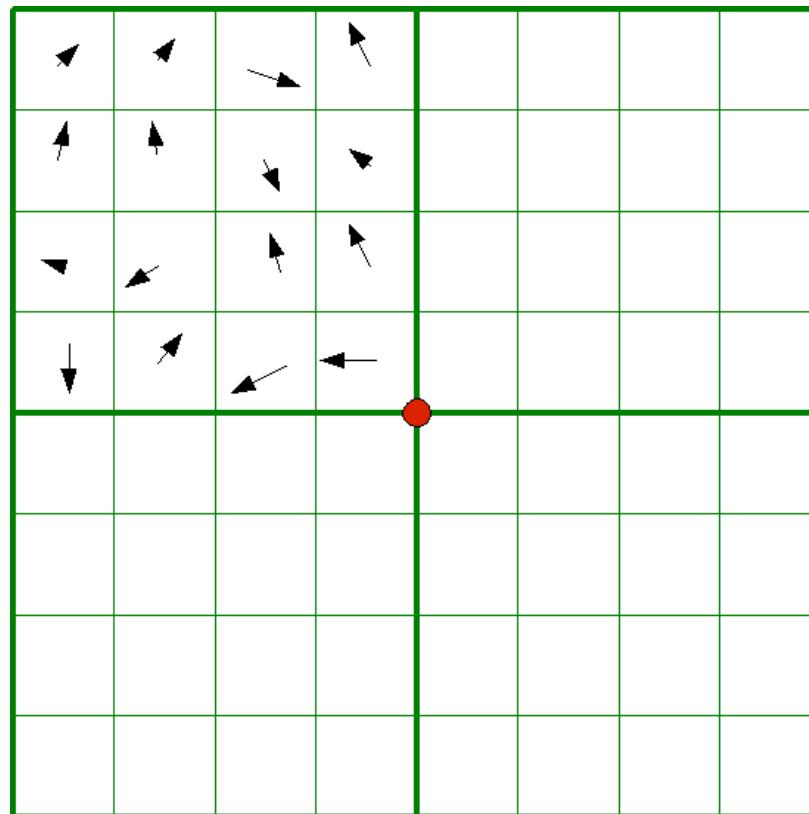


SIFT : Scale Invariant Feature Transform

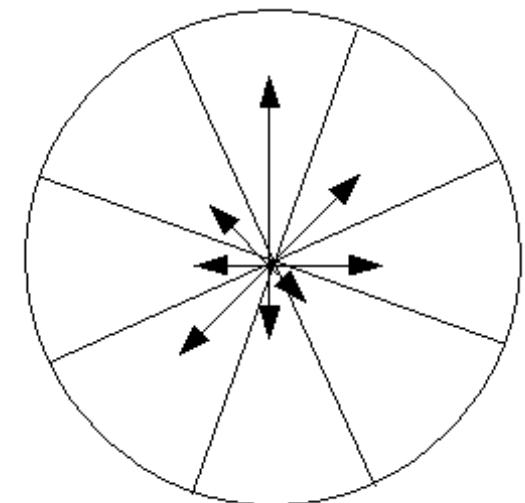
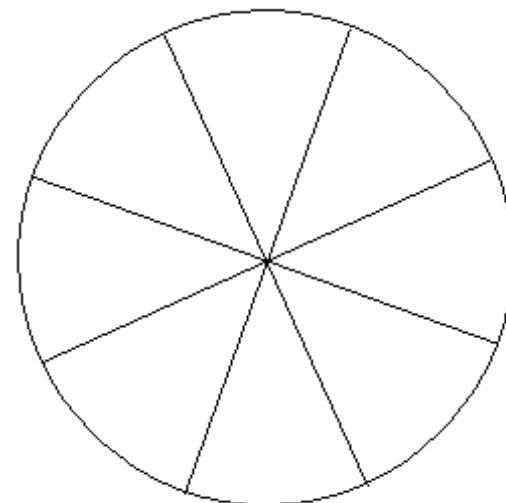
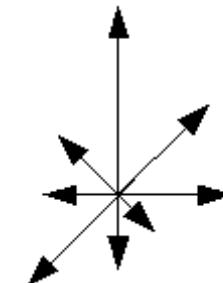
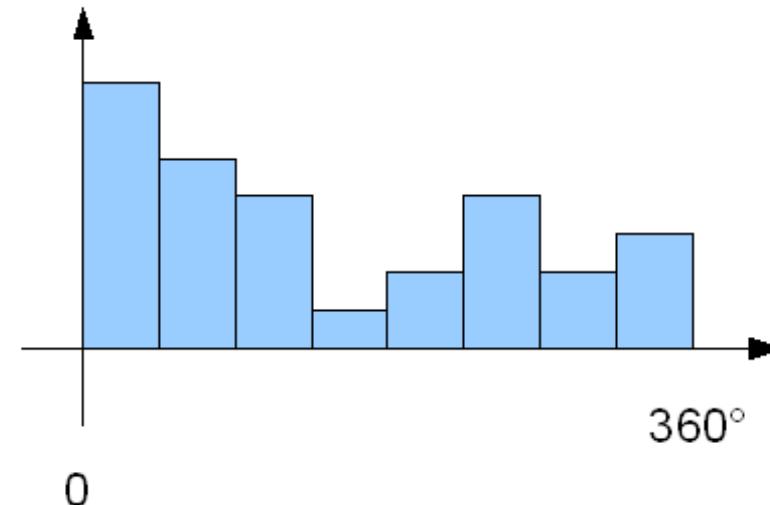
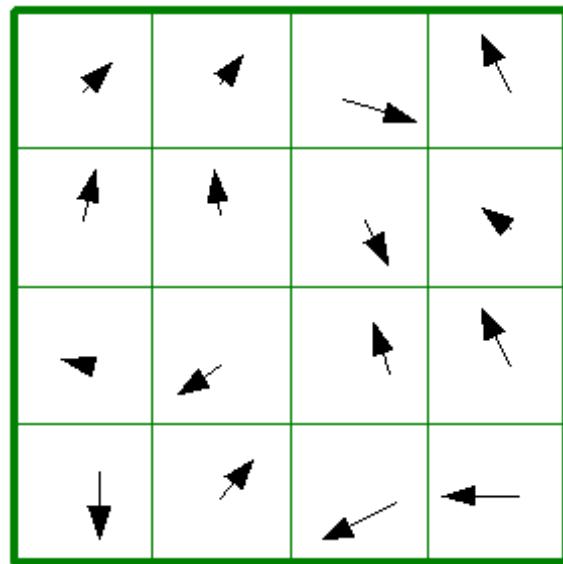
Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)



SIFT : Scale Invariant Feature Transform

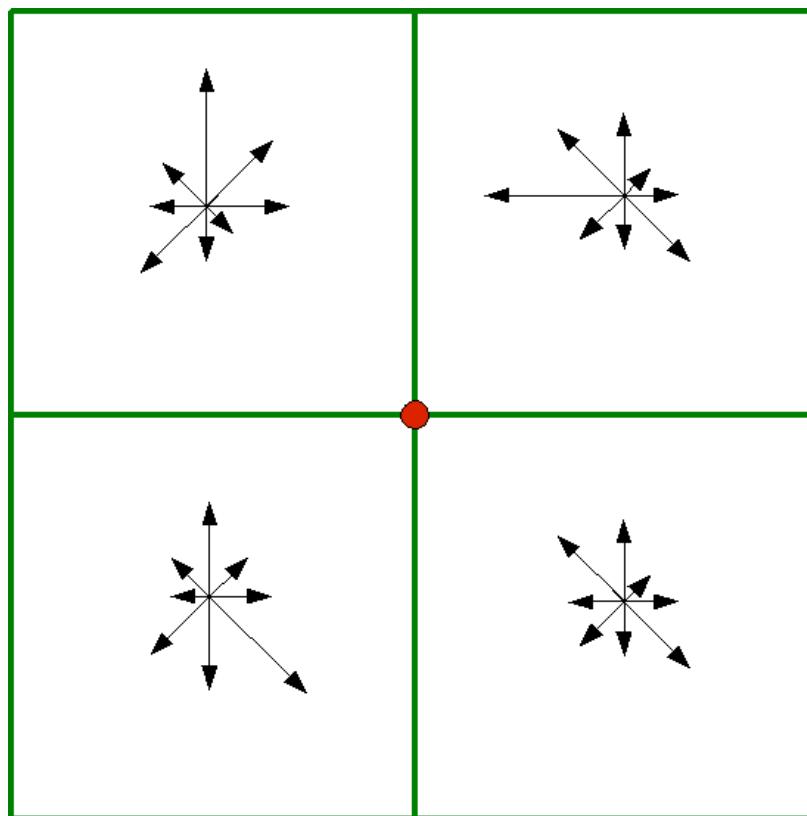


SIFT : Scale Invariant Feature Transform

Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)



SIFT : Scale Invariant Feature Transform

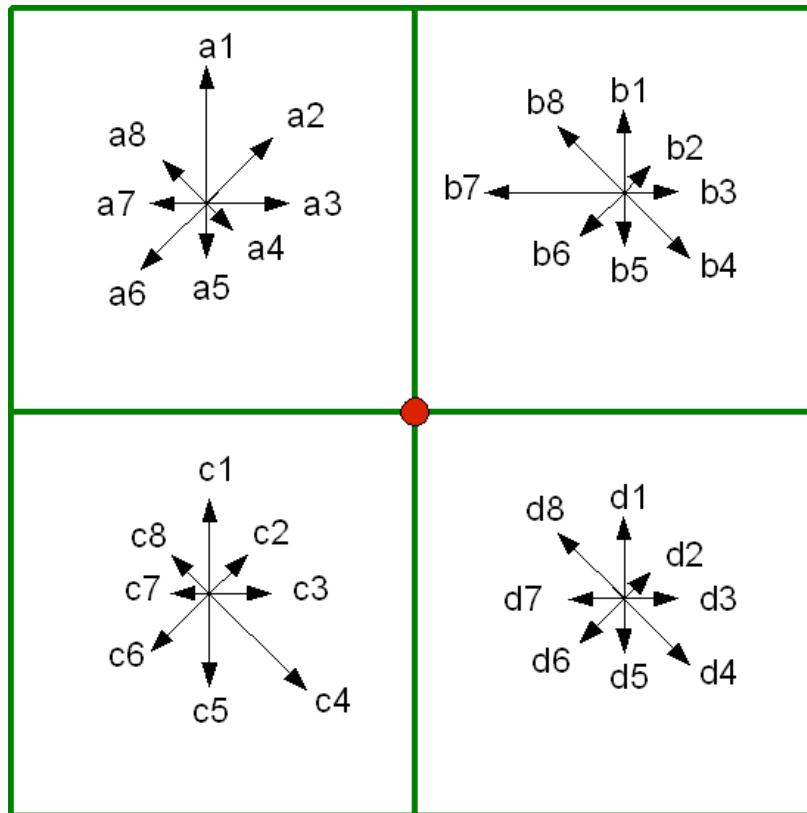
Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

$$V = [a_1 \ a_2 \ a_3 \ a_4 \ a_5 \ a_6 \ a_7 \ a_8 \ b_1 \ b_2 \ b_3 \ b_4 \ b_5 \ b_6 \ b_7 \ b_8 \ c_1 \ c_2 \ c_3 \ c_4 \ c_5 \ c_6 \ c_7 \ c_8 \ d_1 \ d_2 \ d_3 \ d_4 \ d_5 \ d_6 \ d_7 \ d_8]$$

$$V_{SIFT} = \frac{V}{\|V\|}$$



SIFT : Scale Invariant Feature Transform

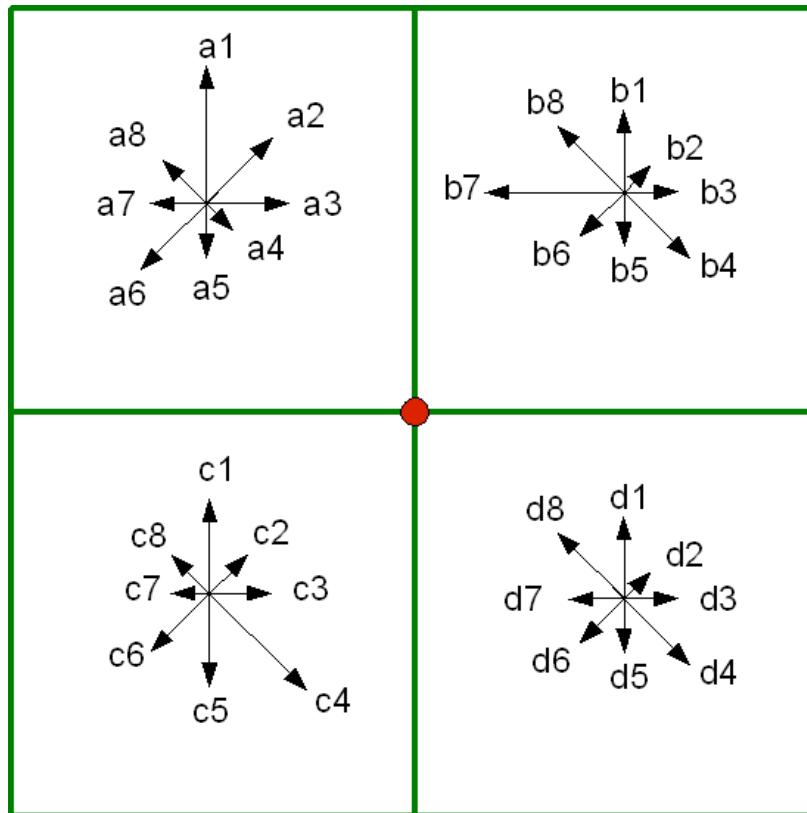
Le(descripteur SIFT)

(Caractérisation du comportement de l'image au voisinage des points d'intérêt)

- Calcul du(descripteur SIFT)

$$V = [a_1 \ a_2 \ a_3 \ a_4 \ a_5 \ a_6 \ a_7 \ a_8 \ b_1 \ b_2 \ b_3 \ b_4 \ b_5 \ b_6 \ b_7 \ b_8 \ c_1 \ c_2 \ c_3 \ c_4 \ c_5 \ c_6 \ c_7 \ c_8 \ d_1 \ d_2 \ d_3 \ d_4 \ d_5 \ d_6 \ d_7 \ d_8]$$

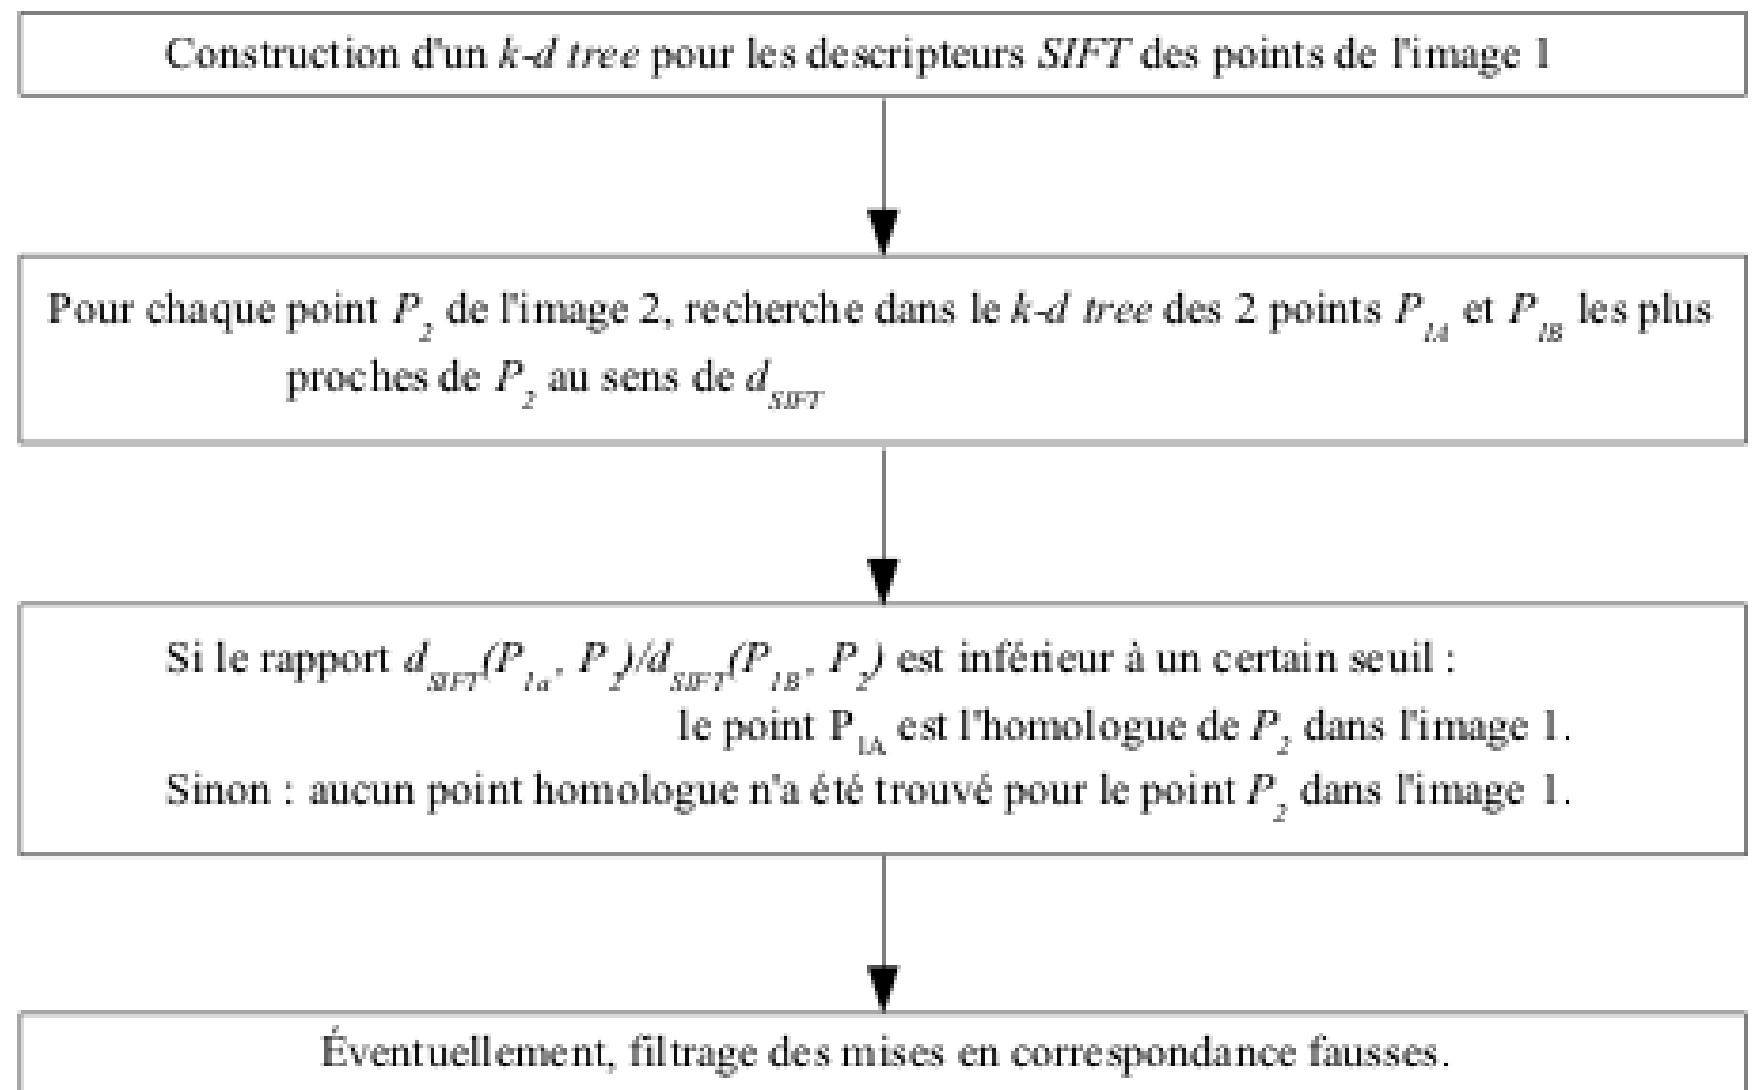
$$V_{SIFT} = \frac{V}{\|V\|}$$



SIFT : Scale Invariant Feature Transform

Appariement

Notation : $d_{SIFT}(P_i, P_j)$ désigne la distance euclidienne entre les descripteurs SIFT des points P_i et P_j .



Appariement

- Pour un point requête d'une image, recherche de son homologue dans une autre image comme étant son plus proche voisin au sens de la distance euclidienne dans l'espace des descripteurs
- Descripteur ~ espace de dimension 128...
- → Utilisation d'une méthode de recherche efficace (e.g. utilisant un *k-d tree*) de plus proche voisins pour des temps de calcul raisonnable.

SIFT : Scale Invariant Feature Transform

Appariement

Notation : $d_{SIFT}(P_i, P_j)$ désigne la distance euclidienne entre les descripteurs SIFT des points P_i et P_j .

Construction d'un k -*d tree* pour les descripteurs SIFT des points de l'image 1

Pour chaque point P_2 de l'image 2, recherche dans le k -*d tree* des 2 points P_{1A} et P_{1B} les plus proches de P_2 au sens de d_{SIFT}

Permet d'éliminer les appariements ambigus

Si le rapport $d_{SIFT}(P_{1A}, P_2) / d_{SIFT}(P_{1B}, P_2)$ est inférieur à un certain seuil :
le point P_{1A} est l'homologue de P_2 dans l'image 1.
Sinon : aucun point homologue n'a été trouvé pour le point P_2 dans l'image 1.

Éventuellement, filtrage des mises en correspondance fausses.

Quelques applications...

Applications

Quelques applications :

- Mise en correspondance d'images en vue d'un recalage
- Calcul de points de liaison multiples pour
 - ◆ l'aérotriangulation
 - ◆ vision par ordinateur
 - ◆ en vue de réaliser une panoramique
- Constitution automatique d'un tableau d'assemblage
- Reconnaissance d'objets
- Indexation d'images

Applications

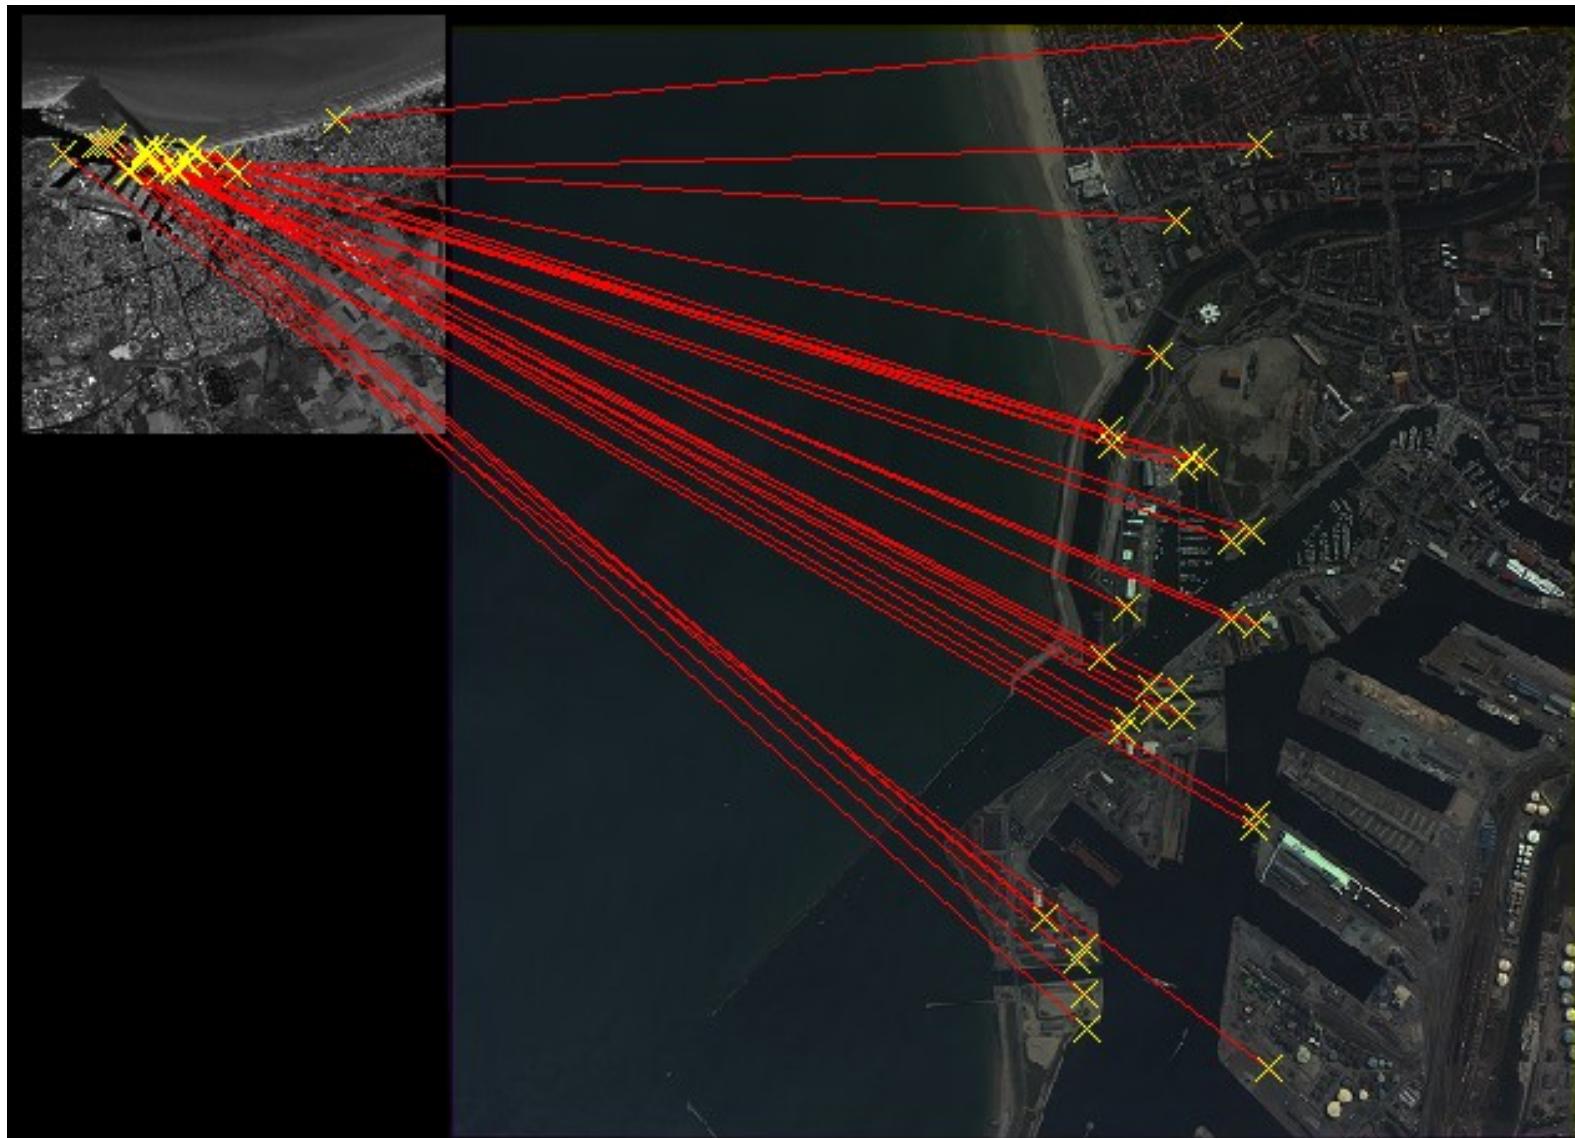
Mise en correspondance d'images en vue d'un recalage



Ortho GEOBASE

Photographie aérienne

Applications



Applications

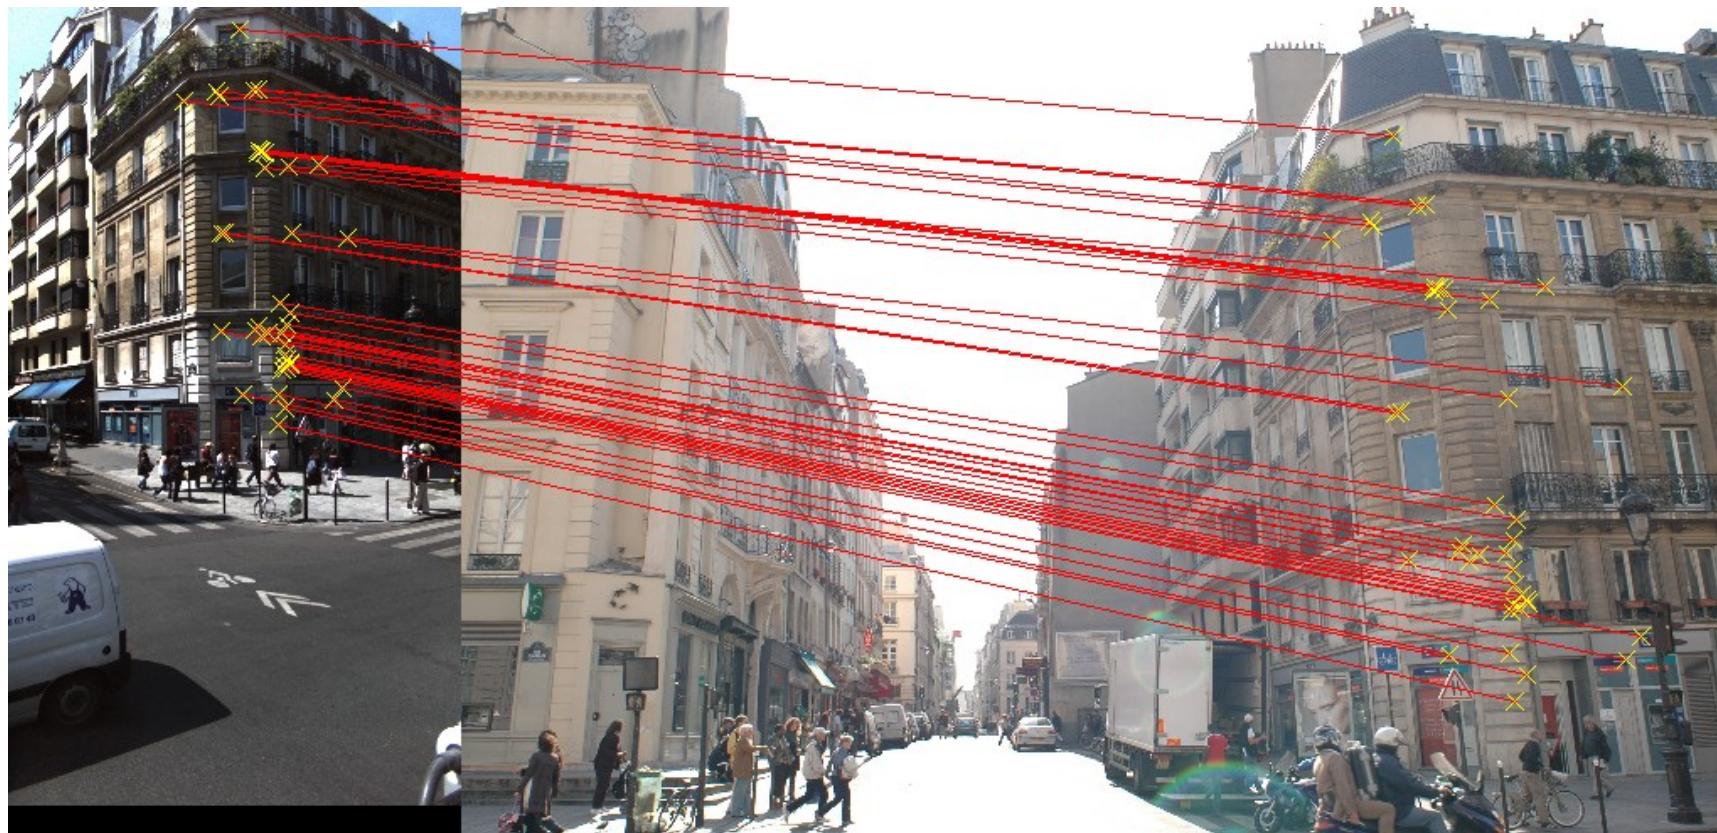


Ortho GEOFEST

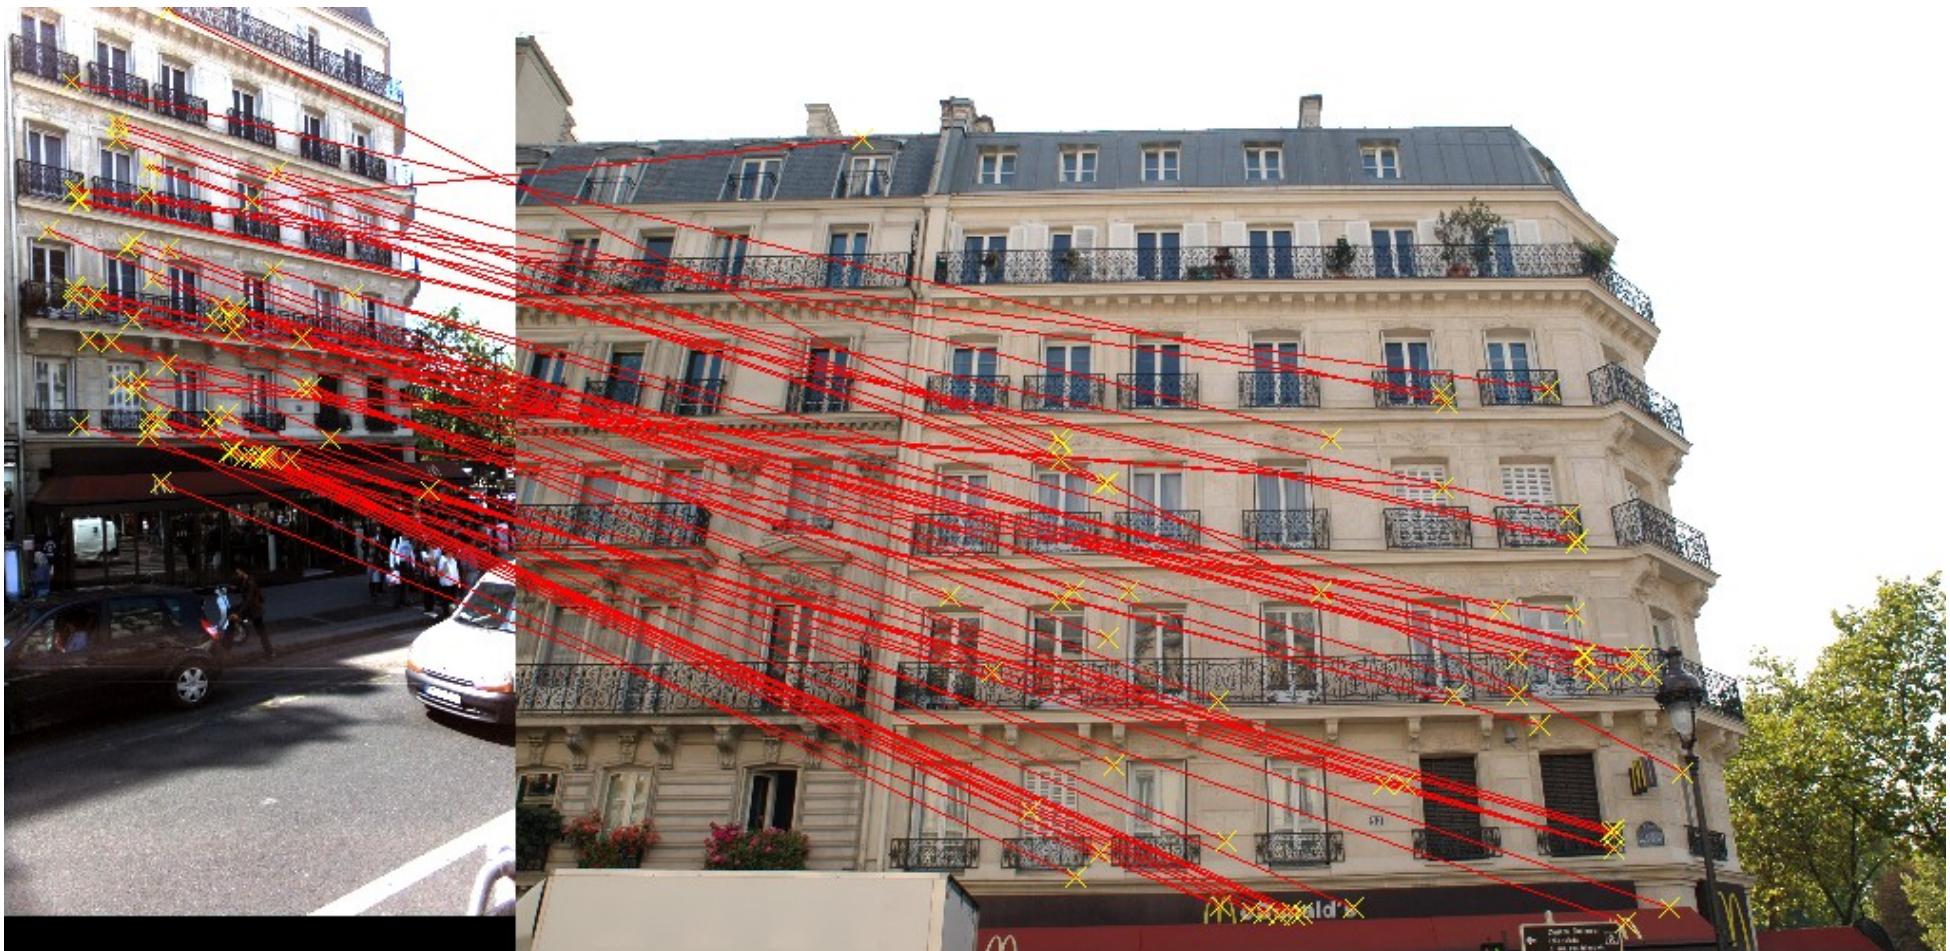


Photographie aérienne

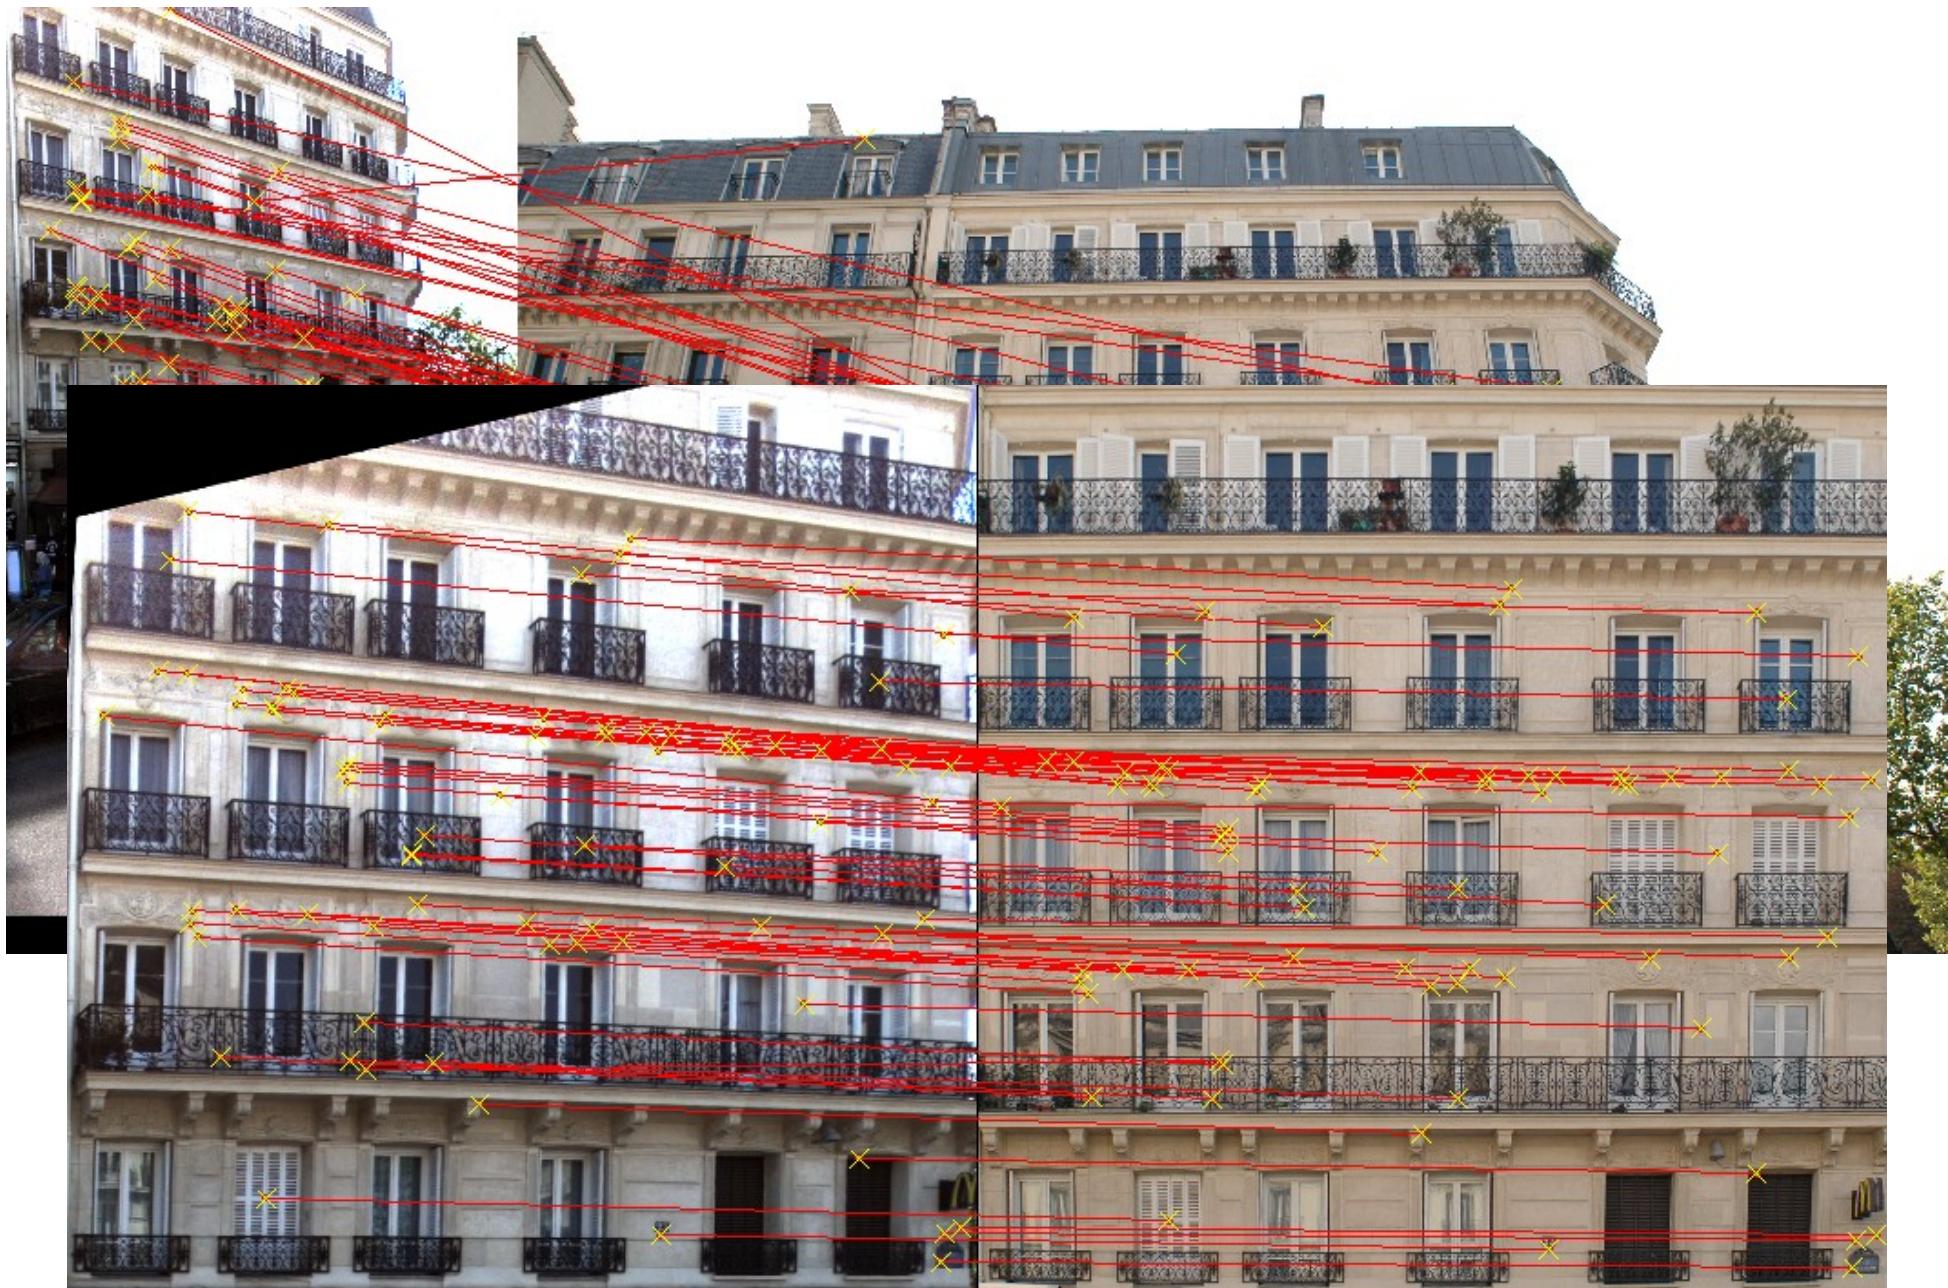
Applications



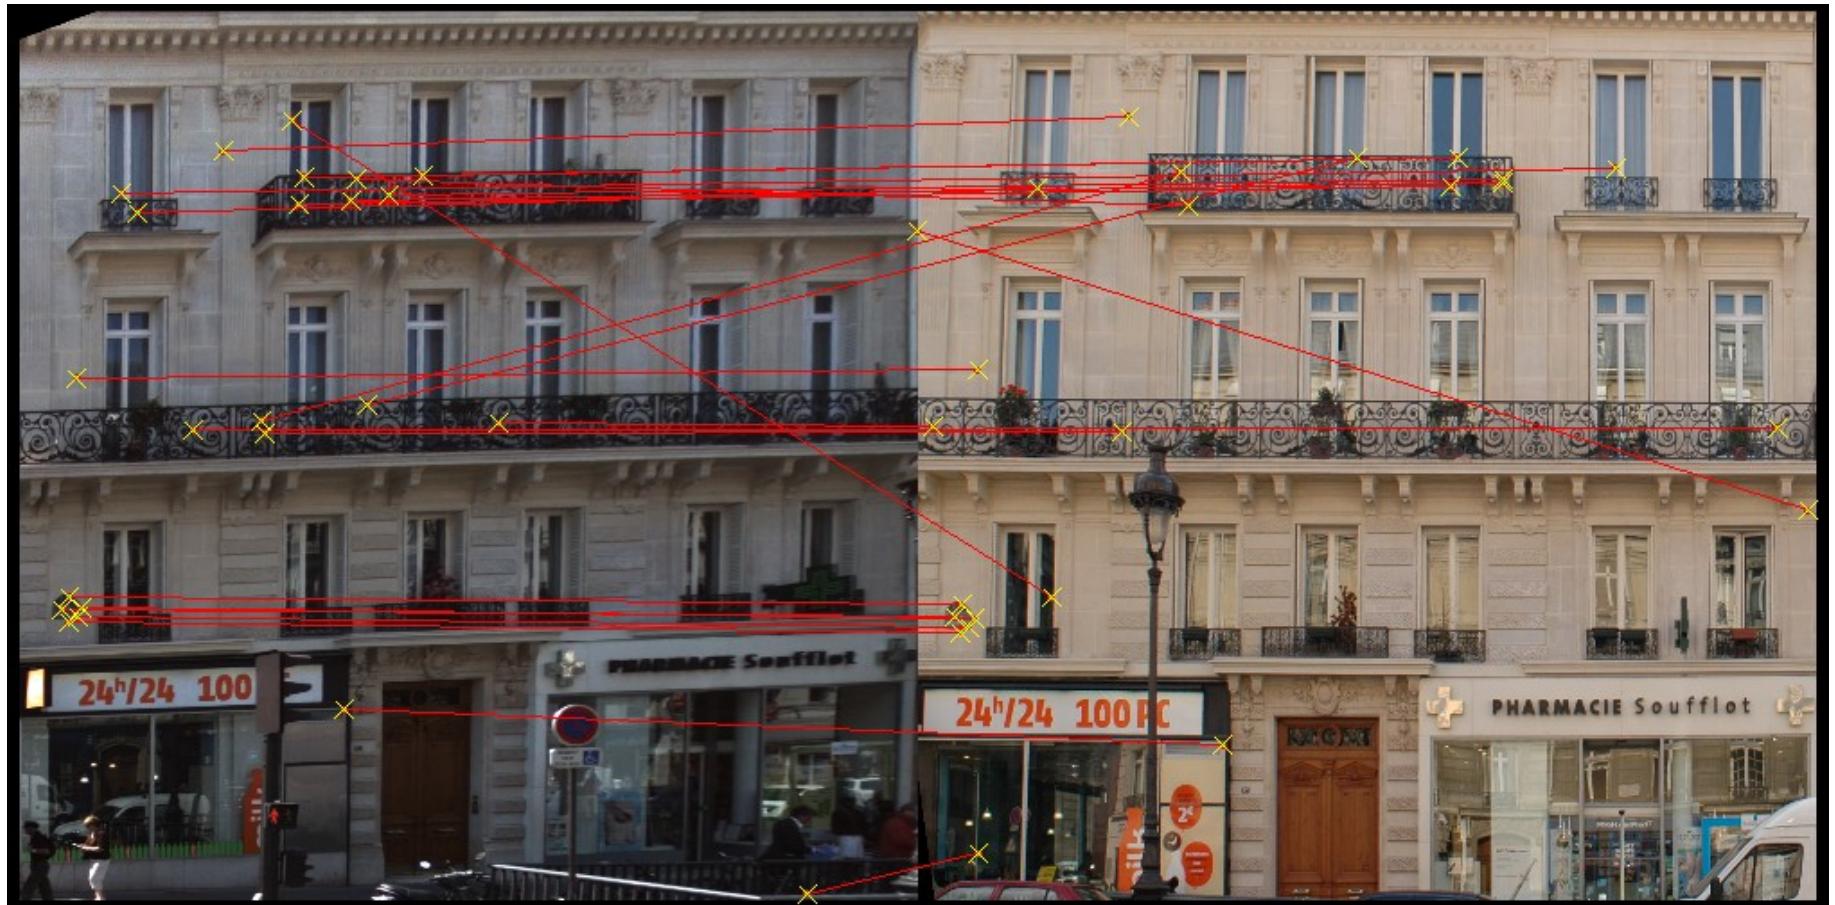
Applications



Applications



Applications



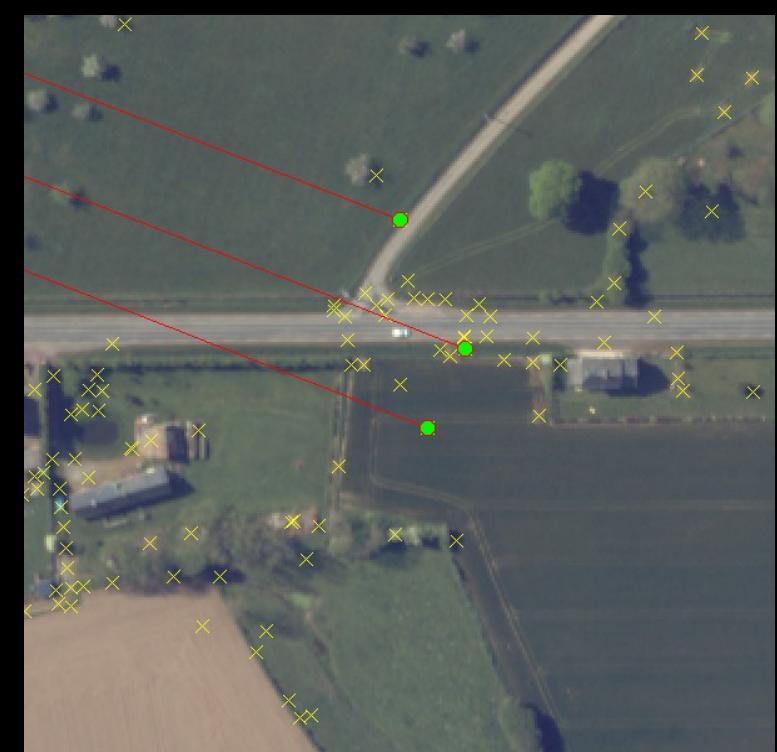
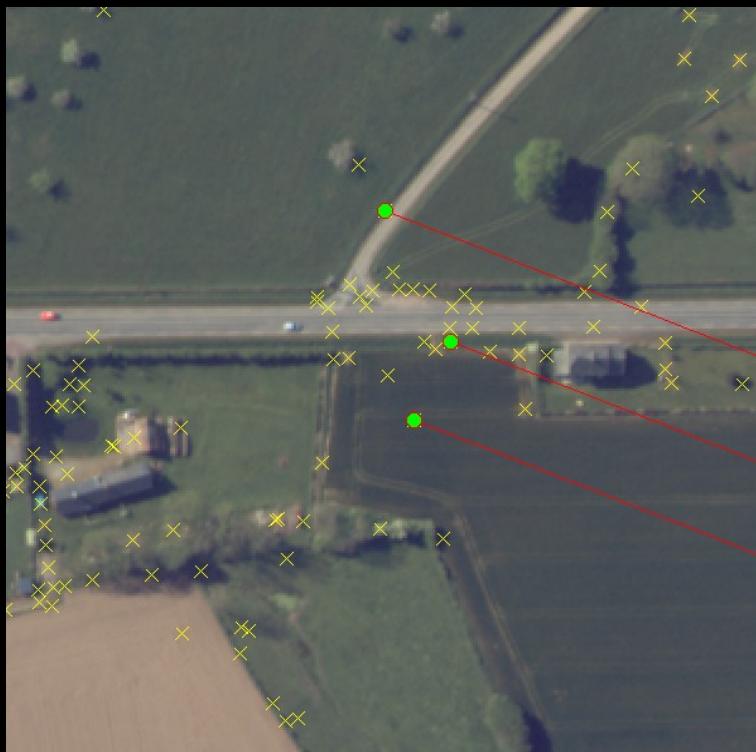
Applications

Calcul de points de liaison (multiples) pour l'aérotriangulation



Applications

Calcul de points de liaison multiples pour l'aérotriangulation





Applications

Calcul de points de liaison (multiples) pour l'aérotriangulation





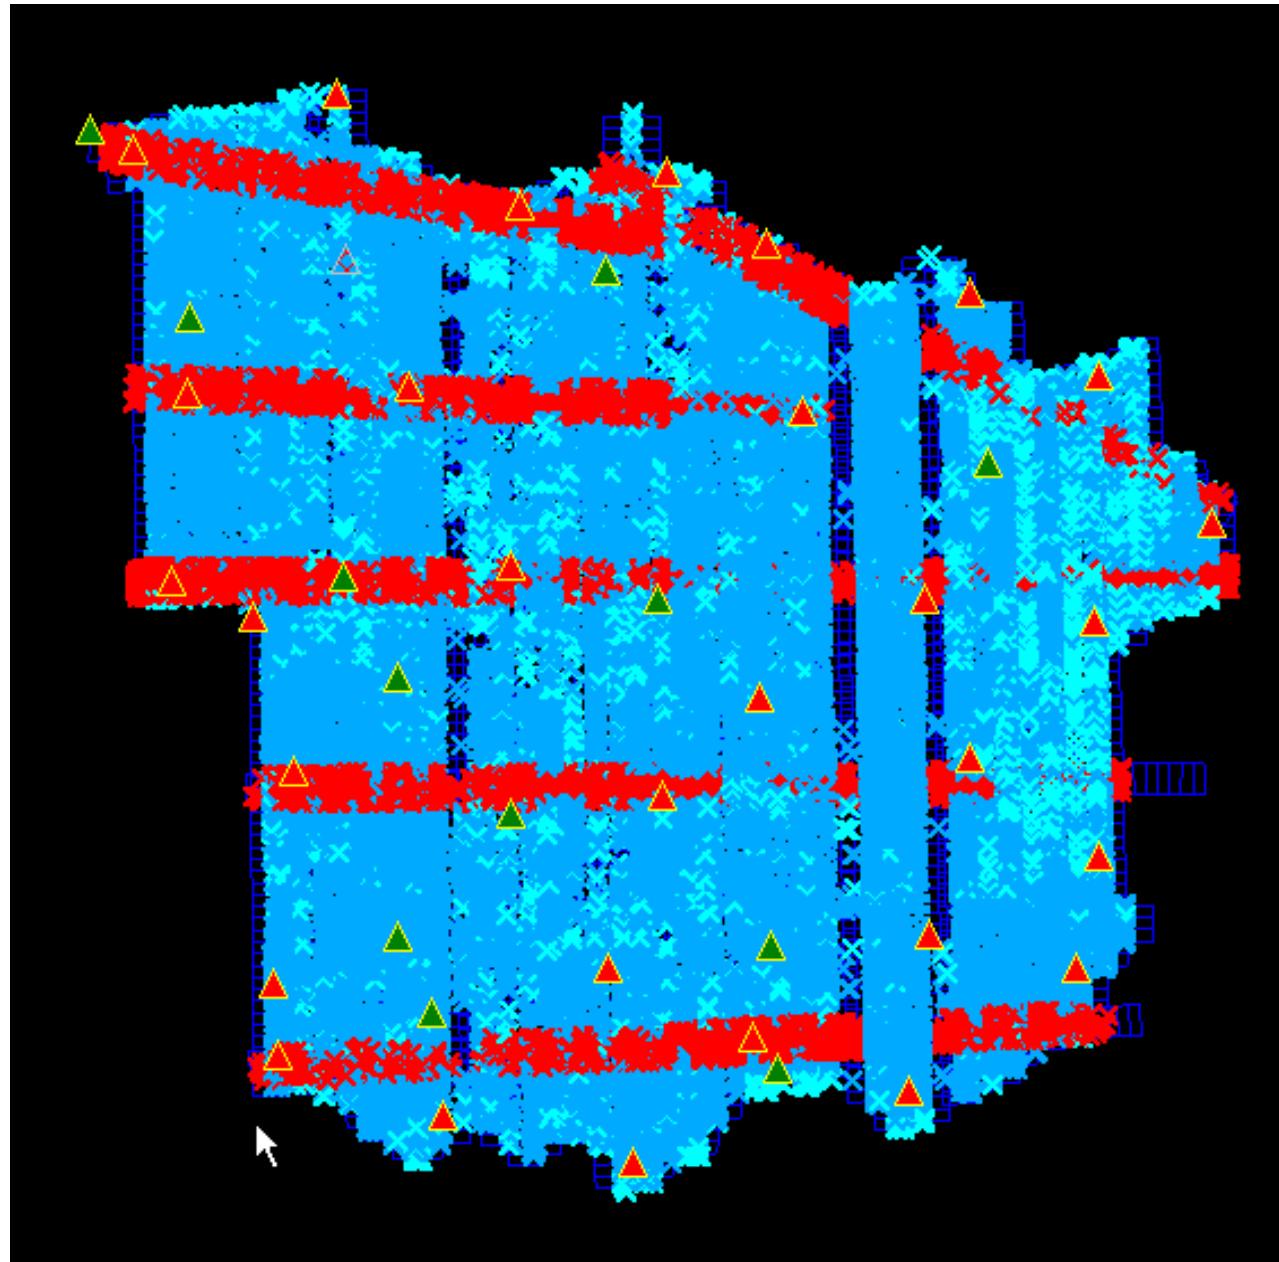
Applications

Calcul de points de liaison (multiples) pour l'aérotriangulation

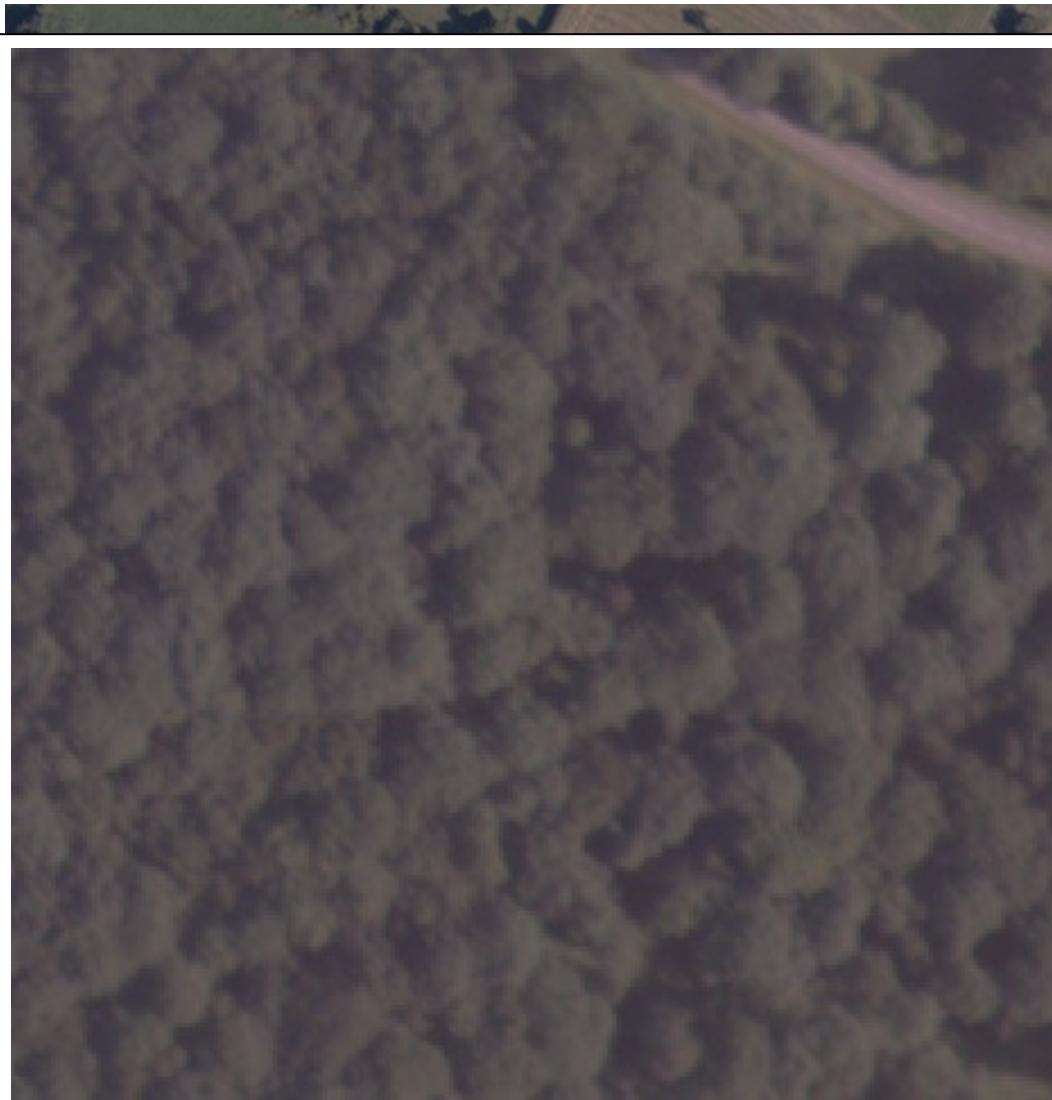
Sensibilité de SIFT au diachronisme









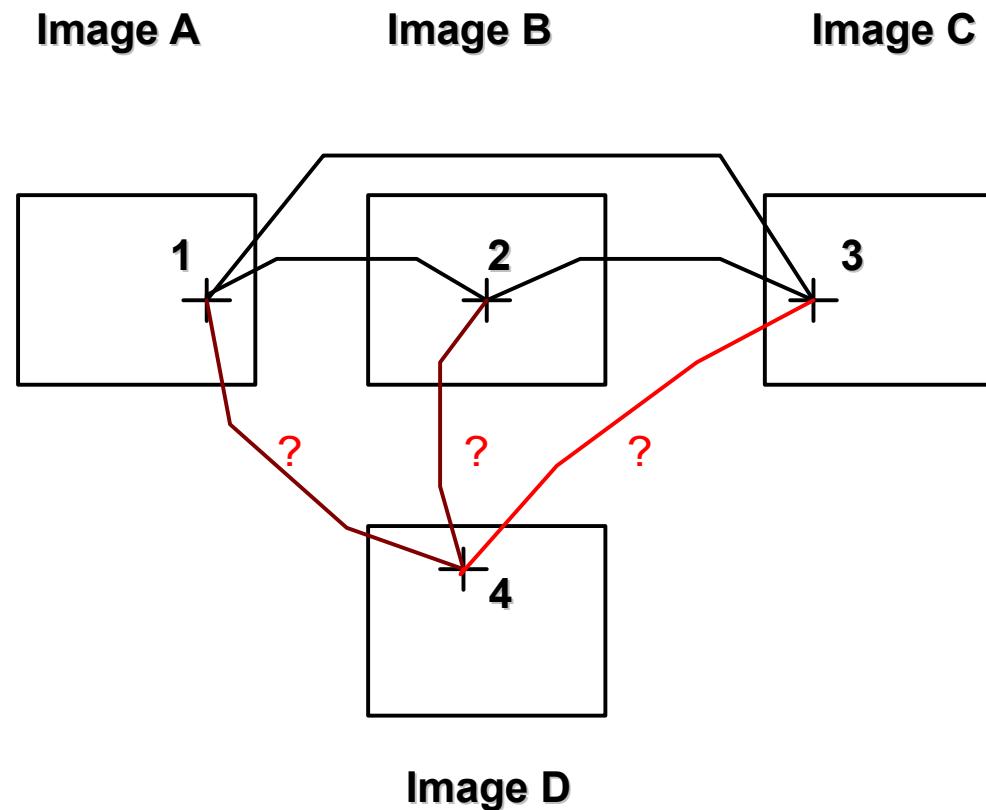


Applications

Points de liaison pour l'aérotriangulation

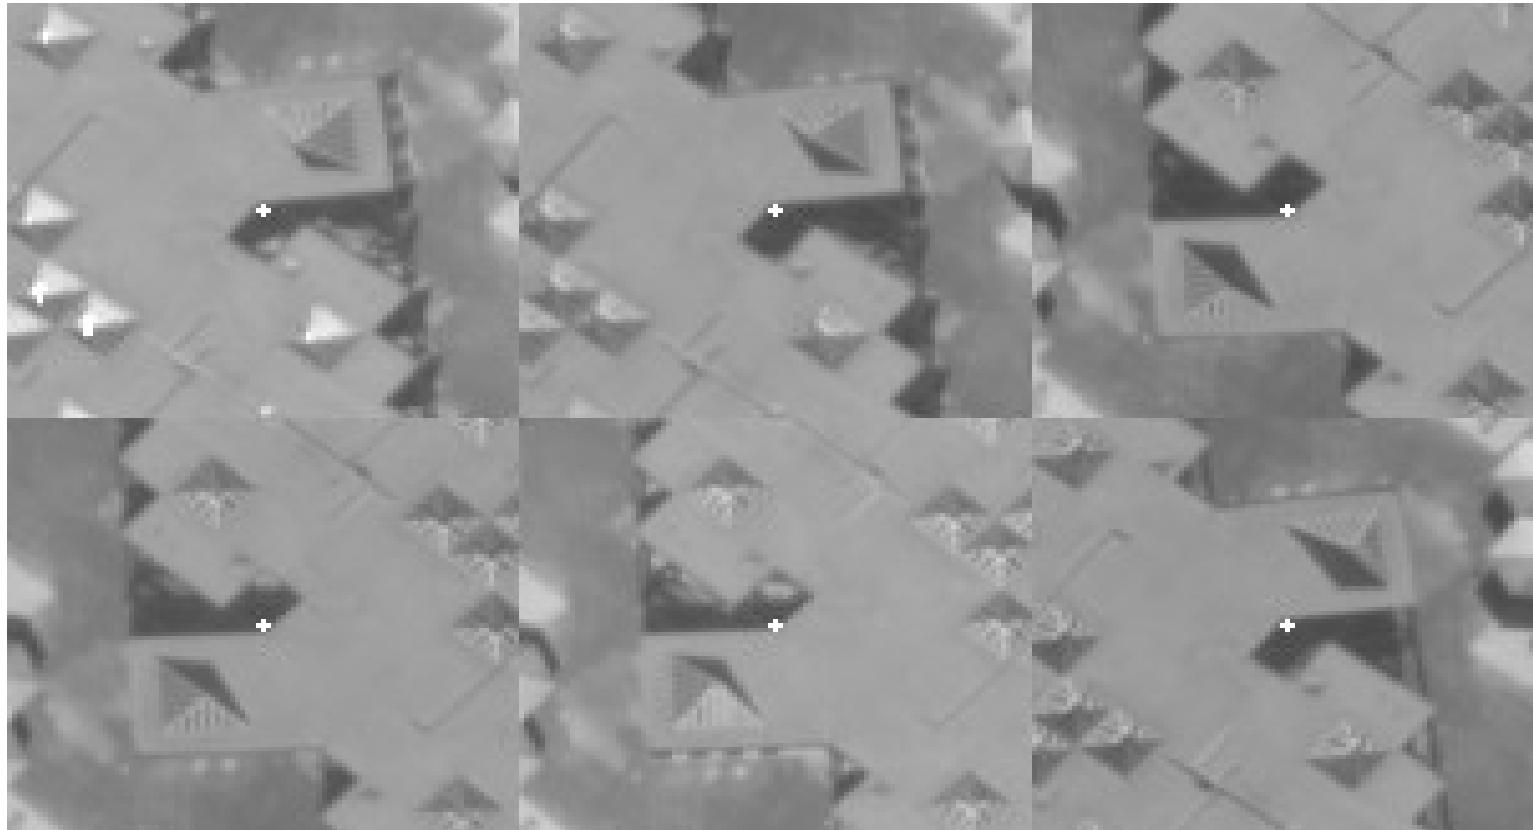
Nécessite des points de liaison multiples

- ◆ Construction itérative des points multiples
- ◆ Utilisation de la liste de points homologues par couple



Applications

Points de liaison pour l'aérotriangulation



Point multiple d'ordre 6



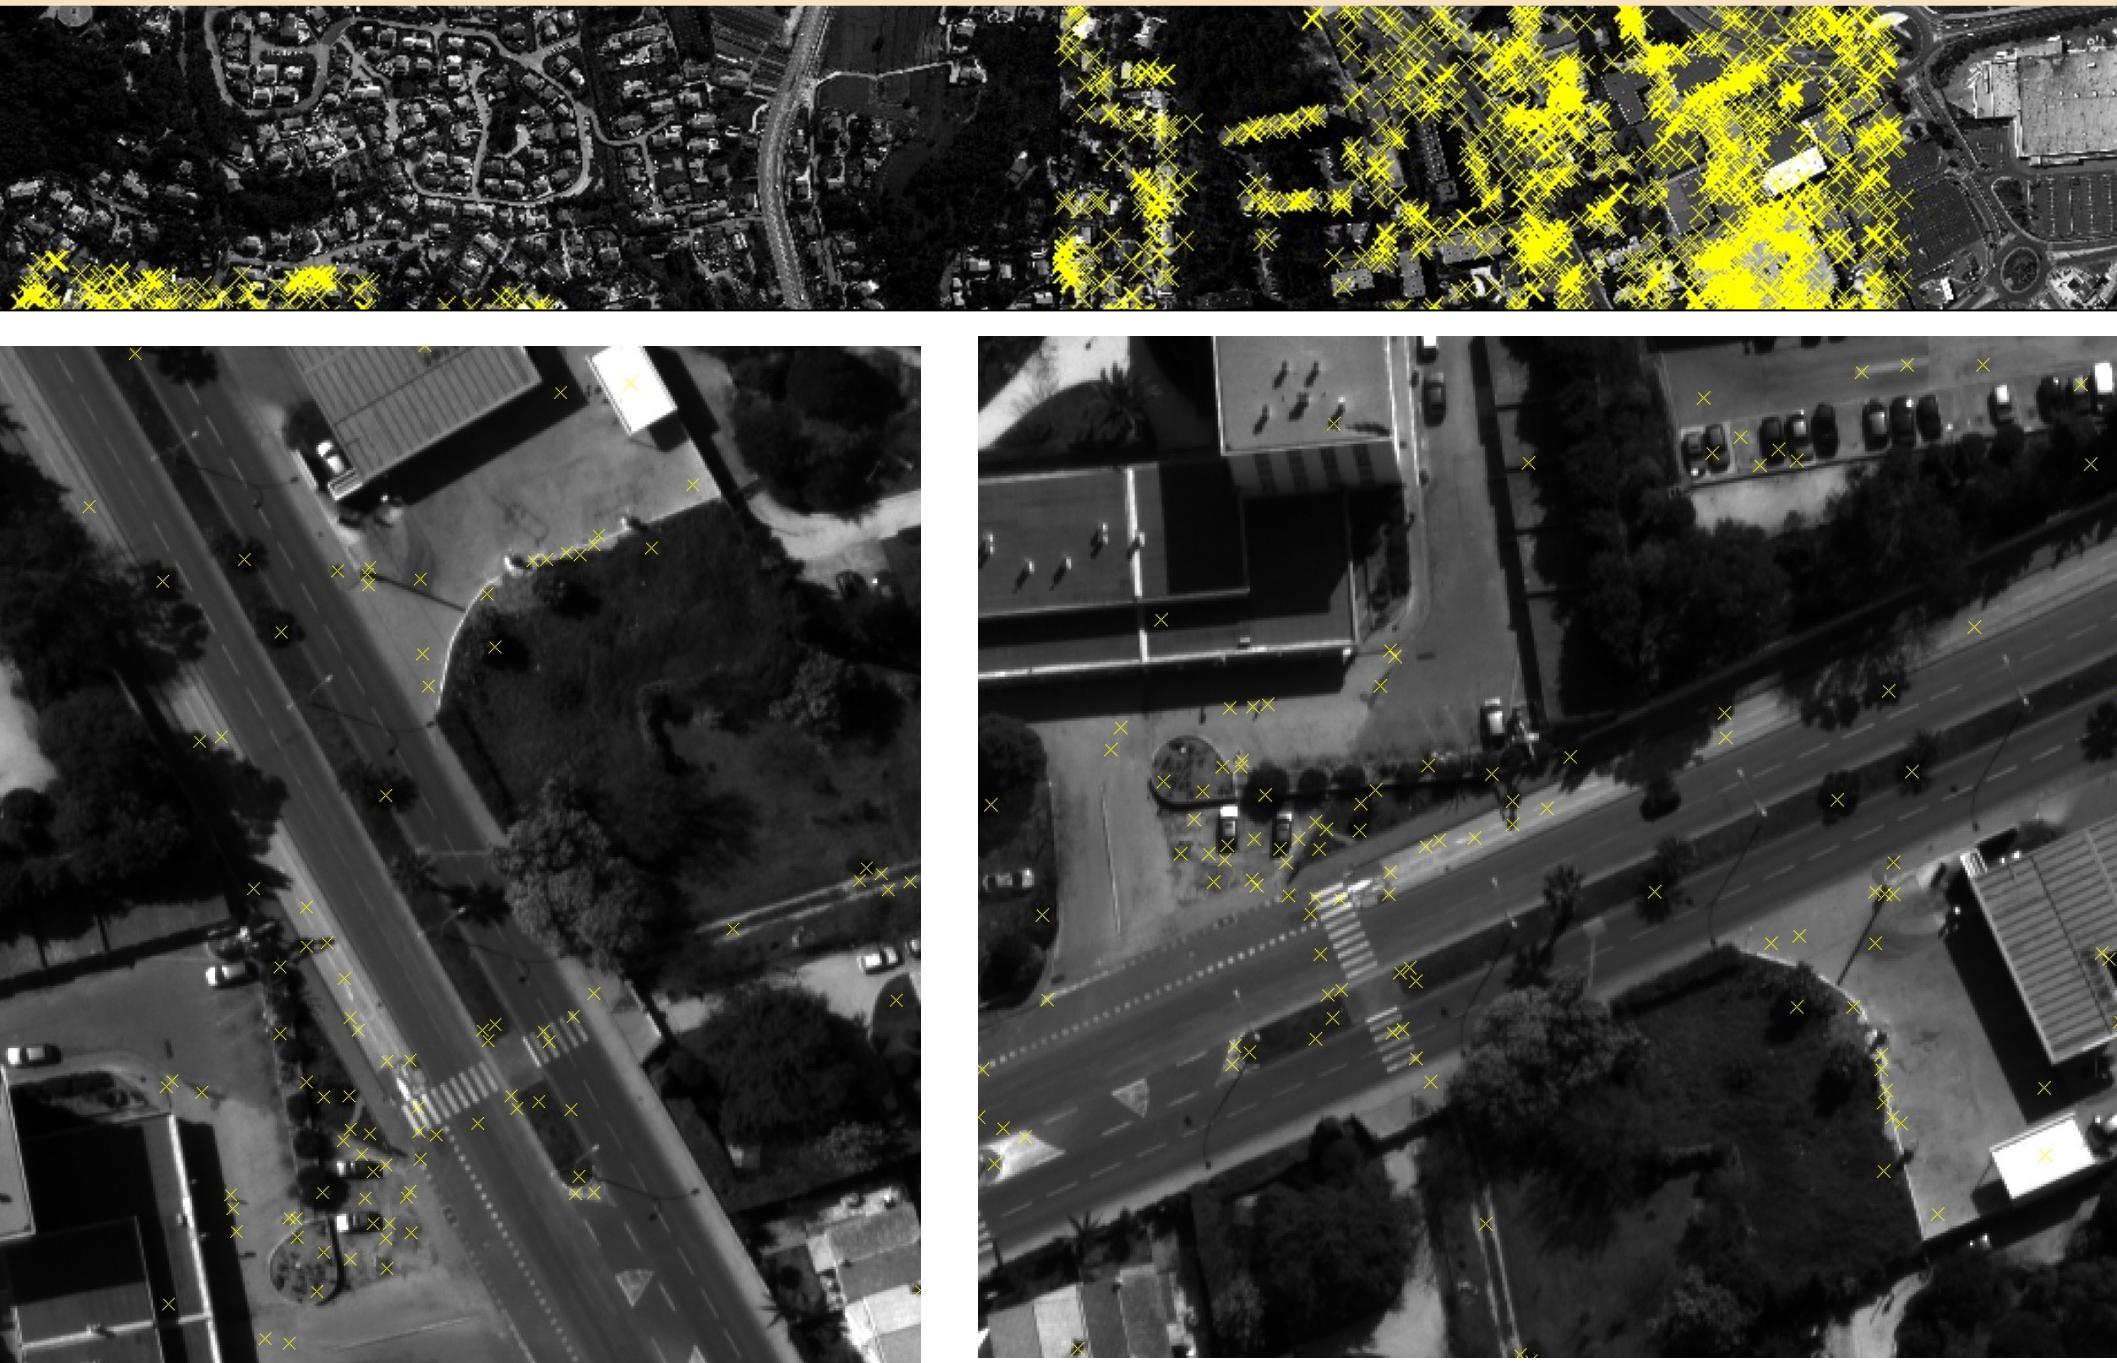
Prise de vue oblique



Applications



Applications



Applications

Mesure de points de liaison pour l'aérotriangulation Comparaison Harris / SIFT

avec SIFT :

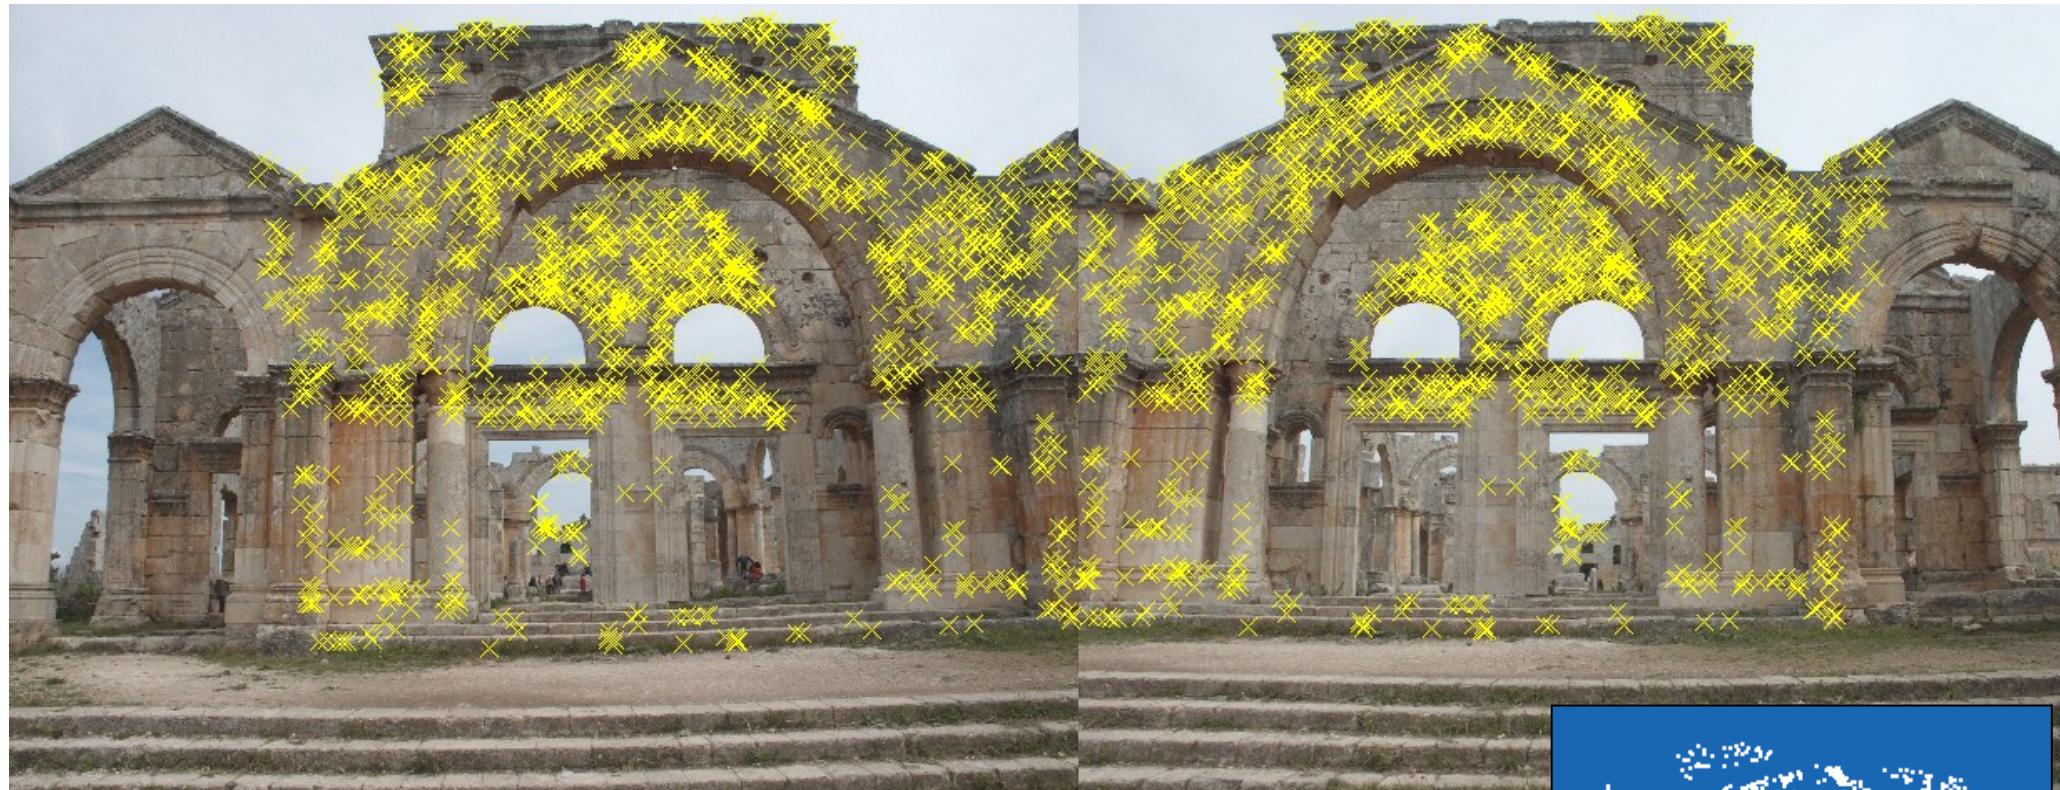
- Détection de points (image par image)
- Calcul de leur descripteur
- Appariement des points détectés (couple par couple)
- Filtrage

Pas besoin de prédicteur...

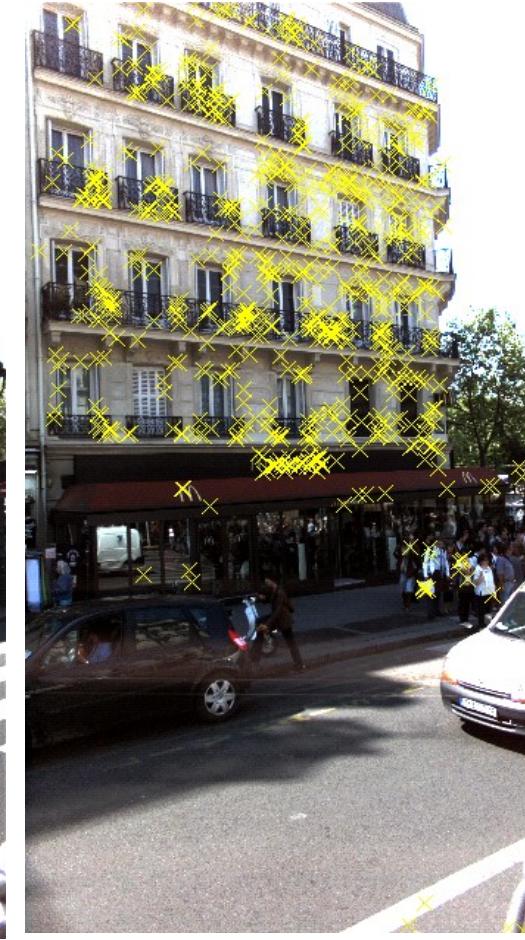
Applications



Applications

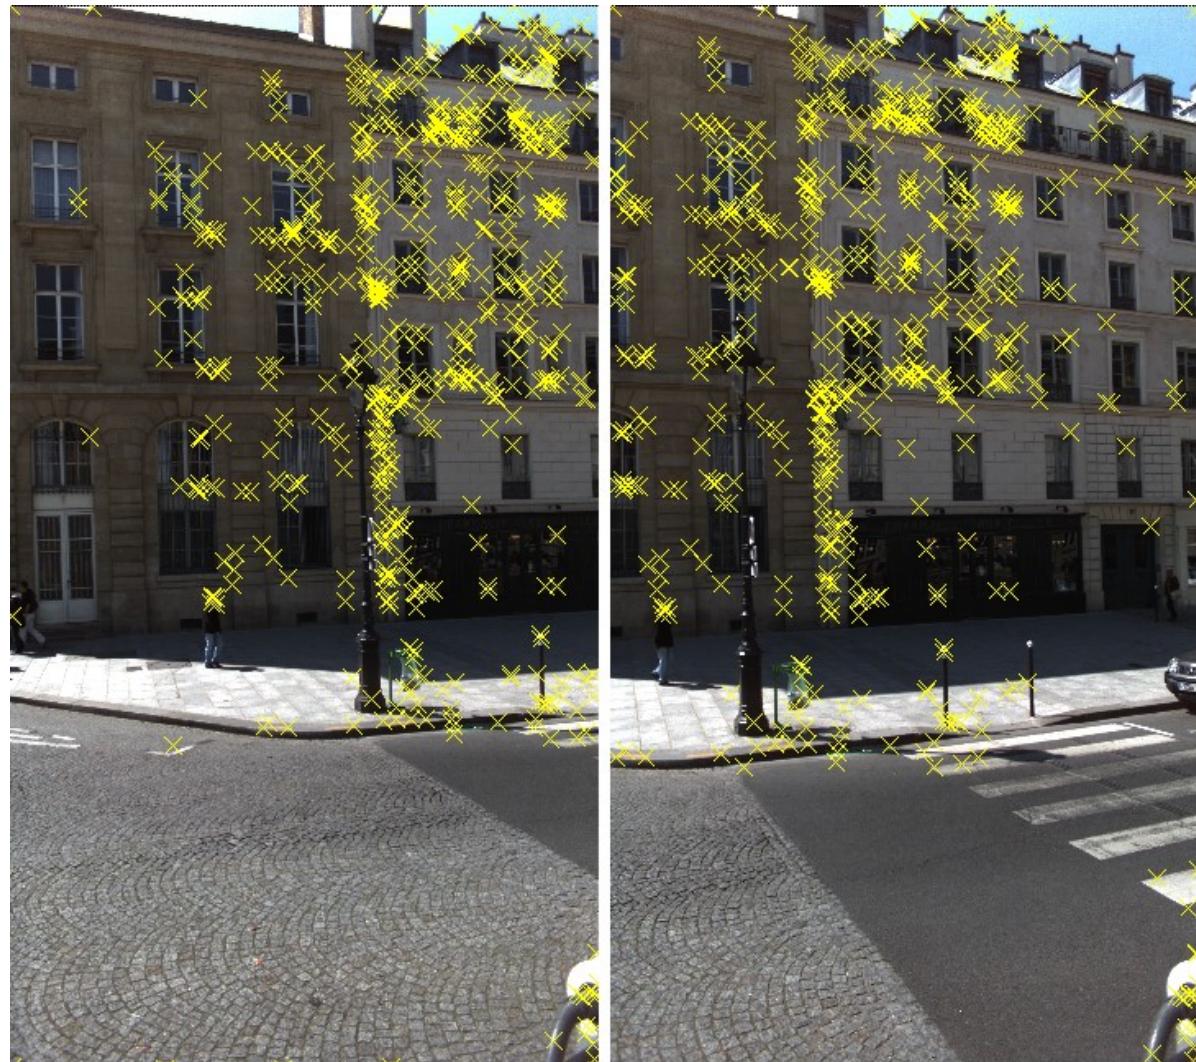


Applications

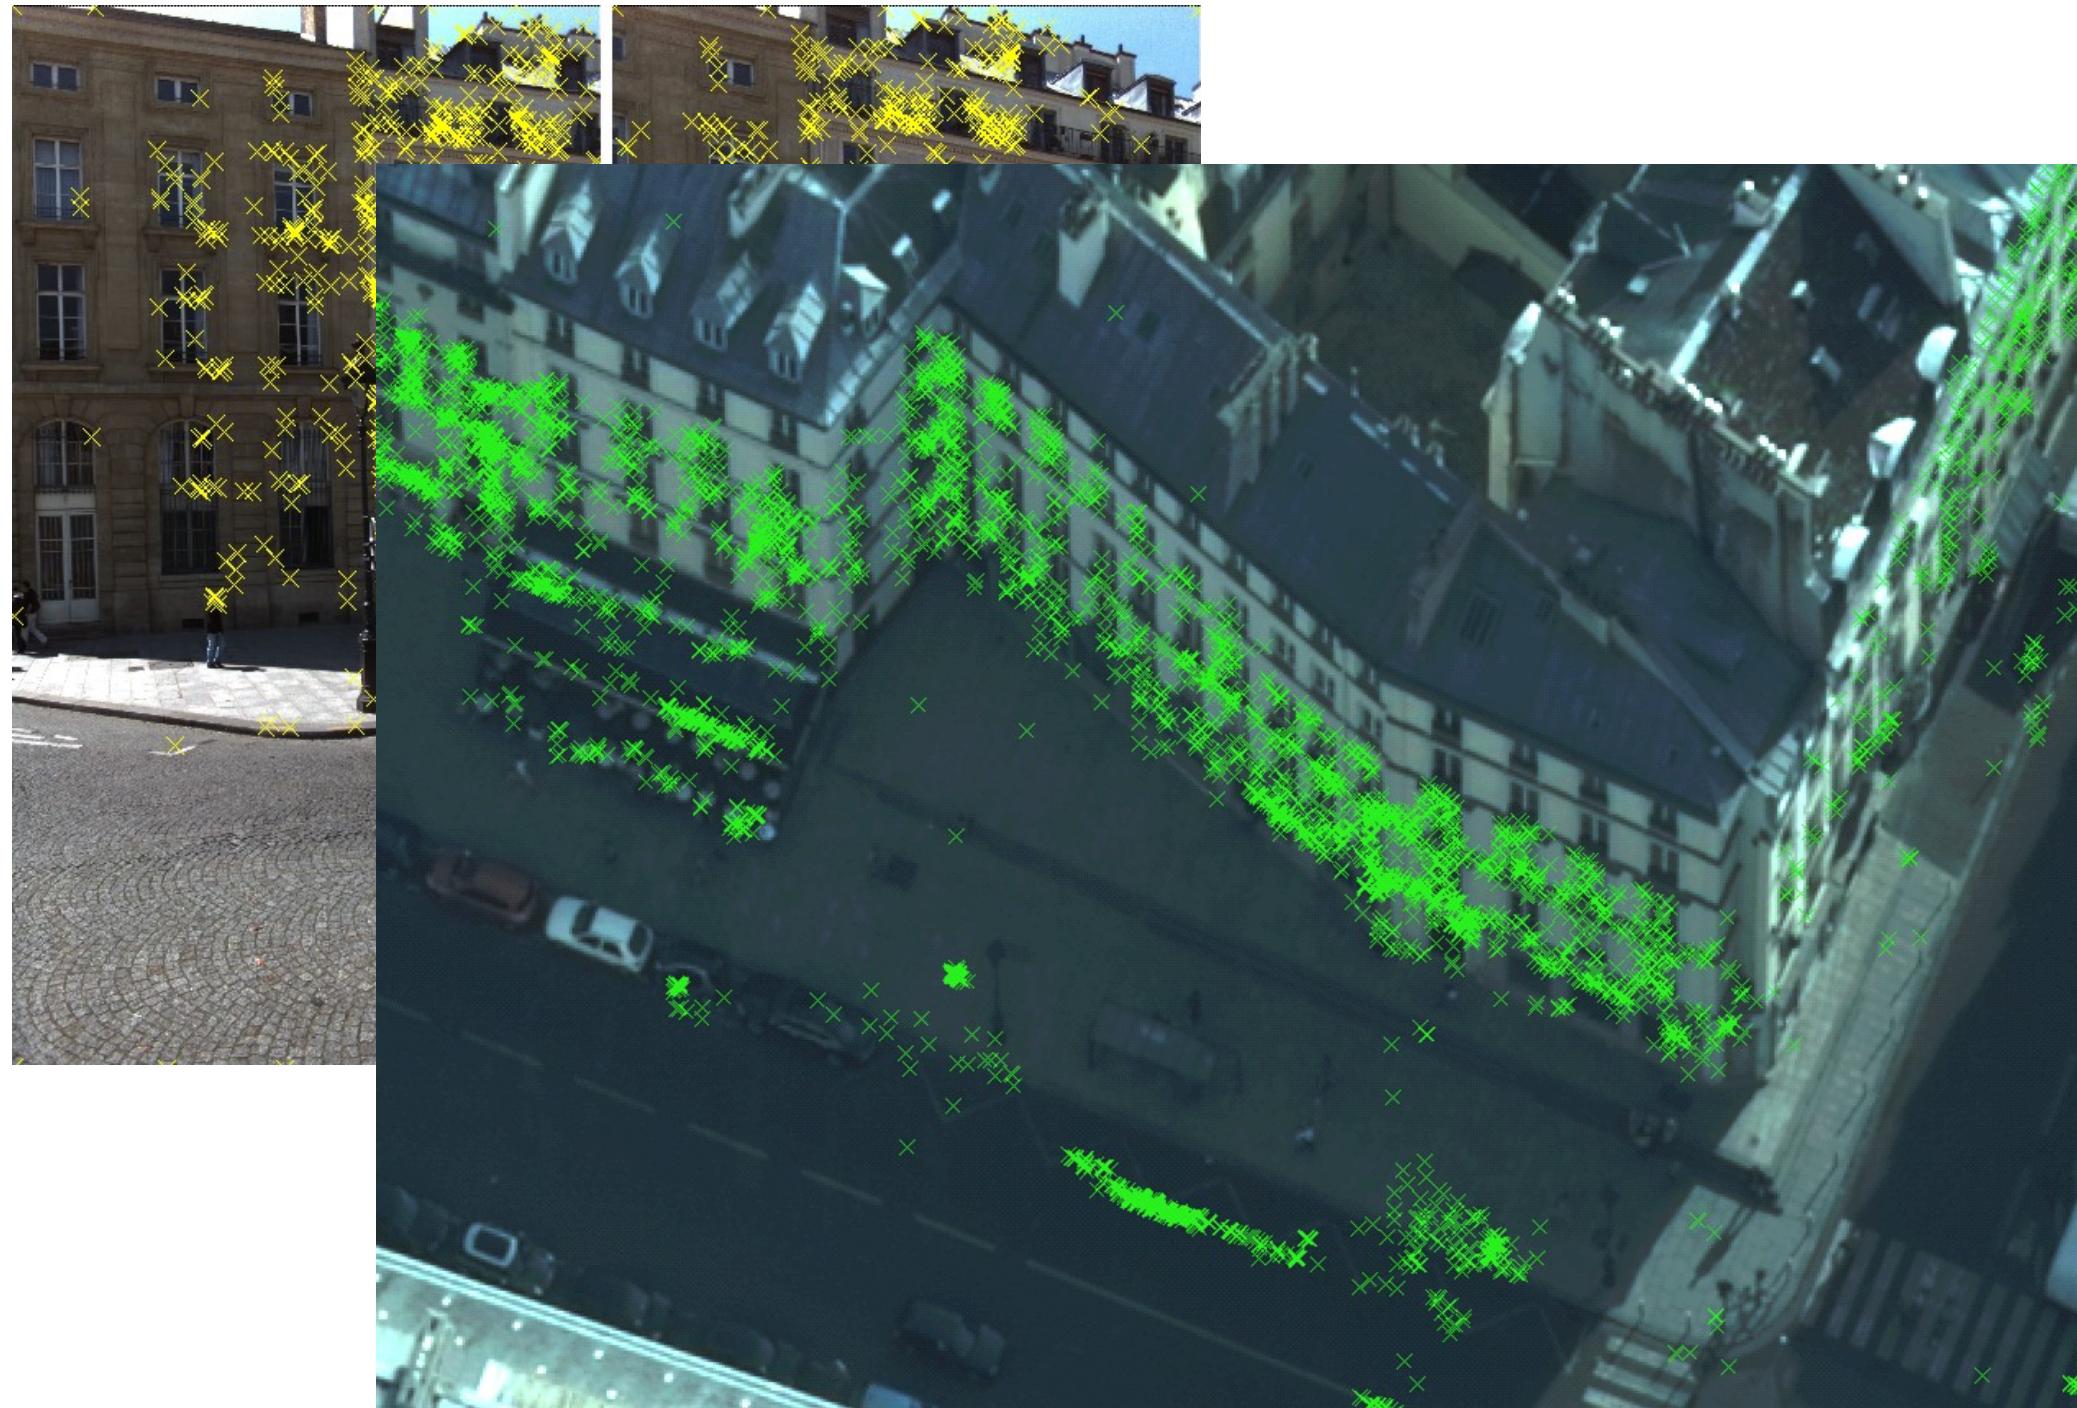


Motifs répétitifs...

Applications



Applications



Applications

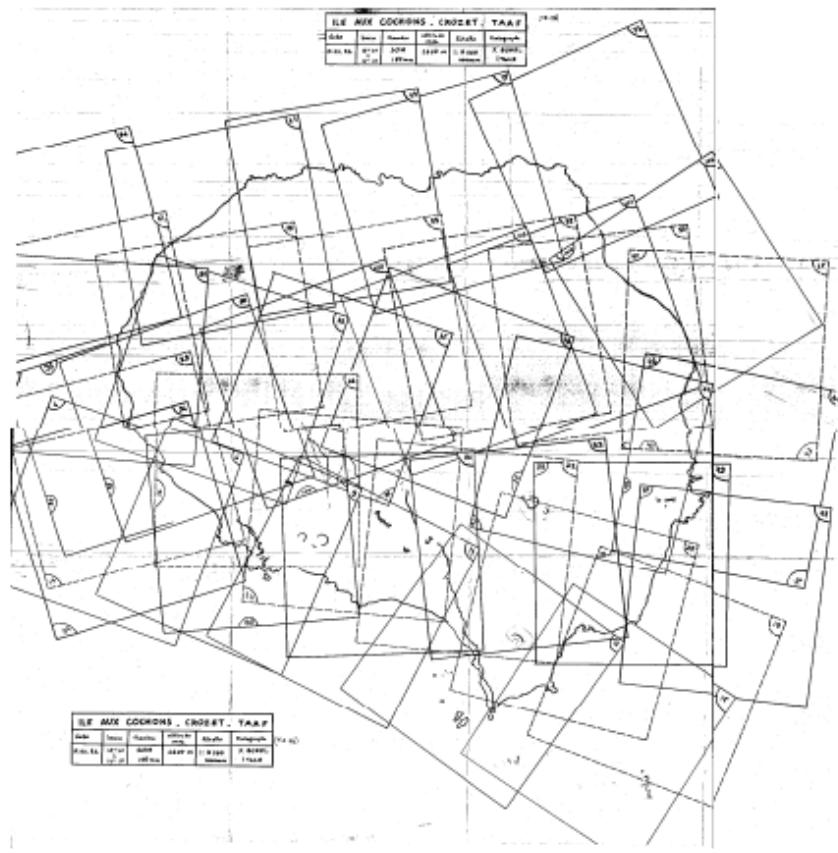


Applications

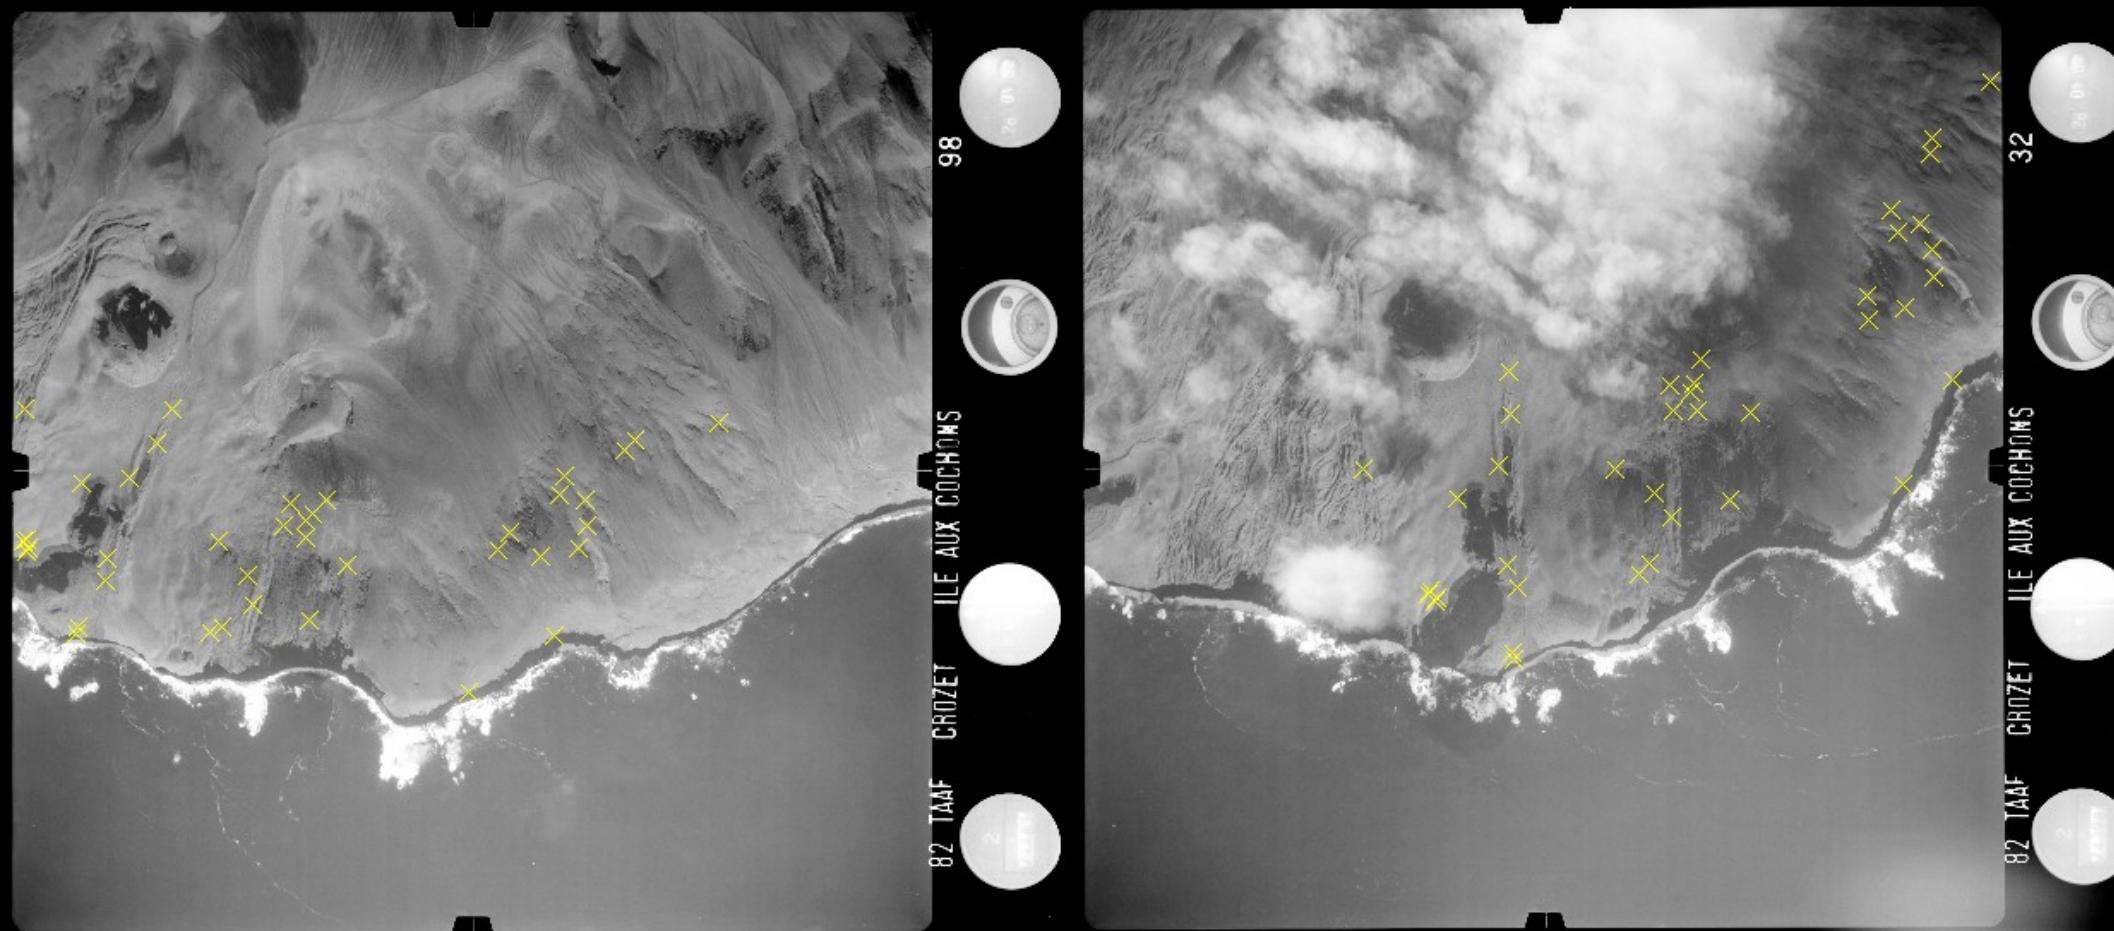
Calcul automatique d'un tableau d'assemblage

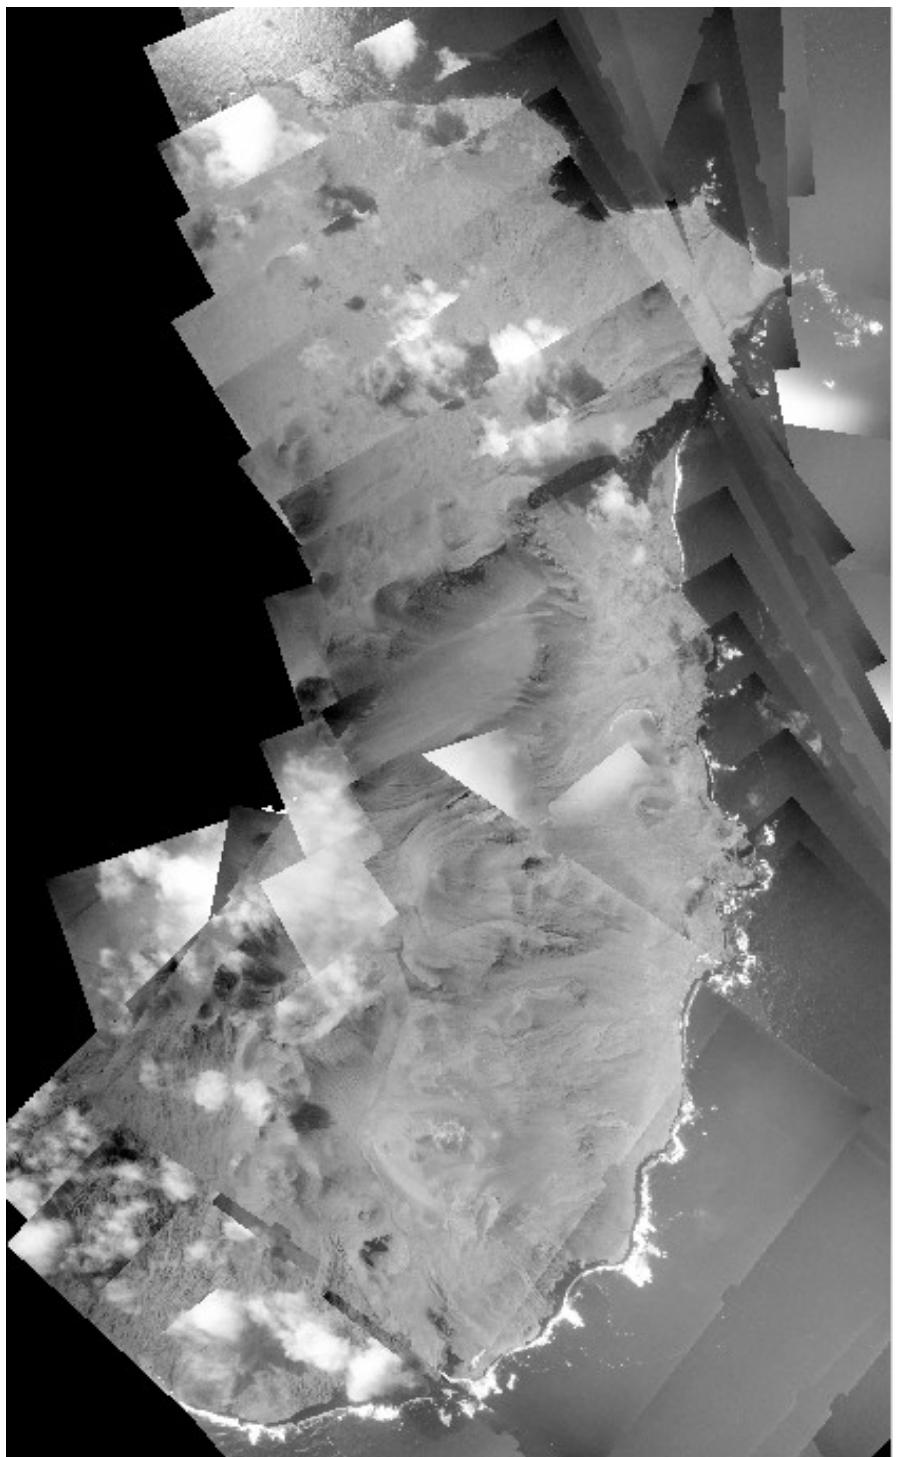
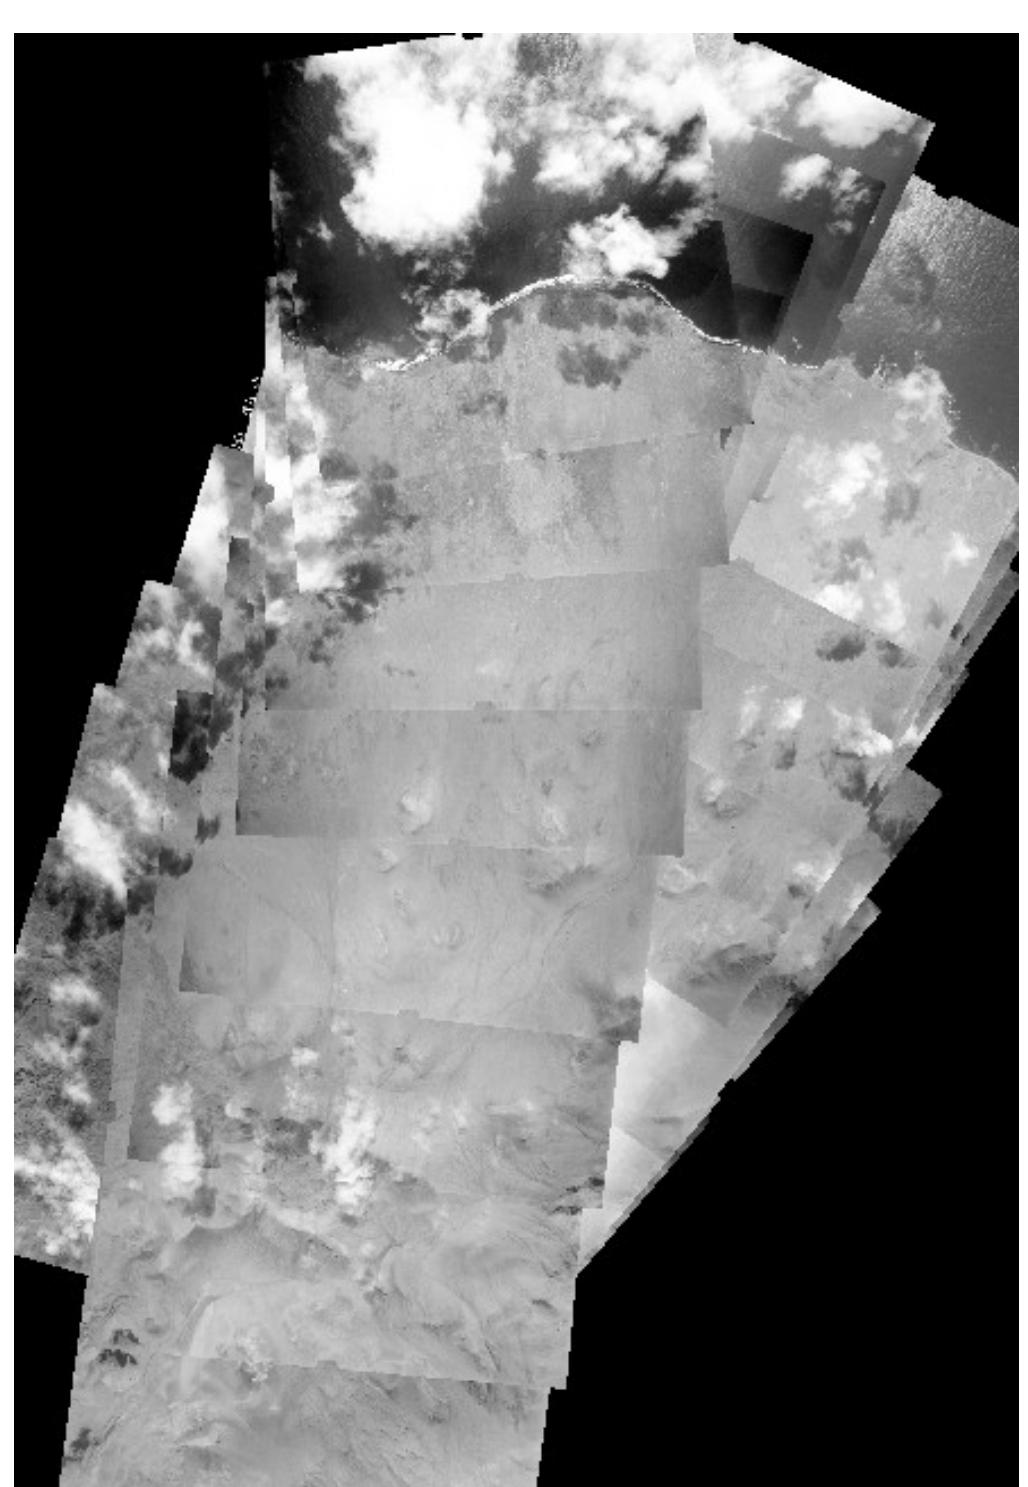
Cas du chantier de l'Ile aux Cochons

- un chantier ancien (images acquises en 1982)
- pas d'orientation approchée des images
- images acquises depuis un hélicoptère (rotations importantes)
- présence de l'océan
- présence importante de nuages
- présence de tâches blanches
- bruit



Applications





Applications

Reconnaissance d'objets

