

# CLASSIFICATION ORIENTEE OBJET

**Ingénieurs 2ème année**


19 novembre 2019

Clément MALLET – [clement.mallet@ign.fr](mailto:clement.mallet@ign.fr)

# INTRODUCTION

# Motivation

- Analyse orientée-objet = Passage du niveau d'analyse « Pixel » au niveau « **Régions** ».
  - OBIA : *Object-Based Image Analysis*
  - On parle aussi de GEOBIA : *GEOgraphic OBIA*
- 
- ▶ Région = groupe de pixels connexes ;
  - ▶ Utilisation d'une image (sur)segmentée en entrée.




# Motivation

- Les classification pixellaires sont limitées car :
  - Elles sont **bruitées** tant qu'on ne fait pas intervenir de grands voisinages
    - Pixel = radiométrie influencée par l'environnement et le processus d'acquisition
  - La **taille des images** augmente de plus en plus
    - Temps de traitement explosent
  - La **résolution spatiale** des images augmente de plus en plus
    - La variabilité spectrale intra-classe augmente.


# Motivation

- Image aérienne en
- Infra-Rouge





# Motivation

- Classification
  - Champs
  - Forêts
  - Sable
  - Eau












Moti




Mot




Moti

Vote majoritaire dans un voisinage 3x3



Moti

Vote majoritaire dans un voisinage 5x5





Moti



## ► Ajouts d'informations :

- **Internes** aux processus d'analyse d'images : *classifications pixellaires issues de connaissances spatiales et spectrales des images*

- **Externes** :

- a priori de formes ;
- relations spatiales entre classes ;
- hiérarchies entre classes ;
- variables auxiliaires : données sociétales, pédologiques, géologiques.


## ► OBIA :

- Formalisation des critères de photo-interprétation : forme, taille, structure, ton, texture, ombres et association.



# Passage au niveau « objet »

- Niveau pixellaire : pas de vraie analyse ni de relations entre eux



- Niveau objet : émergence de structures, de formes au(x) niveau(x)
  - Spatial ;
  - Spectral ;
  - Temporel,

*Assez proches de ce que vous faites avec de la photo-interprétation*

# QUELQUES ILLUSTRATIONS

# Extraction d'attributs


- On se débarrasse de l'hétérogénéité pixellaire (régions = objets).

*Ex : Radiométrie moyenne*



# Extraction d'attributs

- Quel est le meilleur filtre statistique pour synthétiser l'information ?  
→ *ça dépend des classes qui vous intéressent*



Attribut  $a$



$$\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}$$

$n$  pixels

- Moyenne
- Écart-type
- Max/Min
- Percentiles
- Entropie
- ??

# Extraction d'attributs

- On connaît le meilleur voisinage local (régions = voisins  $\leftrightarrow$  objets)



Statistiques intéressantes

J'ai des petites régions qui ne couvrent jamais 2 objets.

Je respecte bien les gradients dans l'image

# Extraction d'attributs

- ▶ On connaît le **meilleur voisinage local** :
  - **Assurance** : 1 région < 1 objet → Pas de mélanges, pas de sous-segmentation.
  - Pour le calcul des attributs qui nécessitent une **petite fenêtre d'analyse** autour de chaque pixel.
  - Du coup, pas besoin de se demander quelle taille de fenêtre est la plus utile (3x3 ? 5x5 ? 15x15?)
  - Très utile pour les attributs de texture.





# Extraction d'attributs

- ▶ On estime de **nouveaux paramètres morphologiques**.
  - Nécessaire d'avoir des critères de **forme(s)** pour séparer des classes spectralement identiques.
  - 2 techniques simples :
    1. Critères génériques morphologiques (identiques à ceux d'analyse spatiale en SIG) : vous en connaissez ?
    2. *Template matching* : parmi un ensemble de formes disponibles (rectangles, cercles etc.), lequel s'ajuste le mieux aux contours de ma région ?

# Extraction d'attributs

## ► Critères morphologiques :

- Aire
- Boite englobante
- Longueur du contour
- Compacité



# Extraction d'attributs

## ► Critères morphologiques

??

??






# Extraction d'attributs

- Ajustement de formes :

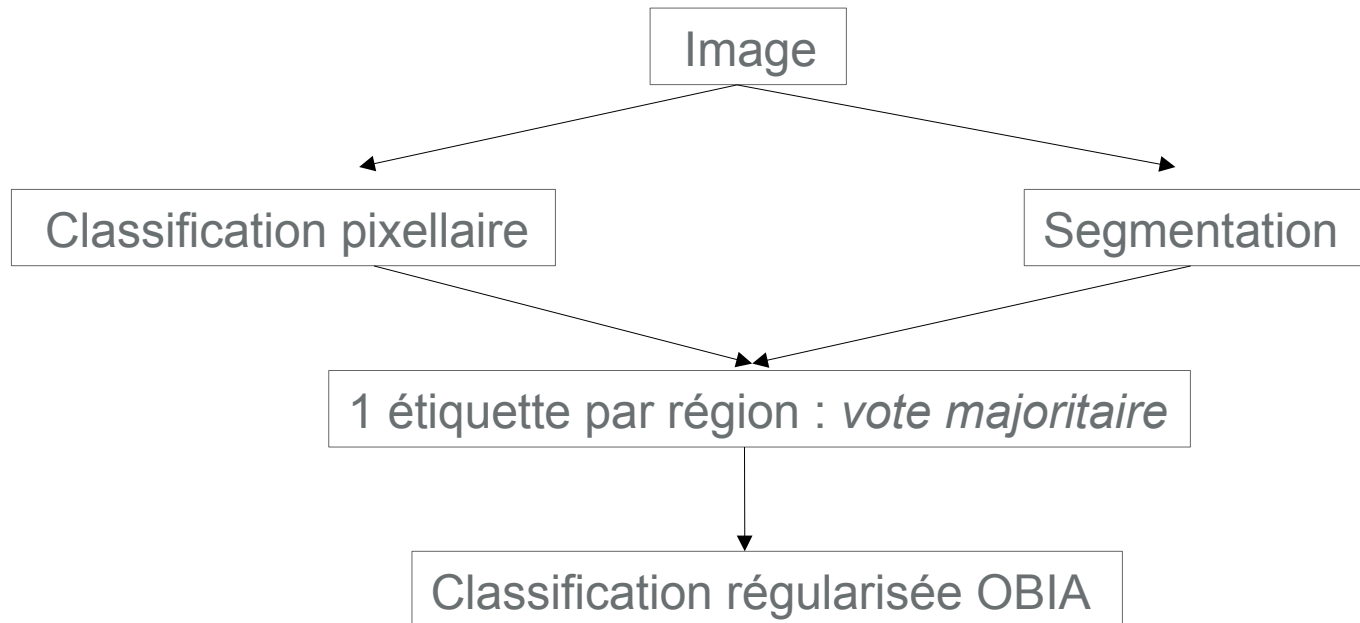
Limitations ?

Améliorations ?



# Régularisation

► Au niveau des décisions :



# Régularisation au niveau des décisions

---


- Ce sera l'objectif du TP du 9 décembre



# Régularisation

## ► Ajout de contexte spatial : relations de voisinage entre régions

1. Élagage : les petites régions incluent dans de plus grandes sont fusionnées avec ces dernières



# Régularisation

## ► Ajout de contexte spatial : relations de voisinage entre régions

1. Élagage : les petites régions incluent dans de plus grandes peuvent être fusionnées avec ces dernières.

*Sauf classes fortes. Ex : bâtiments.*

### 2. Plausibilité :

→ Segments de petites tailles : il est fort probable que le segment voisin soit de la même classe.

→ Grandes tailles : quelles configurations sont réalistes ?

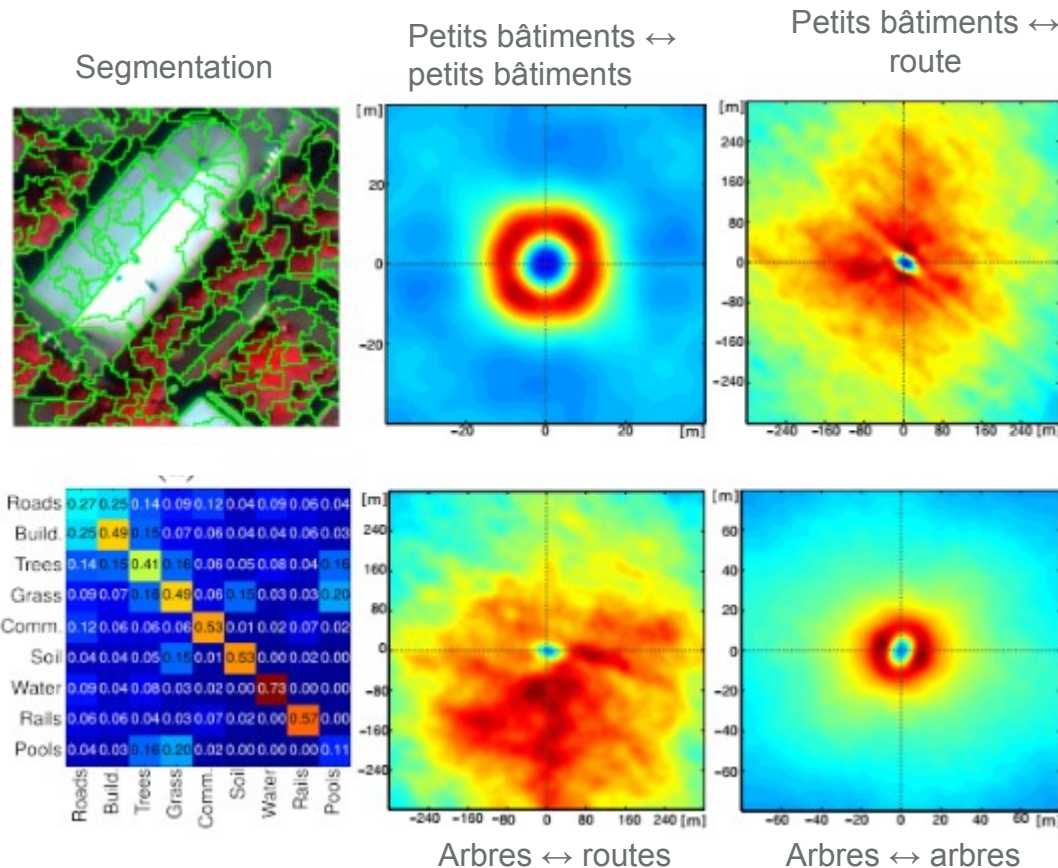
*Route voisine de bâtiments ? Arbres au milieu d'un parking ? Pelouse au milieu d'une rivière ?*

Fait en **post-classification** ou **dans la classification** (méthodes complexes).

# Régularisation

## ► Ajout de contexte spatial : extraction automatique de connaissances

– Issu d'une vérité terrain « dense » existante



Probabilité qu'un  
segment « classe A »  
soit voisin d'un  
segment « classe B »


# Régularisation

## ► Ajout de contexte spatial : extraction automatique de connaissances

– Plus simple : *auto-context*

Les fréquences d'apparition de classes « atomiques » sont utilisées comme **attributs pour la classification** :

- des mêmes classes ;
- de nouvelles classes correspondant à des concepts plus avancés




Arbres ↔ routes

Arbres ↔ arbres



# Régularisation


- **Ajout de contexte spatial** : extraction automatique de connaissances
  - Plus simple : *auto-context* à *plusieurs échelles spatiales*



Niveau 0

# Régularisation

- **Ajout de contexte spatial** : extraction automatique de connaissances
  - Plus simple : *auto-context* à *plusieurs échelles spatiales*




Niveau 1



# Régularisation

- **Ajout de contexte spatial** : extraction automatique de connaissances
  - Plus simple : *auto-context* à *plusieurs échelles spatiales*



Niveau 2

# Régularisation

## ► Ajout de contexte spatial : extraction automatique de connaissances

– Plus simple : *auto-context* à plusieurs échelles spatiales



- Annual summer crops
- Annual winter crop
- Broad-leaved forest
- Coniferous forest
- Natural grasslands
- Woody moorlands
- Continuous urban fabric
- Discontinuous urban fabric
- Industrial or commercial units
- Road surfaces
- Water bodies
- Intensive grassland
- Orchards
- Vineyards

Image satellite Sentinel 2

Arbres ↔ routes

Arbres ↔ arbres



# Régularisation

## ► Ajout de contexte spatial : extraction automatique de connaissances

– Plus simple : *auto-context* à *plusieurs échelles spatiales*



- Annual summer crops
- Annual winter crop
- Broad-leaved forest
- Coniferous forest
- Natural grasslands
- Woody moorlands
- Continuous urban fabric
- Discontinuous urban fabric
- Industrial or commercial units
- Road surfaces
- Water bodies
- Intensive grassland
- Orchards
- Vineyards

*Classification pixellaire*

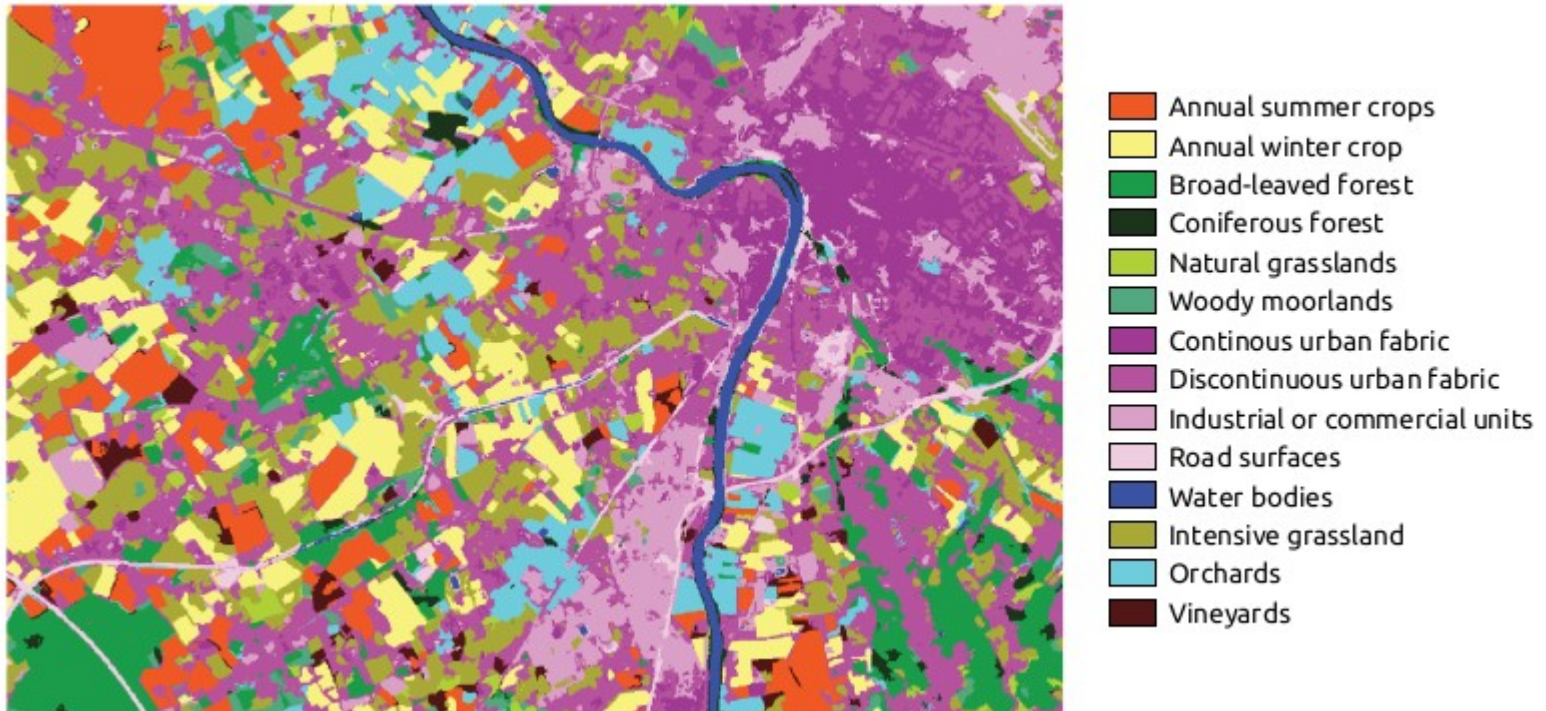
Arbres ↔ routes

Arbres ↔ arbres

# Régularisation

## ► Ajout de contexte spatial : extraction automatique de connaissances

– Plus simple : *auto-context* à *plusieurs échelles spatiales*



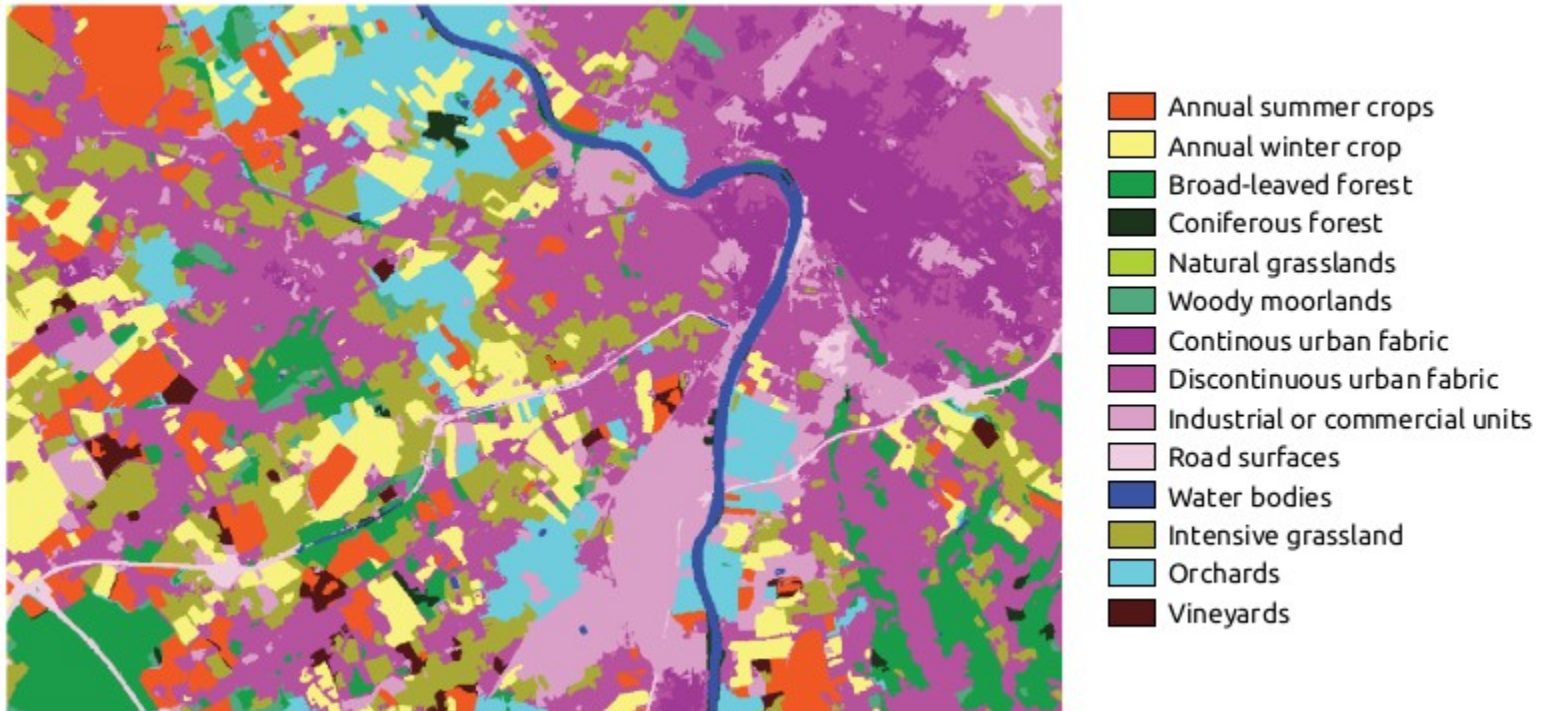
*Classification avec auto-context*



# Régularisation

## ► Ajout de contexte spatial : extraction automatique de connaissances

– Plus simple : *auto-context* à *plusieurs échelles spatiales*



*Classification avec auto-context niveau 2*


Arbres ↔ routes

Arbres ↔ arbres



# Régularisation

- Ajout de contexte spatial : relations de voisinage hiérarchique entre régions



– Segmentations et classifications à **différents niveaux**


→ Classifications au niveau  $N-1$  une forte probabilité de coïncider avec celle du niveau  $N$

→ Classification au niveau  $N$  peut utiliser les classifications du niveau  $N-1$

- Pas forcément de correspondance 1:1 entre les niveaux.

# Régularisation

- Ajout de contexte spatial : relations de voisinage hiérarchique entre régions



Tâche urbaine

Zone résidentielle

Bâti, pelouse, haie, route, bâti, pelouse etc.

# Régularisation

## ► Ajout de connaissances a priori :

→ Issues de l'analyse de classifications déjà existantes

→ Issues de connaissances métiers :

*Cultures en terrasse ?*

*Taillis sous futaie ?*

*Carrières ?*

*Zones inondables ?*

	Biotope complex	Minimum mapping area
I	Residential buildings of cities, towns and villages	0.5 ha
II	Mixed use development, industrial or commercial areas	0.5 ha
III	Vehicular and pedestrian networks minimum width	20 m
IV	Green space, cemeteries, recreation areas and domestic gardens	0.5 ha
V	Mineral extraction sites	2 ha
VI	Infrastructure and storage area	0.5 ha
VII	Arable land, poor in accompanying habitat structures	4 ha
VIII	Arable land, rich in accompanying habitat structures	2 ha
IX	Vineyards and fruit plantations	2 ha
X	Special cultivation area	2 ha
XI	Mixed arable land and grassland area	2 ha
XII	Agriculturally improved grassland	2 ha
XIII	Extensive grassland	2 ha
XIV	Open orchard meadows	2 ha
XV	Abandoned open areas	2 ha
XVI	Fens and bogs	0.5 ha
XVII	Broad-leaved forests	5 ha resp. 2 ha
XVIII	Coniferous forests	5 ha resp. 2 ha
XIX	Areas of water	0.5 ha

# Régularisation


---

► Ajout de connaissances a priori :

→ Données exogènes : pente, position du soleil etc.

# Modèles Probabilistes Graphiques

- Y un champ aléatoire d'étiquettes. Sur une image Y définit la segmentation, une valeur d'étiquettes en chaque pixel.
- X le champ aléatoire d'observations. X représente les valeurs de chaque pixel.



**Théorème de Bayes** : transformation de la probabilité de l'image (X) sachant la scène (Y) en la probabilité de la scène sachant l'image

$$P(Y|X) = \frac{P(X|Y).P(Y)}{P(X)}$$


X (intensités) ne varient pas pendant le processus de segmentation, trouver la maximum a posteriori (MAP), revient à trouver la réalisation de Y qui maximise

$$P(Y|X) \propto P(X|Y).P(Y)$$




# Modèles Probabilistes Graphiques

- Soit un graphe, avec un ensemble de nœuds et de voisinages.



- On définit une *clique d'ordre  $n$* , ensemble de  $n$  sites (nœuds/pixels) tous voisins 2 à 2



# Champs de Markov

- ▶ Un champ aléatoire  $Y$  est dit **Champ de Markov** si et seulement si la probabilité de réalisation en un site conditionnellement aux autres ne dépend que de la réalisation dans un voisinage  $vs$  du site.
- ▶ Alors :  $P(y_s | Y_{S \setminus s}) = P(y_s | y_{vs})$
- ▶ Le théorème d'Hammersley-Clifford dit :  $P(Y) = \exp(-U(Y)) / Z$   
 $Z$  est une constante de normalisation.
- ▶ On définit alors l'énergie  $U(Y)$  comme la somme de fonctions potentielles sur les cliques :  $U(Y) = \sum_c V_c(Y)$
- ▶ Et donc :  $P(Y) = \exp(-\sum_c V_c(Y)) / Z$
- ▶ Dans un cas Markovien, on cherche une réalisation qui **minimise la somme des fonctions potentielles**

# Vraiesemblances

$$P(X|Y).P(Y) = P(X|Y).\exp(-\sum_c V_c(Y)) / Z$$

► Hypothèses :

- Indépendance des observations :  $P(X|Y) = \prod_s P(x_s|Y)$
- L'observation de dépend que de la classe du site :  $P(x_s|Y) = P(x_s|y_s)$

► Donc :  $P(X|Y) = \prod_s P(x_s|y_s)$

► On définit :  $V(x_s|y_s) = -\ln(P(x_s|y_s))$       donc :  $P(x_s|y_s) = \exp(-V(x_s|y_s))$

► Alors :  $P(X|Y) = \exp(-\sum_s V(x_s|y_s))$

► Au final, la probabilité a posteriori est donc proportionnelle à un terme total qui est à maximiser :

$$P(Y|X) \propto \exp(-\sum V(x_s|y_s) - \sum V_c(Y))$$

# Minimisation d'énergie

- Cela revient à minimiser l'énergie suivante:

$$E(Y) = \sum_s V(x_s | y_s) + \sum_c V_c(Y)$$

## Terme d'attache aux données

On évalue la pertinence du label  $x_s$  compte-tenu de l'intensité  $y_s$

## Terme contextuel

On encourage la similarité d'étiquettes, introduit un a priori de voisinage sur les étiquettes et pour assurer la régularité de la segmentation

- Minimiser  $E$  revient à réaliser un **compromis** entre la précision et la régularité de la segmentation
- On ne peut tester toutes les réalisations de  $Y$  et évaluer  $E(Y)$   
→ solutions exactes et approchées, déterministes et stochastiques.

# Minimisation d'énergie

- Cela revient à minimiser l'énergie suivante:

$$E(Y) = \sum_s V(x_s | y_s) + \sum_c V_c(Y)$$

## Terme d'attache aux données

On évalue la pertinence du label  $x_s$  compte-tenu de l'intensité  $y_s$

## Terme contextuel

On encourage la similarité d'étiquettes, introduit un a priori de voisinage sur les étiquettes et pour assurer la régularité de la segmentation

- Minimiser  $E$  revient à réaliser un **compromis** entre la précision et la régularité de la segmentation
- On ne peut tester toutes les réalisations de  $Y$  et évaluer  $E(Y)$   
→ solutions exactes et approchées, déterministes et stochastiques.



## Exemple simple à 2 classes


$$E(X) = \sum_{i=1}^p D_i(x_i) + \alpha \sum_{\substack{i=1 \dots n \\ j \in N_i}} V_{ij} \partial(x_i \neq x_j)$$

# Exemple simple à 2 classes


$$E(X) = \sum_{i=1}^p D_i(x_i) + \alpha \sum_{\substack{i=1 \dots n \\ j \in N_i}} V_{ij} \partial(x_i \neq x_j)$$

$$\begin{cases} D_i(0) = I_i \\ D_i(1) = 1 - I_i \end{cases}$$

(on se ramène à des intensités entre 0 et 1)



$$V_{ij}(x_i, x_j) = 1$$



# Exemple simple à 2 classes



Seuillage ( $\alpha=0$ )

optimisation



$\alpha=0.2$



$\alpha=0.3$



$\alpha=0.4$

